

ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ - ΤΜΗΜΑ ΜΗΧΑΝΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ
ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025-26

ΕΞΑΜΗΝΟ: 8ο

ΜΑΘΗΜΑ: ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ

ΔΙΔΑΣΚΟΥΣΑ: ΣΟΦΙΑ ΠΑΝΑΓΙΩΤΙΔΟΥ, Αν. Καθηγήτρια

5^η ΕΡΓΑΣΙΑ

Όνοματεπώνυμο φοιτητή : _____

A.E.M. : _____

Θεσσαλονίκη, Ιούνιος 2026

Εργασία στο μάθημα "Ανάλυση Δεδομένων" 2025-26

Αντικείμενο της παρούσας εργασίας είναι η ανάπτυξη και εκπαίδευση ενός **Νευρωνικού Δικτύου (Neural Network)** με σκοπό την αυτόματη ταξινόμηση εικόνων χειρόγραφων ψηφίων.

Για το σκοπό αυτό θα χρησιμοποιηθεί το σύνολο δεδομένων **MNIST**, το οποίο αποτελεί ένα από τα πιο διαδεδομένα σημεία αναφοράς (benchmarks) στον τομέα της Μηχανικής Μάθησης. Το σύνολο MNIST περιλαμβάνει ασπρόμαυρες εικόνες (grayscale) από χειρόγραφα ψηφία της αριθμητικής κλίμακας 0 έως 9. Κάθε εικόνα έχει διάσταση **28x28 pixels**, και κάθε pixel λαμβάνει μια τιμή έντασης από το 0 (μαύρο) έως το 255 (λευκό).

Τα δεδομένα που σας παρέχονται είναι οργανωμένα σε μορφή αρχείων PNG και CSV (labels.csv). Τα αρχεία labels.csv περιλαμβάνουν τα paths των αρχείων εικόνας και τις αντίστοιχες ετικέτες (labels) για τα σύνολα εκπαίδευσης (train) και ελέγχου (test).

Από τα αρχικά αρχεία δεδομένων που σας δίνονται, πρέπει να επιλέξετε ένα υποσύνολο χρησιμοποιώντας τον αριθμό Ειδικού Μητρώου (AEM) σας ως seed. Αναλυτικότερα:

1. **Train Set:** Επιλέξτε τυχαία το **90%** των δειγμάτων του αρχικού αρχείου εκπαίδευσης.
2. **Test Set:** Επιλέξτε τυχαία το **80%** των δειγμάτων του αρχικού αρχείου ελέγχου.

ΕΝΟΤΗΤΑ Α: Νευρωνικό Δίκτυο (Simple NN)

Για την κατασκευή και εκπαίδευση του νευρωνικού δικτύου πρέπει να πραγματοποιηθούν τα ακόλουθα:

1. Προσδιορίστε το σχήμα (shape) των δεδομένων και το πλήθος των κλάσεων. Ελέγξτε αν το δείγμα είναι ισορροπημένο (πλήθος δειγμάτων ανά ψηφίο).
2. **Κανονικοποίηση:** Μετατρέψτε τις τιμές των pixels στο διάστημα $[0, 1]$. Εξηγήστε σύντομα πώς αυτή η διαδικασία βοηθά στη σύγκλιση του αλγορίθμου εκπαίδευσης.
3. **Flattening:** Μετατρέψτε τις 2D εικόνες σε μονοδιάστατα διανύσματα 784 στοιχείων (28x28). Πώς βοηθάει αυτό το μοντέλο;
4. Κατασκευάστε ένα Sequential μοντέλο με την εξής δομή:
 - **Input Layer:** Dense, 784 νευρώνες, ενεργοποίηση ReLU.
 - **Hidden Layer 1:** Dense, 256 νευρώνες, ενεργοποίηση ReLU.
 - **Hidden Layer 2:** Dense, 128 νευρώνες, ενεργοποίηση ReLU.
 - **Output Layer:** Dense, 10 νευρώνες, ενεργοποίηση Softmax.

5. **Εκπαίδευση:** Προκειμένου να εκπαιδεύσετε το μοντέλο χρησιμοποιήστε κάποιον optimizer καθώς και μία συνάρτηση απώλειας (loss function). Να εξηγήσετε την επιλογή σας. Εκπαιδεύστε για **30** epochs με 10% validation split.
6. **Αξιολόγηση:**
 - Σχεδιάστε τις καμπύλες Accuracy και Loss για τα σύνολα train και validation.
 - Υπολογίστε την ακρίβεια στο Test Set και δημιουργήστε τον **Πίνακα Σύγχυσης (Confusion Matrix)**.
 - **Σχολιασμός:** Ποια ψηφία μπερδεύονται συχνότερα και γιατί (βάσει της μορφολογίας τους); Εντοπίζετε φαινόμενα overfitting;

ΕΝΟΤΗΤΑ Β: Συνελικτικό Νευρωνικό Δίκτυο (CNN)

Σε αυτή την ενότητα θα εκμεταλλευτούμε τη χωρική δομή των εικόνων χρησιμοποιώντας επίπεδα συνέλιξης.

1. Αρχιτεκτονική CNN Δημιουργήστε ένα νέο μοντέλο με την εξής δομή:

- **Conv2D Layer:** 32 φίλτρα (3x3), ενεργοποίηση ReLU.
- **MaxPooling2D:** Παράθυρο 2x2.
- **Conv2D Layer:** 64 φίλτρα (3x3), ενεργοποίηση ReLU.
- **Flatten & Dense:** Ένα τελικό Dense επίπεδο 64 νευρώνων πριν το Output Layer των 10 νευρώνων.

2. Εκπαίδευση και Σύγκριση

- Εκπαιδεύστε το CNN με τις ίδιες παραμέτρους (epochs, optimizer) όπως στην Ενότητα Α.
- Συγκρίνετε την απόδοση του CNN σε σχέση με το απλό NN της προηγούμενης ενότητας ως προς:
 - i. Την ακρίβεια (Accuracy) στο Test Set.
 - ii. Το πλήθος των παραμέτρων του μοντέλου (χρησιμοποιήστε την εντολή `.summary()`).
 - iii. Την ικανότητα του μοντέλου να αναγνωρίζει μοτίβα (εξηγήστε γιατί τα CNN θεωρούνται καταλληλότερα για εικόνες).