

Ανάλυση Δεδομένων 2025-26

5η Εργασία: Νευρωνικά Δίκτυα και CNN στο MNIST

Ταξινόμηση εικόνων χειρόγραφων ψηφίων

Ρακοβαλής Παύλος
ΑΕΜ: 6931

Ιούνιος 2026

Περίληψη

Στην εργασία εκπαιδεύονται δύο νευρωνικά δίκτυα για αυτόματη ταξινόμηση χειρόγραφων ψηφίων του MNIST. Πρώτα χρησιμοποιείται ένα απλό πλήρως συνδεδεμένο νευρωνικό δίκτυο πάνω σε flattened εικόνες και στη συνέχεια ένα συνελκτικό νευρωνικό δίκτυο, το οποίο αξιοποιεί τη χωρική δομή των εικόνων. Τα δεδομένα δειγματοληπτούνται με seed τον ΑΕΜ 6931: 90% του αρχικού train set και 80% του αρχικού test set. Το CNN πέτυχε υψηλότερη ακρίβεια στο test set (98.99%) από το απλό NN (97.56%), ενώ είχε και λιγότερες παραμέτρους.

Περιεχόμενα

1	Δεδομένα και προεπεξεργασία	3
1.1	Shape των δεδομένων και πλήθος κλάσεων	3
1.2	Ισορροπία κλάσεων	4
1.3	Κανονικοποίηση	5
1.4	Flattening	5
2	Ενότητα Α: Απλό Νευρωνικό Δίκτυο	5
2.1	Αρχιτεκτονική	5
2.2	Optimizer και loss function	6
2.3	Αποτελέσματα εκπαίδευσης	6
2.4	Πίνακας σύγκρισης	7
2.5	Overfitting	8
3	Ενότητα Β: Συνελκτικό Νευρωνικό Δίκτυο	8
3.1	Αρχιτεκτονική CNN	8
3.2	Αποτελέσματα εκπαίδευσης	9
3.3	Πίνακας σύγκρισης	10

4 Σύγκριση μοντέλων	11
4.1 Συμπέρασμα	11

1 Δεδομένα και προεπεξεργασία

Το σύνολο MNIST αποτελείται από grayscale εικόνες χειρόγραφων ψηφίων, με διαστάσεις 28×28 pixels. Κάθε εικόνα ανήκει σε μία από τις 10 κλάσεις, δηλαδή στα ψηφία 0 έως 9.

Σύμφωνα με την εκφώνηση, έγινε τυχαία δειγματοληψία με seed τον AEM:

```
random_state = 6931.
```

Από τα αρχικά δεδομένα επιλέχθηκαν:

Σύνολο	Αρχικό πλήθος	Πλήθος μετά τη δειγματοληψία
Train set	60000	54000
Test set	10000	8000

1.1 Shape των δεδομένων και πλήθος κλάσεων

Μετά τη δειγματοληψία, τα δεδομένα έχουν τα εξής σχήματα:

Πίνακας	Shape
x_train ως εικόνες	(54000, 28, 28)
y_train	(54000,)
x_test ως εικόνες	(8000, 28, 28)
y_test	(8000,)
x_train flattened	(54000, 784)
x_test flattened	(8000, 784)
x_train για CNN	(54000, 28, 28, 1)
x_test για CNN	(8000, 28, 28, 1)

Το πλήθος των κλάσεων είναι:


$$K = 10.$$

1.2 Ισορροπία κλάσεων


Πίνακας 1: Πλήθος δειγμάτων ανά ψηφίο μετά τη δειγματοληψία.

Ψηφίο	Train sample	Test sample
0	5329	792
1	6060	905
2	5350	810
3	5522	820
4	5279	791
5	4887	707
6	5347	775
7	5614	827
8	5232	774
9	5380	799

Οι κλάσεις είναι αρκετά ισορροπημένες. Υπάρχουν μικρές διαφορές, με το ψηφίο 1 να εμφανίζεται συχνότερα και το ψηφίο 5 λιγότερο συχνά, όμως καμία κλάση δεν λείπει και οι αναλογίες παραμένουν κοντά στο 10%.



Σχήμα 1: Κατανομή των κλάσεων στα δειγματοληπτημένα train και test sets.



Σχήμα 2: Ενδεικτική εικόνα από κάθε ψηφίο στο training set.

1.3 Κανονικοποίηση

Οι αρχικές τιμές των pixels βρίσκονται στο διάστημα $[0, 255]$. Για την εκπαίδευση των νευρωνικών δικτύων μετατράπηκαν στο διάστημα $[0, 1]$:

$$x_{\text{norm}} = \frac{x}{255}.$$

Η κανονικοποίηση βοηθά στη σύγκλιση, επειδή όλες οι είσοδοι αποκτούν κοινή κλίμακα. Έτσι οι ενημερώσεις των βαρών μέσω backpropagation γίνονται πιο σταθερές, αποφεύγονται πολύ μεγάλες ενεργοποιήσεις και ο optimizer μπορεί να κινηθεί πιο ομαλά προς ένα καλό ελάχιστο της συνάρτησης απώλειας.

1.4 Flattening

Για το απλό πλήρως συνδεδεμένο νευρωνικό δίκτυο, κάθε εικόνα 28×28 μετατράπηκε σε διάνυσμα 784 στοιχείων:

$$28 \cdot 28 = 784.$$

Το flattening είναι απαραίτητο για Dense επίπεδα, επειδή αυτά δέχονται ως είσοδο μονοδιάστατα διανύσματα χαρακτηριστικών. Το μειονέκτημα είναι ότι χάνεται η άμεση χωρική πληροφορία της εικόνας, δηλαδή το ποια pixels είναι γειτονικά μεταξύ τους. Αυτό είναι ένας από τους λόγους που τα CNN είναι πιο κατάλληλα για εικόνες.

2 Ενότητα Α: Απλό Νευρωνικό Δίκτυο

2.1 Αρχιτεκτονική

Το απλό μοντέλο είναι Sequential και αποτελείται από Dense επίπεδα:

Επίπεδο	Ενεργοποίηση	Νευρώνες
Input/Dense	ReLU	784
Hidden 1	ReLU	256
Hidden 2	ReLU	128
Output	Softmax	10

Η συνάρτηση ReLU χρησιμοποιείται στα ενδιάμεσα επίπεδα, επειδή είναι απλή, υπολογιστικά αποδοτική και βοηθά στην εκπαίδευση βαθύτερων δικτύων περιορίζοντας το πρόβλημα των πολύ μικρών gradients. Στο output χρησιμοποιείται Softmax, ώστε το μοντέλο να δίνει πιθανότητες για τις 10 κλάσεις.

2.2 Optimizer και loss function

Ως optimizer χρησιμοποιήθηκε ο Adam. Ο Adam προσαρμόζει το learning rate ανά παράμετρο και συνήθως συγκλίνει γρήγορα σε προβλήματα ταξινόμησης εικόνων.

Ως συνάρτηση απώλειας χρησιμοποιήθηκε η sparse categorical crossentropy. Είναι κατάλληλη επειδή έχουμε πολυταξική ταξινόμηση 10 αμοιβαία αποκλειόμενων κλάσεων και τα labels δίνονται ως ακέραιοι αριθμοί 0 έως 9, όχι ως one-hot vectors.

Η εκπαίδευση έγινε για 30 epochs με validation split 10%. Άρα από τα 54000 training δείγματα, περίπου 48600 χρησιμοποιούνται για εκπαίδευση και 5400 για validation σε κάθε epoch.

2.3 Αποτελέσματα εκπαίδευσης



Σχήμα 3: Καμπύλες accuracy και loss για το απλό νευρωνικό δίκτυο.

Στο τέλος των 30 epochs προέκυψαν:

Μέγεθος	Τιμή
Train accuracy	0.9985
Validation accuracy	0.9746
Train loss	0.0046
Validation loss	0.1372
Test accuracy	0.9756
Test loss	0.1315
Παράμετροι	850586

2.4 Πίνακας σύγχυσης

simple_nn: confusion matrix

True digit \ Predicted digit	0	1	2	3	4	5	6	7	8	9
0	784	0	0	0	0	2	1	0	4	1
1	0	879	1	2	1	1	2	1	18	0
2	3	0	786	4	1	0	0	4	11	1
3	0	0	0	804	1	4	0	2	4	5
4	2	0	3	0	774	0	3	2	1	6
5	2	0	0	1	1	697	2	1	1	2
6	2	1	2	1	2	9	754	0	4	0
7	1	1	5	4	2	0	0	802	3	9
8	2	0	1	3	3	9	0	2	751	3
9	2	1	1	9	6	0	0	1	5	774

Σχήμα 4: Πίνακας σύγχυσης για το απλό νευρωνικό δίκτυο στο test set.

Τα συχνότερα λάθη του απλού NN ήταν:

Πραγματικό ψηφίο	Πρόβλεψη	Πλήθος
1	8	18
2	8	11
6	5	9
7	9	9
8	5	9
9	3	9

Τα λάθη αυτά σχετίζονται κυρίως με μορφολογικές ομοιότητες σε χειρόγραφες μορφές. Για παράδειγμα, το 7 μπορεί να μοιάζει με 9 όταν έχει έντονη καμπύλη, το 9 μπορεί να μοιάζει με 3 όταν η κάθετη ουρά είναι αχνή, ενώ το

8 μπορεί να υπερδευτεί με 5 σε εικόνες όπου ο κάτω λοβός είναι πιο έντονος από τον πάνω. Το απλό NN βλέπει την εικόνα ως απλό διάνυσμα 784 αριθμών και δεν αξιοποιεί ρητά τις τοπικές σχέσεις ανάμεσα σε γειτονικά pixels, άρα είναι πιο ευάλωτο σε τέτοιες μικρές μετατοπίσεις και παραμορφώσεις.

2.5 Overfitting

Παρατηρείται ένδειξη overfitting. Το train accuracy φτάνει πολύ κοντά στο 1, ενώ το validation accuracy σταθεροποιείται περίπου στο 0.975. Παράλληλα, το train loss γίνεται σχεδόν μηδενικό, ενώ το validation loss αυξάνεται στα τελευταία epochs. Αυτό σημαίνει ότι το μοντέλο μαθαίνει πολύ καλά τα training δεδομένα, αλλά η επιπλέον εκπαίδευση δεν βελτιώνει αντίστοιχα τη γενίκευση.

3 Ενότητα Β: Συνελικτικό Νευρωνικό Δίκτυο


3.1 Αρχιτεκτονική CNN

Το CNN δέχεται ως είσοδο τις εικόνες στη μορφή (28, 28, 1), ώστε να διατηρείται η χωρική δομή και το κανάλι grayscale.

Επίπεδο	Ρύθμιση	Παράμετροι
Conv2D	32 φίλτρα 3×3 , ReLU	320
MaxPooling2D	Παράθυρο 2×2	0
Conv2D	64 φίλτρα 3×3 , ReLU	18496
Flatten	–	0
Dense	64 νευρώνες, ReLU	495680
Output Dense	10 νευρώνες, Softmax	650
Σύνολο		515146

Το CNN εκπαιδεύτηκε επίσης με Adam, sparse categorical crossentropy, 30 epochs και validation split 10%.

3.2 Αποτελέσματα εκπαίδευσης



Σχήμα 5: Καμπύλες accuracy και loss για το CNN.

Στο τέλος των 30 epochs προέκυψαν:

Μέγεθος	Τιμή
Train accuracy	0.9998
Validation accuracy	0.9881
Train loss	0.0010
Validation loss	0.0654
Test accuracy	0.9899
Test loss	0.0469
Παράμετροι	515146

3.3 Πίνακας σύγχυσης

cnn: confusion matrix

0	788	0	0	0	0	1	1	0	1	1
1	0	902	0	1	0	0	1	0	1	0
2	1	1	806	0	0	0	0	1	1	0
3	0	0	2	814	0	3	0	0	1	0
4	0	0	2	0	777	0	0	0	1	11
5	1	0	0	2	0	702	1	0	0	1
6	2	1	2	0	1	4	762	0	3	0
7	0	3	5	0	0	0	0	814	1	4
8	4	0	4	0	0	0	0	0	764	2
9	1	1	0	1	2	3	0	1	0	790
	0	1	2	3	4	5	6	7	8	9

Predicted digit

Σχήμα 6: Πίνακας σύγχυσης για το CNN στο test set.

Τα συχνότερα λάθη του CNN ήταν:

Πραγματικό ψηφίο	Πρόβλεψη	Πλήθος
4	9	11
7	2	5
7	9	4
6	5	4
8	2	4
8	0	4

Το συχνότερο μπερδεμα είναι το $4 \rightarrow 9$. Αυτό είναι αναμενόμενο σε χειρόγραφα ψηφία, επειδή κάποια 4 γράφονται με κλειστό πάνω τμήμα και μπορούν να θυμίσουν 9. Επίσης, το 7 μπορεί να μπερδευτεί με 2 λόγω κοινής λοξής γραμμής και άνω οριζόντιας γραμμής, ενώ τα 8 και 0 έχουν κοινή κλειστή, κυκλική μορφή.

4 Σύγκριση μοντέλων

Πίνακας 2: Σύγκριση απλού NN και CNN.

Μοντέλο	Παράμετροι	Val. accuracy	Test accuracy	Test loss
Simple NN	850586	0.9746	0.9756	0.1315
CNN	515146	0.9881	0.9899	0.0469

Το CNN έχει καλύτερη απόδοση στο test set:

$$0.9899 - 0.9756 = 0.0143.$$

Δηλαδή η ακρίβεια αυξάνεται περίπου κατά 1.43 ποσοστιαίες μονάδες. Επιπλέον, το CNN έχει λιγότερες παραμέτρους από το απλό NN, παρότι πετυχαίνει καλύτερη ακρίβεια.

Η διαφορά εξηγείται από τον τρόπο με τον οποίο τα CNN επεξεργάζονται εικόνες. Τα συνελκτικά φίλτρα μαθαίνουν τοπικά μοτίβα, όπως ακμές, καμπύλες, γωνίες και μικρά τμήματα ψηφίων. Τα ίδια φίλτρα εφαρμόζονται σε διαφορετικές θέσεις της εικόνας, άρα το μοντέλο μπορεί να αναγνωρίζει ένα μοτίβο ανεξάρτητα από το αν εμφανίζεται λίγο πιο πάνω, κάτω, αριστερά ή δεξιά. Το MaxPooling μειώνει τη διάσταση και κάνει την αναπαράσταση πιο ανθεκτική σε μικρές μετατοπίσεις.

Αντίθετα, το απλό NN αντιμετωπίζει κάθε pixel ως ξεχωριστό χαρακτηριστικό. Έτσι μπορεί να μάθει χρήσιμα μοτίβα, αλλά δεν έχει ενσωματωμένη γνώση ότι γειτονικά pixels σχηματίζουν τοπικές δομές. Για αυτό τα CNN θεωρούνται γενικά καταλληλότερα για εικόνες.

4.1 Συμπέρασμα

Και τα δύο μοντέλα ταξινομούν με υψηλή ακρίβεια τα ψηφία του MNIST. Ωστόσο, το CNN είναι σαφώς πιο κατάλληλο για το συγκεκριμένο πρόβλημα, επειδή αξιοποιεί τη χωρική πληροφορία των εικόνων. Στο πείραμα της εργασίας πέτυχε υψηλότερη test accuracy, χαμηλότερο test loss και μικρότερο πλήθος παραμέτρων από το απλό πλήρως συνδεδεμένο νευρωνικό δίκτυο.