

ΑΡΙΣΤΟΤΕΛΕΙΟ ΠΑΝΕΠΙΣΤΗΜΙΟ ΘΕΣΣΑΛΟΝΙΚΗΣ
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ - ΤΜΗΜΑ ΜΗΧΑΝΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ
ΑΚΑΔΗΜΑΪΚΟ ΕΤΟΣ 2025-26

ΕΞΑΜΗΝΟ: 8ο

ΜΑΘΗΜΑ: ΑΝΑΛΥΣΗ ΔΕΔΟΜΕΝΩΝ

ΔΙΔΑΣΚΟΥΣΑ: ΣΟΦΙΑ ΠΑΝΑΓΙΩΤΙΔΟΥ, Αν. Καθηγήτρια

4^η ΕΡΓΑΣΙΑ

Όνοματεπώνυμο φοιτητή : _____

A.E.M. : _____

Θεσσαλονίκη, Απρίλιος 2026

4^η Εργασία στο μάθημα "Ανάλυση Δεδομένων" 2025-26

Για τη 4^η εργασία του μαθήματος, να χρησιμοποιηθούν τα δεδομένα της 3^{ης} εργασίας.

Στόχος είναι και πάλι η εκτίμηση του τύπου κρασιού (λευκό ή κόκκινο) χρησιμοποιώντας ως πιθανές προβλεπτικές μεταβλητές όλες τις υπόλοιπες μεταβλητές εκτός από τη μεταβλητή *quality*.

Τα δεδομένα να διαχωριστούν σε *training* (70%) και *test* (30%) με τυχαίο *random_state* το AEM σας.

Ζητούμενα εργασίας

Να γίνει πρόβλεψη/εκτίμηση του τύπου κρασιού με εφαρμογή των παρακάτω μεθόδων. Σε κάθε περίπτωση, να υπολογιστεί η ακρίβεια που επιτυγχάνεται (*test accuracy*) με την εκάστοτε μέθοδο. Επίσης, σε κάθε μοντέλο να χρησιμοποιηθεί *random_state* το AEM σας (επιπλέον του *random_state* που χρησιμοποιήθηκε για τον διαχωρισμό των δεδομένων σε *train* και *test*).

1. Με δέντρο ταξινόμησης μέγιστου βάθους 2 (*max depth*).
2. Με τη μέθοδο *Bagging* χρησιμοποιώντας εκτιμήσεις από 200 δειγματοληψίες (*n estimators*).
3. Με τη μέθοδο *Random Forest* χρησιμοποιώντας εκτιμήσεις από 200 δειγματοληψίες (*n estimators*) και τυχαίο πλήθος υποψήφιων χαρακτηριστικών (*features/predictors*) $m=p/2$, όπου *p* το σύνολο των χαρακτηριστικών του προβλήματος (εννοείται όσων λαμβάνονται υπόψη).
4. Με τη μέθοδο *Boosting* χρησιμοποιώντας εκτιμήσεις από 200 επιμέρους μοντέλα (*n estimators*), συντελεστή μάθησης 0.1 (*learning rate*) και μέγιστο βάθος 1 (*max depth*).
5. Να παρασταθεί γραφικά το *test error* ($=1-\text{test accuracy}$) της μεθόδου του ερωτήματος (1) συναρτήσει του βάθους του δέντρου (για όσες τιμές βάθους κρίνετε απαραίτητο και λογικό). Τι παρατηρείτε; Σχολιάστε.
6. Να παρασταθεί στο ίδιο γράφημα το *test error* ($=1-\text{test accuracy}$) των μεθόδων των ερωτημάτων (2), (3) και (4) συναρτήσει της μεταβλητής «*n estimators*». Η γραφική παράσταση να περιλαμβάνει τιμές της μεταβλητής «*n estimators*» στο εύρος 10-200 με βήμα 10, καθώς και την τιμή *n estimators* = 1. Τι παρατηρείτε σε κάθε περίπτωση; Σχολιάστε.
7. Για καθεμία από τις παραπάνω μεθόδους:
 - Να πραγματοποιηθεί διαδικασία βελτιστοποίησης υπερπαραμέτρων (*hyperparameter tuning*) με χρήση κατάλληλης μεθόδου (π.χ. *Grid Search* με *k-fold cross-validation*).
 - Να προσδιοριστούν οι βέλτιστες τιμές των υπερπαραμέτρων για κάθε μοντέλο.
 - Να υπολογιστεί η ακρίβεια (*test accuracy*) των βελτιστοποιημένων (*tuned*) μοντέλων.

Στη συνέχεια:

- Να συγκριθούν τα αποτελέσματα των αρχικών (*untuned*) και των βελτιστοποιημένων (*tuned*) μοντέλων.
- Να παρουσιαστούν τα αποτελέσματα σε έναν συνοπτικό πίνακα.
- Να σχολιαστεί η επίδραση της διαδικασίας *tuning* στην απόδοση κάθε μοντέλου.

Ποια από τις μεθόδους ταξινόμησης παρουσιάζει την καλύτερη ακρίβεια; Να αιτιολογήσετε την απάντησή σας, λαμβάνοντας υπόψη τόσο τα αρχικά όσο και τα βελτιστοποιημένα μοντέλα.