

Ανάλυση Δεδομένων 2025-26

4η Εργασία – Explanatory Report

Ερώτημα 2: Bagging με 200 εκτιμητές

Ρακοβαλής Πάυλος
ΑΕΜ: 6931

30 Απριλίου 2026

Περίληψη

Το παρόν κείμενο είναι ένα αναλυτικό, επεξηγηματικό report για το δεύτερο ερώτημα της 4ης εργασίας. Στόχος είναι να εξηγηθεί η μέθοδος Bagging με τρόπο κατανοητό ακόμη και σε κάποιον που δεν έχει προηγούμενη εμπειρία στην Ανάλυση Δεδομένων. Πρώτα παρουσιάζεται τι ζητάει το ερώτημα, στη συνέχεια εξηγείται το θεωρητικό υπόβαθρο της μεθόδου και τέλος περιγράφεται βήμα προς βήμα η υλοποίηση με 200 εκτιμητές. Το μοντέλο Bagging πέτυχε test accuracy 0.9660, δηλαδή ταξινόμησε σωστά περίπου το 96.60% των test παρατηρήσεων.

Περιεχόμενα

1 Το ερώτημα της εργασίας	2
1.1 Τι ακριβώς πρέπει να παραδώσουμε	2
2 Υπενθύμιση του προβλήματος	2
2.1 Το ίδιο train/test split με το Ερώτημα 1	3
3 Θεωρητικό υπόβαθρο: γιατί δεν αρκεί πάντα ένα δέντρο	3
3.1 Τι σημαίνει ότι ένα δέντρο είναι ασταθές	3
3.2 Η βασική ιδέα των ensemble μεθόδων	4
4 Θεωρητικό υπόβαθρο: τι είναι το Bagging	4
4.1 Τι είναι bootstrap δείγμα	4
4.2 Τι σημαίνει n estimators	5
4.3 Πώς αποφασίζει τελικά το Bagging	5
4.4 Γιατί το Bagging συνήθως βοηθάει	5
5 Πώς λύσαμε το ερώτημα βήμα-βήμα	6
5.1 Βήμα 1: Φορτώσαμε τα δεδομένα	6
5.2 Βήμα 2: Ορίσαμε predictors και target	6
5.3 Βήμα 3: Χωρίσαμε τα δεδομένα σε training και test	6

5.4	Βήμα 4: Δημιουργήσαμε το Bagging μοντέλο	7
5.5	Βήμα 5: Εκπαιδεύσαμε το μοντέλο	7
5.6	Βήμα 6: Κάναμε προβλέψεις στο test set	7
5.7	Βήμα 7: Υπολογίσαμε accuracy και test error	7
6	Αποτελέσματα του Bagging	8
6.1	Confusion matrix	8
6.2	Πώς διαβάζουμε τα αποτελέσματα	9
7	Σύγκριση με το απλό δέντρο του Ερωτήματος 1	10
7.1	Γιατί βελτιώθηκε η απόδοση	10
8	Ποια χαρακτηριστικά χρησιμοποίησε περισσότερο το Bagging	11
9	Τελικός σχολιασμός για το Ερώτημα 2	12
9.1	Σύντομη απάντηση που μπορεί να μπει στην εργασία	12
A'	Αρχεία που δημιουργήθηκαν για το report	12

1 Το ερώτημα της εργασίας

Το δεύτερο ερώτημα της 4ης εργασίας είναι:

«Να γίνει πρόβλεψη/εκτίμηση του τύπου κρασιού με τη μέθοδο Bagging, χρησιμοποιώντας εκτιμήσεις από 200 δειγματοληψίες ($n_estimators=200$).»

Με απλά λόγια, η εργασία ζητάει να προβλέψουμε αν ένα κρασί είναι λευκό ή κόκκινο, όπως και στο πρώτο ερώτημα. Η διαφορά είναι ότι τώρα δεν θα χρησιμοποιήσουμε μόνο ένα δέντρο ταξινόμησης. Θα χρησιμοποιήσουμε πολλά δέντρα μαζί.

Η μέθοδος Bagging λειτουργεί ως εξής:

- δημιουργεί πολλά διαφορετικά δείγματα από το training set,
- εκπαιδεύει ένα δέντρο ταξινόμησης σε κάθε δείγμα,
- παίρνει την πρόβλεψη κάθε δέντρου,
- και στο τέλος αποφασίζει με ψηφοφορία.

Στο συγκεκριμένο ερώτημα ο αριθμός των δέντρων είναι:

$n_estimators = 200$

Δηλαδή το μοντέλο δεν στηρίζεται σε μία μόνο γνώμη, αλλά σε 200 διαφορετικά δέντρα ταξινόμησης.

1.1 Τι ακριβώς πρέπει να παραδώσουμε

Για να λυθεί πλήρως το δεύτερο ερώτημα, πρέπει να γίνουν τα εξής:

1. Να χρησιμοποιηθούν τα ίδια δεδομένα της 3ης εργασίας.
2. Να χρησιμοποιηθεί ως στόχος η μεταβλητή `wine_type`.
3. Να εξαιρεθεί η μεταβλητή `quality`, όπως ζητάει η εκφώνηση.
4. Να γίνει ο ίδιος διαχωρισμός σε training set 70% και test set 30%.
5. Να εφαρμοστεί η μέθοδος Bagging με $n_estimators=200$.
6. Να γίνουν προβλέψεις στο test set.
7. Να υπολογιστεί η test accuracy.
8. Να παρουσιαστεί και να ερμηνευτεί ο confusion matrix.

2 Υπευθύμιση του προβλήματος

Το πρόβλημα είναι πρόβλημα ταξινόμησης. Θέλουμε να πάρουμε τις φυσικοχημικές μετρήσεις ενός κρασιού και να αποφασίσουμε αν είναι:

red ή white.

Η μεταβλητή στόχος είναι:

wine_type.

Η κωδικοποίηση που χρησιμοποιήθηκε είναι:

red = 0 και white = 1.

Οι προβλεπτικές μεταβλητές είναι όλες οι υπόλοιπες φυσικοχημικές μεταβλητές, εκτός από τη quality. Συνολικά χρησιμοποιούνται 11 predictors.

fixed acidity	volatile acidity	citric acid
residual sugar	chlorides	free sulfur dioxide
total sulfur dioxide	density	pH
sulphates	alcohol	

2.1 Το ίδιο train/test split με το Ερώτημα 1

Για να είναι δίκαιη η σύγκριση με το προηγούμενο ερώτημα, χρησιμοποιήθηκε το ίδιο train/test split:

Σύνολο	Πλήθος	Ποσοστό
Training set	3706	70%
Test set	1589	30%

Επίσης χρησιμοποιήθηκε:

random_state = 6931

και stratify=y, ώστε να διατηρηθεί παρόμοια αναλογία κόκκινων και λευκών κρασιών στο training και στο test set.

3 Θεωρητικό υπόβαθρο: γιατί δεν αρκεί πάντα ένα δέντρο

Στο πρώτο ερώτημα χρησιμοποιήσαμε ένα δέντρο ταξινόμησης μέγιστου βάθους 2. Το δέντρο αυτό είχε το πλεονέκτημα ότι ήταν απλό και εύκολα ερμηνεύσιμο. Όμως ένα μόνο δέντρο έχει και ένα βασικό μειονέκτημα: μπορεί να είναι ασταθές.

3.1 Τι σημαίνει ότι ένα δέντρο είναι ασταθές

Ένα δέντρο ταξινόμησης φτιάχνεται κάνοντας διαδοχικούς διαχωρισμούς στα δεδομένα. Αν αλλάξουν λίγο τα training δεδομένα, μπορεί να αλλάξουν και οι διαχωρισμοί που επιλέγει το δέντρο. Άρα μπορεί να καταλήξουμε σε διαφορετικό δέντρο.

Με απλά λόγια:

Ένα δέντρο μπορεί να επηρεάζεται αρκετά από τις λεπτομέρειες του συγκεκριμένου training set.

Αυτό δεν σημαίνει ότι τα δέντρα είναι κακή μέθοδος. Σημαίνει όμως ότι ένα μόνο δέντρο μπορεί να έχει σχετικά μεγάλη διακύμανση. Δηλαδή, αν εκπαιδευτεί σε λίγο διαφορετικά δεδομένα, μπορεί να δώσει λίγο διαφορετικό μοντέλο.

3.2 Η βασική ιδέα των ensemble μεθόδων

Οι ensemble μέθοδοι προσπαθούν να βελτιώσουν την πρόβλεψη συνδυάζοντας πολλά μοντέλα.

Η ιδέα είναι απλή:

Αν ένα μοντέλο μπορεί να κάνει λάθος, πολλά μοντέλα μαζί μπορεί να δώσουν πιο σταθερή και πιο αξιόπιστη απόφαση.

Αυτό μοιάζει με την ιδέα της ψηφοφορίας. Αν ρωτήσουμε μόνο ένα άτομο, μπορεί να κάνει λάθος. Αν όμως ρωτήσουμε 200 άτομα και πάρουμε την πλειοψηφική απάντηση, η τελική απόφαση μπορεί να είναι πιο σταθερή.

Το Bagging είναι μία από τις πιο βασικές ensemble μεθόδους.

4 Θεωρητικό υπόβαθρο: τι είναι το Bagging

Η λέξη Bagging προέρχεται από τη φράση:

Bootstrap Aggregating.

Η φράση αυτή έχει δύο κομμάτια:

- **Bootstrap:** δημιουργούμε πολλά νέα δείγματα από το αρχικό training set.
- **Aggregating:** συνδυάζουμε τις προβλέψεις πολλών μοντέλων.

4.1 Τι είναι bootstrap δείγμα

Ένα bootstrap δείγμα είναι ένα δείγμα που φτιάχνεται από το training set με δειγματοληψία **με επανάθεση**.

Η φράση «με επανάθεση» σημαίνει ότι κάθε φορά που επιλέγουμε μία παρατήρηση, την ξαναβάζουμε πίσω στο σύνολο, άρα μπορεί να επιλεγεί ξανά.

Παράδειγμα:

Αν έχουμε τις παρατηρήσεις A, B, C, D, ένα bootstrap δείγμα μεγέθους 4 θα μπορούσε να είναι A, C, C, D. Η παρατήρηση C εμφανίζεται δύο φορές, ενώ η B δεν εμφανίζεται καθόλου.

Στο Bagging δημιουργούνται πολλά τέτοια bootstrap δείγματα. Σε κάθε δείγμα εκπαιδεύεται ένα μοντέλο.

4.2 Τι σημαίνει `n_estimators`

Η παράμετρος `n_estimators` δηλώνει πόσα επιμέρους μοντέλα θα εκπαιδευτούν.

Στο ερώτημα αυτό:

$$n_estimators = 200$$

Άρα το Bagging δημιουργεί 200 bootstrap δείγματα και εκπαιδεύει 200 δέντρα ταξινόμησης. Κάθε δέντρο δίνει τη δική του πρόβλεψη και στο τέλος οι προβλέψεις συνδυάζονται.

4.3 Πώς αποφασίζει τελικά το Bagging

Επειδή έχουμε πρόβλημα ταξινόμησης, το Bagging χρησιμοποιεί πλειοψηφική ψηφοφορία.


Για παράδειγμα, έστω ότι για ένα συγκεκριμένο κρασί:

- 170 δέντρα προβλέπουν `white`,
- 30 δέντρα προβλέπουν `red`.

Τότε η τελική πρόβλεψη του Bagging είναι:

`white`.

Δηλαδή το μοντέλο επιλέγει την κλάση που πήρε τις περισσότερες ψήφους.



Bagging: many trees are trained on different bootstrap samples, then their votes are combined.

Σχήμα 1: Η βασική ιδέα του Bagging: πολλά bootstrap δείγματα, πολλά δέντρα, μία τελική ψηφοφορία.

4.4 Γιατί το Bagging συνήθως βοηθάει

Το Bagging βοηθά κυρίως επειδή μειώνει τη διακύμανση του μοντέλου. Ένα δέντρο μπορεί να είναι ασταθές, αλλά ο μέσος όρος ή η ψηφοφορία πολλών δέντρων είναι συνήθως πιο σταθερή.

Στα δέντρα ταξινόμησης αυτό είναι ιδιαίτερα χρήσιμο, επειδή τα δέντρα μπορούν να αλλάξουν αρκετά αν αλλάξει λίγο το training set. Με το Bagging, δεν εμπιστευόμαστε μόνο ένα δέντρο, αλλά συνδυάζουμε πολλά.

5 Πώς λύσαμε το ερώτημα βήμα-βήμα

5.1 Βήμα 1: Φορτώσαμε τα δεδομένα

Όπως και στο πρώτο ερώτημα, ξεκινήσαμε διαβάζοντας το αρχείο CSV:

```
df = pd.read_csv("../../Third_Assignment/Data_Analysis_2026_3rd_Case_Data.csv")
```

Ο πίνακας df περιέχει όλες τις παρατηρήσεις και όλες τις μεταβλητές.

5.2 Βήμα 2: Ορίσαμε predictors και target

Κρατήσαμε ως predictors όλες τις μεταβλητές εκτός από τη quality και τη wine_type:

```
features = [col for col in df.columns if col not in ("quality", "wine_type")]
X = df[features]
```

Έπειτα ορίσαμε τη μεταβλητή στόχο:

```
y = (df["wine_type"] == "white").astype(int)
```

Άρα:

- red αντιστοιχεί σε 0,
- white αντιστοιχεί σε 1.

5.3 Βήμα 3: Χωρίσαμε τα δεδομένα σε training και test

Ο διαχωρισμός έγινε με:

```
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.30,
    random_state=6931,
    stratify=y,
)
```

Αυτό σημαίνει ότι το μοντέλο εκπαιδεύτηκε σε 3706 παρατηρήσεις και αξιολογήθηκε σε 1589 παρατηρήσεις που δεν είχε δει κατά την εκπαίδευση.

5.4 Βήμα 4: Δημιουργήσαμε το Bagging μοντέλο

Το μοντέλο δημιουργήθηκε ως εξής:

```
model = BaggingClassifier(  
    estimator=DecisionTreeClassifier(random_state=6931),  
    n_estimators=200,  
    random_state=6931,  
    n_jobs=-1,  
)
```

Ας εξηγήσουμε κάθε κομμάτι:

- `BaggingClassifier`: δηλώνει ότι θα χρησιμοποιήσουμε τη μέθοδο Bagging για ταξινόμηση.
- `estimator=DecisionTreeClassifier(...)`: δηλώνει ότι το κάθε επιμέρους μοντέλο θα είναι δέντρο ταξινόμησης.
- `n_estimators=200`: δηλώνει ότι θα εκπαιδευτούν 200 δέντρα.
- `random_state=6931`: κάνει τη διαδικασία αναπαραγώγιμη.
- `n_jobs=-1`: επιτρέπει στον υπολογιστή να χρησιμοποιήσει όλους τους διαθέσιμους πυρήνες για πιο γρήγορη εκπαίδευση.

5.5 Βήμα 5: Εκπαιδεύσαμε το μοντέλο

Η εκπαίδευση έγινε με:

```
model.fit(X_train, y_train)
```

Στο σημείο αυτό το Bagging φτιάχνει 200 bootstrap δείγματα και εκπαιδεύει ένα δέντρο σε κάθε δείγμα.

5.6 Βήμα 6: Κάνουμε προβλέψεις στο test set

Μετά την εκπαίδευση, ζητήσαμε από το μοντέλο να προβλέψει τον τύπο κρασιού για τις παρατηρήσεις του test set:

```
y_pred = model.predict(X_test)
```

Η μεταβλητή `y_pred` περιέχει τις προβλέψεις του Bagging.

5.7 Βήμα 7: Υπολογίσαμε accuracy και test error

Η ακρίβεια και το σφάλμα υπολογίστηκαν με:

```
accuracy = accuracy_score(y_test, y_pred)  
test_error = 1 - accuracy
```

Το `accuracy` είναι το ποσοστό σωστών προβλέψεων. Το `test_error` είναι το ποσοστό λανθασμένων προβλέψεων.

6 Αποτελέσματα του Bagging

Τα αποτελέσματα του Bagging με 200 εκτιμητές ήταν:

Πίνακας 1: Βασικά αποτελέσματα Bagging.

Μέγεθος / μέτρο	Τιμή
Μοντέλο	Bagging
Πλήθος εκτιμητών	200
Random state	6931
Πλήθος predictors	11
Πλήθος test παρατηρήσεων	1589
Test accuracy	0.9660
Test error	0.0340

Η τιμή:

Test accuracy = 0.9660

σημαίνει ότι το μοντέλο ταξινομήσε σωστά περίπου το 96.60% των test παρατηρήσεων.

Αντίστοιχα:

Test error = 0.0340


σημαίνει ότι έκανε λάθος περίπου στο 3.40% των test παρατηρήσεων.

6.1 Confusion matrix

Ο confusion matrix του Bagging ήταν:

Πίνακας 2: Confusion matrix για το Bagging.

	Πρόβλεψη: red	Πρόβλεψη: white
Πραγματικό: red	365	26
Πραγματικό: white	28	1170



Σχήμα 2: Γραφική απεικόνιση του confusion matrix για το Bagging.

6.2 Πώς διαβάζουμε τα αποτελέσματα

Ο confusion matrix μάς λέει τα εξής:

- 365 κόκκινα κρασιά ταξινομήθηκαν σωστά ως κόκκινα.
- 26 κόκκινα κρασιά ταξινομήθηκαν λάθος ως λευκά.
- 28 λευκά κρασιά ταξινομήθηκαν λάθος ως κόκκινα.
- 1170 λευκά κρασιά ταξινομήθηκαν σωστά ως λευκά.

Άρα οι σωστές προβλέψεις είναι:

$$365 + 1170 = 1535.$$

Οι συνολικές test παρατηρήσεις είναι:

$$365 + 26 + 28 + 1170 = 1589.$$

Επομένως:

$$\text{Accuracy} = \frac{1535}{1589} = 0.9660.$$

Τα συνολικά λάθη είναι:

$$26 + 28 = 54.$$

Άρα:

$$\text{Test Error} = \frac{54}{1589} = 0.0340.$$

7 Σύγκριση με το απλό δέντρο του Ερωτήματος 1

Είναι χρήσιμο να συγκρίνουμε το Bagging με το απλό δέντρο ταξινόμησης του πρώτου ερωτήματος. Στο πρώτο ερώτημα είχαμε μόνο ένα δέντρο με `max_depth=2`. Στο δεύτερο ερώτημα έχουμε 200 δέντρα, τα οποία συνδυάζονται με ψηφοφορία.

Πίνακας 3: Σύγκριση απλού δέντρου και Bagging.

Μοντέλο	Test Accuracy	Test Error
Decision Tree (<code>max_depth=2</code>)	0.9339	0.0661
Bagging (200 estimators)	0.9660	0.0340

Η ακρίβεια αυξήθηκε από 0.9339 σε 0.9660. Η βελτίωση είναι:

$$0.9660 - 0.9339 = 0.0321.$$

Δηλαδή το Bagging αύξησε την ακρίβεια κατά περίπου 3.21 ποσοστιαίες μονάδες.

Αντίστοιχα, τα λάθη μειώθηκαν:

Μοντέλο	Λάθη στο test set	Σωστές προβλέψεις
Decision Tree	105	1484
Bagging	54	1535

Άρα το Bagging έκανε:

$$105 - 54 = 51$$

λιγότερα λάθη από το απλό δέντρο του πρώτου ερωτήματος.


7.1 Γιατί βελτιώθηκε η απόδοση

Η βελτίωση είναι αναμενόμενη. Το απλό δέντρο του πρώτου ερωτήματος ήταν πολύ περιορισμένο, επειδή είχε μέγιστο βάθος 2. Αντίθετα, το Bagging χρησιμοποιεί πολλά δέντρα και συνδυάζει τις αποφάσεις τους.

Αν κάποιο δέντρο κάνει λάθος σε μία παρατήρηση, αυτό δεν σημαίνει απαραίτητα ότι θα κάνει λάθος και το συνολικό Bagging μοντέλο. Η τελική απόφαση λαμβάνεται από την πλειοψηφία των δέντρων. Έτσι, τα μεμονωμένα λάθη μπορούν να αντισταθμιστούν.

8 Ποια χαρακτηριστικά χρησιμοποίησε περισσότερο το Bagging

Αν και το Bagging αποτελείται από πολλά δέντρα και είναι λιγότερο απλό από ένα μόνο δέντρο, μπορούμε να πάρουμε μία ένδειξη για το ποιες μεταβλητές ήταν πιο σημαντικές. Αυτό έγινε υπολογίζοντας τη μέση σημαντικότητα κάθε μεταβλητής στα 200 δέντρα.



Σχήμα 3: Οι σημαντικότερες μεταβλητές στο Bagging μοντέλο.

Πίνακας 4: Μέση σημαντικότητα χαρακτηριστικών στο Bagging.

Μεταβλητή	Σημαντικότητα
total sulfur dioxide	0.5416
chlorides	0.2609
sulphates	0.0347
fixed acidity	0.0312
density	0.0303
pH	0.0228
volatile acidity	0.0211
residual sugar	0.0187
citric acid	0.0139
alcohol	0.0135
free sulfur dioxide	0.0112

Παρατηρούμε ότι οι δύο πιο σημαντικές μεταβλητές είναι:

- total sulfur dioxide
- chlorides

Αυτό είναι ενδιαφέρον, γιατί και στο απλό δέντρο του πρώτου ερωτήματος αυτές οι μεταβλητές ήταν οι βασικές μεταβλητές που χρησιμοποιήθηκαν στους κανόνες απόφασης. Άρα υπάρχει συνέπεια ανάμεσα στο απλό δέντρο και στο Bagging: και τα δύο μοντέλα θεωρούν πολύ χρήσιμες τις μεταβλητές που σχετίζονται με τα θειώδη και τα χλωριούχα άλατα.

9 Τελικός σχολιασμός για το Ερώτημα 2

Η μέθοδος Bagging με 200 εκτιμητές πέτυχε πολύ υψηλή απόδοση στην πρόβλεψη του τύπου κρασιού. Η test accuracy ήταν 0.9660, δηλαδή το μοντέλο ταξινομήσε σωστά περίπου το 96.60% των test παρατηρήσεων.

Σε σχέση με το απλό δέντρο του πρώτου ερωτήματος, το Bagging είχε σαφώς καλύτερη απόδοση. Το απλό δέντρο έκανε 105 λάθη στο test set, ενώ το Bagging έκανε 54 λάθη. Επομένως, το Bagging μείωσε τα λάθη κατά 51 παρατηρήσεις.

Η βελτίωση αυτή οφείλεται στη βασική ιδέα του Bagging: αντί να βασιστούμε σε ένα μόνο δέντρο, εκπαιδεύουμε πολλά δέντρα σε διαφορετικά bootstrap δείγματα και συνδυάζουμε τις προβλέψεις τους. Με αυτόν τον τρόπο μειώνεται η αστάθεια ενός μεμονωμένου δέντρου και προκύπτει ένα πιο αξιόπιστο μοντέλο.

9.1 Σύνοψη απάντηση που μπορεί να μπει στην εργασία

Για το δεύτερο ερώτημα εφαρμόστηκε η μέθοδος Bagging με `n_estimators=200`. Ως βασικός εκτιμητής χρησιμοποιήθηκε δέντρο ταξινόμησης, ενώ οι προβλεπτικές μεταβλητές ήταν όλες οι διαθέσιμες μεταβλητές εκτός από τη `quality`. Ο διαχωρισμός των δεδομένων έγινε σε training set 70% και test set 30% με `random_state=6931`. Το μοντέλο πέτυχε test accuracy 0.9660 και test error 0.0340. Ο confusion matrix έδειξε ότι ταξινομήθηκαν σωστά 365 κόκκινα και 1170 λευκά κρασιά, ενώ έγιναν συνολικά 54 λάθη. Σε σύγκριση με το απλό δέντρο ταξινόμησης του πρώτου ερωτήματος, το Bagging παρουσίασε σημαντική βελτίωση, καθώς μείωσε τα λάθη από 105 σε 54.

A' Αρχεία που δημιουργήθηκαν για το report

Για το επεξηγηματικό report του Ερωτήματος 2 δημιουργήθηκαν τα παρακάτω αρχεία:

- `q2_explanatory_bagging.py`: script που αναπαράγει τη λύση.
- `q2_explanatory_results.csv`: συγκεντρωτικός πίνακας αποτελεσμάτων.
- `q2_vs_q1_comparison.csv`: σύγκριση Bagging με το δέντρο του Ερωτήματος 1.

- `q2_confusion_matrix.png`: εικόνα του confusion matrix.
- `q2_bagging_concept.png`: απλό σχήμα που εξηγεί τη μέθοδο Bagging.
- `q2_bagging_feature_importance.csv`: μέση σημαντικότητα χαρακτηριστικών.
- `q2_bagging_feature_importance.png`: γράφημα σημαντικότητας χαρακτηριστικών.
- `explanatory_report_q2_bagging.tex`: το παρόν LaTeX αρχείο.