

Ανάλυση Δεδομένων 2025-26

4η Εργασία – Explanatory Report

Ερώτημα 3: Random Forest με 200 εκτιμητές και $m = p/2$

Ρακοβαλής Πάυλος
ΑΕΜ: 6931

30 Απριλίου 2026

Περίληψη

Το παρόν κείμενο εξηγεί αναλυτικά το τρίτο ερώτημα της 4ης εργασίας, στο οποίο εφαρμόζεται η μέθοδος Random Forest για την πρόβλεψη του τύπου κρασιού. Το report είναι γραμμένο με εκπαιδευτικό ύφος, σαν να απευθύνεται σε αναγνώστη που τώρα μαθαίνει Ανάλυση Δεδομένων. Πρώτα εξηγείται τι ζητάει το ερώτημα, έπειτα παρουσιάζεται η θεωρία πίσω από το Random Forest και τέλος περιγράφεται βήμα προς βήμα η υλοποίηση. Το Random Forest με 200 δέντρα και `max_features=5` πέτυχε test accuracy 0.9666.

Περιεχόμενα

1 Το ερώτημα της εργασίας	2
1.1 Τι πρέπει να κάνουμε πρακτικά	2
2 Υπενθύμιση του προβλήματος	2
3 Θεωρητικό υπόβαθρο: από Bagging σε Random Forest	3
3.1 Η βασική ιδέα του Random Forest	3
3.2 Γιατί θέλουμε τα δέντρα να είναι διαφορετικά	4
3.3 Διαφορά Bagging και Random Forest	4
4 Τι σημαίνει $m = p/2$	5
4.1 Γιατί δεν εξετάζουμε όλες τις μεταβλητές	6
5 Πώς λύσαμε το ερώτημα βήμα-βήμα	6
5.1 Βήμα 1: Φορτώσαμε τα δεδομένα	6
5.2 Βήμα 2: Ορίσαμε τις προβλεπτικές μεταβλητές	6
5.3 Βήμα 3: Ορίσαμε τη μεταβλητή στόχο	6
5.4 Βήμα 4: Χωρίσαμε τα δεδομένα σε training και test	7
5.5 Βήμα 5: Δημιουργήσαμε το Random Forest μοντέλο	7
5.6 Βήμα 6: Εκπαιδεύσαμε το μοντέλο	7

5.7	Βήμα 7: Κάναμε προβλέψεις στο test set	8
5.8	Βήμα 8: Υπολογίσαμε accuracy και test error	8
6	Αποτελέσματα του Random Forest	8
6.1	Confusion matrix	9
6.2	Πώς διαβάζουμε τον confusion matrix	9
7	Σύγκριση με τα προηγούμενα ερωτήματα	10
7.1	Σύγκριση λαθών	11
8	Σημαντικότητα χαρακτηριστικών	11
9	Τελικός σχολιασμός για το Ερώτημα 3	12
9.1	Σύντομη απάντηση που μπορεί να μπει στην εργασία	13
A'	Αρχεία που δημιουργήθηκαν για το report	13

1 Το ερώτημα της εργασίας

Το τρίτο ερώτημα της 4ης εργασίας είναι:

«Να γίνει πρόβλεψη/εκτίμηση του τύπου κρασιού με τη μέθοδο Random Forest, χρησιμοποιώντας εκτιμήσεις από 200 δειγματοληψίες ($n_estimators=200$) και τυχαίο πλήθος υποψήφιων χαρακτηριστικών $m = p/2$, όπου p είναι το σύνολο των χαρακτηριστικών του προβλήματος.»

Με απλά λόγια, η εργασία ζητά να προβλέψουμε ξανά αν ένα κρασί είναι λευκό ή κόκκινο, αλλά αυτή τη φορά με τη μέθοδο **Random Forest**.

Το Random Forest μοιάζει πολύ με το Bagging του προηγούμενου ερωτήματος, επειδή και αυτό χρησιμοποιεί πολλά δέντρα ταξινόμησης. Όμως έχει μία επιπλέον ιδέα: όταν κάθε δέντρο κάνει έναν διαχωρισμό, δεν εξετάζει όλες τις διαθέσιμες μεταβλητές. Εξετάζει μόνο ένα τυχαίο υποσύνολο μεταβλητών.

Στο συγκεκριμένο ερώτημα ζητείται:

$$n_estimators = 200$$

δηλαδή 200 δέντρα, και:

$$m = \frac{p}{2},$$

όπου p είναι το πλήθος των predictors.

1.1 Τι πρέπει να κάνουμε πρακτικά

Για να λύσουμε το ερώτημα, πρέπει να κάνουμε τα εξής:

1. Να χρησιμοποιήσουμε τα δεδομένα της 3ης εργασίας.
2. Να προβλέψουμε τη μεταβλητή `wine_type`.
3. Να μη χρησιμοποιήσουμε τη μεταβλητή `quality`.
4. Να κρατήσουμε το ίδιο training/test split: 70% και 30%.
5. Να εφαρμόσουμε Random Forest με 200 δέντρα.
6. Να ορίσουμε το πλήθος υποψήφιων χαρακτηριστικών ανά split ίσο με $m = p/2$.
7. Να υπολογίσουμε την test accuracy.
8. Να παρουσιάσουμε και να εξηγήσουμε τον confusion matrix.

2 Υπευθύμιση του προβλήματος

Το πρόβλημα παραμένει το ίδιο με τα δύο προηγούμενα ερωτήματα. Έχουμε παρατηρήσεις κρασιών και θέλουμε να προβλέψουμε τον τύπο του κρασιού:

red ή white.

Η μεταβλητή στόχος είναι:

wine_type.

Η κωδικοποίηση είναι:

red = 0 και white = 1.

Οι προβλεπτικές μεταβλητές είναι όλες οι φυσικοχημικές μεταβλητές εκτός από τη quality. Συνολικά χρησιμοποιούνται:

$$p = 11$$

προβλεπτικές μεταβλητές.

fixed acidity	volatile acidity	citric acid
residual sugar	chlorides	free sulfur dioxide
total sulfur dioxide	density	pH
sulphates	alcohol	

To training/test split ήταν:

Σύνολο	Πλήθος	Ποσοστό
Training set	3706	70%
Test set	1589	30%

Χρησιμοποιήθηκε και πάλι:

random_state = 6931

ώστε τα αποτελέσματα να είναι αναπαραγώγιμα και συγκρίσιμα με τα προηγούμενα ερωτήματα.

3 Θεωρητικό υπόβαθρο: από Bagging σε Random Forest

Στο Ερώτημα 2 είδαμε τη μέθοδο Bagging. Το Bagging εκπαιδεύει πολλά δέντρα σε διαφορετικά bootstrap δείγματα και στο τέλος συνδυάζει τις προβλέψεις τους με πλειοψηφική ψηφοφορία.

Το Random Forest κρατά αυτή τη βασική ιδέα, αλλά προσθέτει ένα ακόμη επίπεδο τυχαιότητας.

3.1 Η βασική ιδέα του Random Forest

Το Random Forest είναι ένα «δάσος» από πολλά δέντρα ταξινόμησης. Κάθε δέντρο εκπαιδεύεται σε ένα διαφορετικό bootstrap δείγμα, όπως στο Bagging.

Η επιπλέον διαφορά είναι η εξής:

Σε κάθε split κάθε δέντρου, το μοντέλο δεν εξετάζει όλες τις μεταβλητές. Εξετάζει μόνο ένα τυχαίο υποσύνολο μεταβλητών.

Αυτό σημαίνει ότι τα δέντρα γίνονται πιο διαφορετικά μεταξύ τους. Και αυτό είναι πολύ χρήσιμο σε ένα ensemble μοντέλο.

3.2 Γιατί θέλουμε τα δέντρα να είναι διαφορετικά

Αν όλα τα δέντρα ενός ensemble είναι σχεδόν ίδια, τότε θα κάνουν περίπου τα ίδια λάθη. Σε αυτή την περίπτωση, η ψηφοφορία πολλών δέντρων δεν βοηθά τόσο πολύ, γιατί όλα τα δέντρα συμφωνούν για τους ίδιους λόγους.

Αν όμως τα δέντρα είναι διαφορετικά μεταξύ τους, τότε το ένα μπορεί να διορθώνει τα λάθη του άλλου. Έτσι, η τελική απόφαση της πλειοψηφίας γίνεται πιο σταθερή.

Το Random Forest προσπαθεί να δημιουργήσει αυτή τη διαφορετικότητα με δύο τρόπους:


1. Κάθε δέντρο εκπαιδεύεται σε διαφορετικό bootstrap δείγμα.
2. Σε κάθε split εξετάζεται τυχαίο υποσύνολο χαρακτηριστικών.

3.3 Διαφορά Bagging και Random Forest

Η βασική διαφορά είναι:

Bagging	Random Forest
Πολλά δέντρα σε bootstrap δείγματα.	Πολλά δέντρα σε bootstrap δείγματα.
Σε κάθε split κάθε δέντρο μπορεί να εξετάσει όλες τις μεταβλητές.	Σε κάθε split κάθε δέντρο εξετάζει μόνο τυχαίο υποσύνολο μεταβλητών.
Τα δέντρα μπορεί να μοιάζουν αρκετά μεταξύ τους, ειδικά αν υπάρχουν πολύ ισχυροί predictors.	Τα δέντρα αναγκάζονται να είναι πιο διαφορετικά μεταξύ τους.

Άρα το Random Forest είναι σαν Bagging, αλλά με επιπλέον τυχαιότητα στην επιλογή των μεταβλητών.



Random Forest = Bagging of trees + random subset of candidate features at each split ($m = p/2$).

Σχήμα 1: Η βασική ιδέα του Random Forest: bootstrap δείγματα, τυχαία χαρακτηριστικά ανά split και τελική ψηφοφορία.

4 Τι σημαίνει $m = p/2$

Η εκφώνηση ζητά το τυχαίο πλήθος υποψήφιων χαρακτηριστικών να είναι:

$$m = \frac{p}{2}.$$

Εδώ:

- p είναι το συνολικό πλήθος προβλεπτικών μεταβλητών.
- m είναι πόσες από αυτές θα εξετάζονται ως υποψήφιες σε κάθε split.

Στη δική μας περίπτωση:

$$p = 11.$$

Άρα:

$$\frac{p}{2} = \frac{11}{2} = 5.5.$$

Όμως το `scikit-learn`, όταν δίνουμε το `max_features` ως ακέραιο πλήθος μεταβλητών, χρειάζεται ακέραιο αριθμό. Δεν μπορούμε να του πούμε να εξετάζει 5.5 μεταβλητές. Για τον λόγο αυτό χρησιμοποιήθηκε:

$$\text{max_features} = 5.$$

Με άλλα λόγια, σε κάθε split κάθε δέντρου, το Random Forest εξετάζει τυχαία 5 από τις 11 διαθέσιμες προβλεπτικές μεταβλητές.

4.1 Γιατί δεν εξετάζουμε όλες τις μεταβλητές

Αν εξετάζαμε όλες τις μεταβλητές σε κάθε split, το Random Forest θα έμοιαζε πολύ περισσότερο με Bagging. Τα δέντρα θα είχαν μεγαλύτερη πιθανότητα να χρησιμοποιούν ξανά και ξανά τις ίδιες ισχυρές μεταβλητές.

Με το `max_features=5`, κάθε split βλέπει μόνο μέρος των μεταβλητών. Αυτό αναγκάζει τα δέντρα να δοκιμάσουν διαφορετικούς συνδυασμούς μεταβλητών. Έτσι μειώνεται η ομοιότητα μεταξύ των δέντρων.

5 Πώς λύσαμε το ερώτημα βήμα-βήμα

5.1 Βήμα 1: Φορτώσαμε τα δεδομένα

Ξεκινήσαμε διαβάζοντας το CSV αρχείο της 3ης εργασίας:

```
df = pd.read_csv("../Third_Assignment/Data_Analysis_2026_3rd_Case_Data.csv")
```

Ο πίνακας `df` περιέχει όλες τις παρατηρήσεις κρασιών.

5.2 Βήμα 2: Ορίσαμε τις προβλεπτικές μεταβλητές

Κρατήσαμε όλες τις μεταβλητές εκτός από τη `quality` και τη `wine_type`:

```
features = [col for col in df.columns if col not in ("quality", "wine_type")]  
p = len(features)  
max_features = p // 2
```

Εδώ το `p` είναι 11. Το `p // 2` δίνει το ακέραιο μέρος του $p/2$, δηλαδή:

$$11//2 = 5.$$

Άρα:

```
max_features = 5.
```

5.3 Βήμα 3: Ορίσαμε τη μεταβλητή στόχο

Η μεταβλητή στόχος είναι η `wine_type`. Την κωδικοποιήσαμε ως:

```
y = (df["wine_type"] == "white").astype(int)
```

Δηλαδή:

- `red` = 0,
- `white` = 1.

5.4 Βήμα 4: Χωρίσαμε τα δεδομένα σε training και test

Ο διαχωρισμός έγινε όπως και στα προηγούμενα ερωτήματα:

```
X_train, X_test, y_train, y_test = train_test_split(  
    X,  
    y,  
    test_size=0.30,  
    random_state=6931,  
    stratify=y,  
)
```

Το training set χρησιμοποιήθηκε για την εκπαίδευση του μοντέλου και το test set για την τελική αξιολόγηση.

5.5 Βήμα 5: Δημιουργήσαμε το Random Forest μοντέλο

Το μοντέλο ορίστηκε ως:

```
model = RandomForestClassifier(  
    n_estimators=200,  
    max_features=5,  
    random_state=6931,  
    n_jobs=-1,  
)
```

Ας δούμε τι σημαίνει κάθε παράμετρος:

- `RandomForestClassifier`: δηλώνει ότι χρησιμοποιούμε Random Forest για ταξινόμηση.
- `n_estimators=200`: το δάσος θα αποτελείται από 200 δέντρα.
- `max_features=5`: σε κάθε split θα εξετάζονται τυχαία 5 υποψήφιες μεταβλητές.
- `random_state=6931`: η διαδικασία γίνεται αναπαραγωγίμη.
- `n_jobs=-1`: χρησιμοποιούνται όλοι οι διαθέσιμοι πυρήνες του υπολογιστή για πιο γρήγορη εκτέλεση.

5.6 Βήμα 6: Εκπαιδεύσαμε το μοντέλο

Η εκπαίδευση έγινε με:

```
model.fit(X_train, y_train)
```

Σε αυτό το βήμα, το Random Forest εκπαιδεύει 200 δέντρα. Κάθε δέντρο εκπαιδεύεται σε bootstrap δείγμα και, σε κάθε split, εξετάζει μόνο 5 από τις 11 διαθέσιμες μεταβλητές.

5.7 Βήμα 7: Κάνουμε προβλέψεις στο test set

Οι προβλέψεις έγιναν με:

```
y_pred = model.predict(X_test)
```

Το `y_pred` περιέχει την τελική πρόβλεψη του Random Forest για κάθε παρατήρηση του test set.

5.8 Βήμα 8: Υπολογίσαμε accuracy και test error

Τέλος, υπολογίσαμε:

```
accuracy = accuracy_score(y_test, y_pred)
test_error = 1 - accuracy
```

Το `accuracy` δείχνει το ποσοστό σωστών προβλέψεων, ενώ το `test_error` δείχνει το ποσοστό λανθασμένων προβλέψεων.

6 Αποτελέσματα του Random Forest

Τα βασικά αποτελέσματα του Random Forest ήταν:

Πίνακας 1: Βασικά αποτελέσματα Random Forest.

Μέγεθος / μέτρο	Τιμή
Μοντέλο	Random Forest
Πλήθος εκτιμητών	200
Πλήθος predictors p	11
$p/2$	5.5
Χρησιμοποιημένο <code>max_features</code>	5
Random state	6931
Πλήθος test παρατηρήσεων	1589
Test accuracy	0.9666
Test error	0.0334

Η τιμή:

Test accuracy = 0.9666

σημαίνει ότι το Random Forest ταξινομήσε σωστά περίπου το 96.66% των test παρατηρήσεων.

Αντίστοιχα:

Test error = 0.0334


σημαίνει ότι έκανε λάθος περίπου στο 3.34% των test παρατηρήσεων.

6.1 Confusion matrix

Ο confusion matrix του Random Forest ήταν:

Πίνακας 2: Confusion matrix για το Random Forest.

	Πρόβλεψη: red	Πρόβλεψη: white
Πραγματικό: red	365	26
Πραγματικό: white	27	1171



Σχήμα 2: Γραφική απεικόνιση του confusion matrix για το Random Forest.

6.2 Πώς διαβάζουμε τον confusion matrix

Ο confusion matrix μάς λέει:

- 365 κόκκινα κρασιά ταξινομήθηκαν σωστά ως κόκκινα.
- 26 κόκκινα κρασιά ταξινομήθηκαν λάθος ως λευκά.
- 27 λευκά κρασιά ταξινομήθηκαν λάθος ως κόκκινα.
- 1171 λευκά κρασιά ταξινομήθηκαν σωστά ως λευκά.

Άρα οι σωστές προβλέψεις είναι:

$$365 + 1171 = 1536.$$

Το συνολικό πλήθος test παρατηρήσεων είναι:

$$365 + 26 + 27 + 1171 = 1589.$$

Επομένως:

$$\text{Accuracy} = \frac{1536}{1589} = 0.9666.$$

Τα συνολικά λάθη είναι:

$$26 + 27 = 53.$$

Άρα:

$$\text{Test Error} = \frac{53}{1589} = 0.0334.$$

7 Σύγκριση με τα προηγούμενα ερωτήματα

Μέχρι τώρα έχουμε εφαρμόσει τρεις μεθόδους:

1. Απλό δέντρο ταξινόμησης με $\text{max_depth}=2$.
2. Bagging με 200 δέντρα.
3. Random Forest με 200 δέντρα και $\text{max_features}=5$.

Τα αποτελέσματα είναι:

Πίνακας 3: Σύγκριση Ερωτημάτων 1, 2 και 3.

Μοντέλο	Test Accuracy	Test Error
Decision Tree ($\text{max_depth}=2$)	0.9339	0.0661
Bagging (200 estimators)	0.9660	0.0340
Random Forest (200 estimators, $m = 5$)	0.9666	0.0334

Σε σχέση με το απλό δέντρο, το Random Forest έχει πολύ καλύτερη απόδοση:

$$0.9666 - 0.9339 = 0.0327.$$

Δηλαδή αυξάνει την ακρίβεια κατά περίπου 3.27 ποσοστιαίες μονάδες.

Σε σχέση με το Bagging, η διαφορά είναι μικρή:

$$0.9666 - 0.9660 = 0.0006.$$

Άρα το Random Forest είναι ελαφρώς καλύτερο από το Bagging σε αυτό το test set, αλλά η διαφορά είναι πολύ μικρή.


7.1 Σύγκριση λαθών

Μοντέλο	Λάθη στο test set	Σωστές προβλέψεις
Decision Tree	105	1484
Bagging	54	1535
Random Forest	53	1536

Το Random Forest έκανε ένα λάθος λιγότερο από το Bagging και 52 λάθη λιγότερα από το απλό δέντρο.

8 Σημαντικότητα χαρακτηριστικών

Το Random Forest μπορεί να μας δώσει μία ένδειξη για το ποιες μεταβλητές χρησιμοποιήθηκαν περισσότερο και βοήθησαν περισσότερο στους διαχωρισμούς των δέντρων. Αυτό λέγεται **feature importance**.



Σχήμα 3: Οι σημαντικότερες μεταβλητές στο Random Forest.

Πίνακας 4: Σημαντικότητα χαρακτηριστικών στο Random Forest.

Μεταβλητή	Σημαντικότητα
total sulfur dioxide	0.3590
chlorides	0.2962
volatile acidity	0.0842
sulphates	0.0547
density	0.0419
free sulfur dioxide	0.0381
residual sugar	0.0343
fixed acidity	0.0311
pH	0.0266
citric acid	0.0188
alcohol	0.0151

Παρατηρούμε ότι οι δύο σημαντικότερες μεταβλητές είναι:

- total sulfur dioxide
- chlorides

Αυτό είναι συνεπές με όσα είδαμε στα προηγούμενα ερωτήματα. Το απλό δέντρο του Ερωτήματος 1 βασίστηκε ακριβώς σε αυτές τις μεταβλητές. Το Bagging επίσης τις ανέδειξε ως τις σημαντικότερες. Το Random Forest επιβεβαιώνει ότι τα θειώδη και τα χλωριούχα άλατα είναι πολύ χρήσιμα για τη διάκριση λευκών και κόκκινων κρασιών.

9 Τελικός σχολιασμός για το Ερώτημα 3

Το Random Forest με 200 δέντρα και `max_features=5` πέτυχε test accuracy 0.9666. Αυτό είναι πολύ υψηλή ακρίβεια και δείχνει ότι η μέθοδος μπορεί να προβλέψει με μεγάλη επιτυχία τον τύπο κρασιού.

Η απόδοση του Random Forest είναι πολύ καλύτερη από το απλό δέντρο του Ερωτήματος 1 και ελαφρώς καλύτερη από το Bagging του Ερωτήματος 2. Η διαφορά με το Bagging είναι μικρή, αλλά έχει νόημα: το Random Forest εισάγει επιπλέον τυχαιότητα στην επιλογή χαρακτηριστικών, κάτι που μπορεί να μειώσει τη συσχέτιση μεταξύ των δέντρων και να κάνει την τελική ψηφοφορία πιο αξιόπιστη.

Στο συγκεκριμένο dataset, το Random Forest έκανε 53 λάθη σε 1589 test παρατηρήσεις. Αυτό σημαίνει ότι ταξινομήσε σωστά 1536 κρασιά. Οι περισσότερες παρατηρήσεις ταξινομήθηκαν σωστά, ενώ τα λάθη ήταν σχετικά λίγα.

9.1 Σύντομη απάντηση που μπορεί να μπει στην εργασία

Για το τρίτο ερώτημα εφαρμόστηκε η μέθοδος Random Forest με $n_estimators=200$. Το πλήθος των προβλεπτικών μεταβλητών ήταν $p = 11$, άρα $p/2 = 5.5$. Επειδή το πλήθος υποψήφιων χαρακτηριστικών πρέπει να δοθεί ως ακέραιος αριθμός, χρησιμοποιήθηκε $max_features=5$. Το μοντέλο εκπαιδεύτηκε στο training set και αξιολογήθηκε στο test set, με $random_state=6931$. Η test accuracy ήταν 0.9666 και το test error ήταν 0.0334. Ο confusion matrix έδειξε ότι ταξινομήθηκαν σωστά 365 κόκκινα και 1171 λευκά κρασιά, ενώ έγιναν συνολικά 53 λάθη. Το Random Forest είχε ελαφρώς καλύτερη απόδοση από το Bagging και σαφώς καλύτερη από το απλό δέντρο ταξινόμησης.

A' Αρχεία που δημιουργήθηκαν για το report

Για το επεξηγηματικό report του Ερωτήματος 3 δημιουργήθηκαν τα παρακάτω αρχεία:

- `q3_explanatory_random_forest.py`: script που αναπαράγει τη λύση.
- `q3_explanatory_results.csv`: συγκεντρωτικός πίνακας αποτελεσμάτων.
- `q3_comparison_q1_q2_q3.csv`: σύγκριση των τριών πρώτων μεθόδων.
- `q3_confusion_matrix.png`: εικόνα του confusion matrix.
- `q3_random_forest_concept.png`: απλό σχήμα που εξηγεί τη μέθοδο Random Forest.
- `q3_random_forest_feature_importance.csv`: σημαντικότητα χαρακτηριστικών.
- `q3_random_forest_feature_importance.png`: γράφημα σημαντικότητας χαρακτηριστικών.
- `explanatory_report_q3_random_forest.tex`: το παρόν LaTeX αρχείο.