Ανάλυση Δεδομένων 2025-26

1η Εργασία: Ανάλυση Ποιότητας Κρασιού

ΑΕΜ: 6931 – Ρακοβαλής Παύλος

Μάρτιος 2026

Περιεχόμενα

1 Ερώτημα 1: Δειγματοληψία και Καθαρισμός Δεδομένων **2**
1.1 Εισαγωγή . . . 2
1.1.1 Σκοπός της Εργασίας . . . 2
1.1.2 Τι είναι ο Καθαρισμός Δεδομένων; . . . 2
1.2 Περιγραφή Δεδομένων . . . 2
1.2.1 Μεταβλητές . . . 2
1.3 Δειγματοληψία . . . 3
1.3.1 Τι είναι το Seed και γιατί το χρησιμοποιούμε; . . . 3
1.3.2 Εφαρμογή Δειγματοληψίας . . . 4
1.4 Εντοπισμός Προβλημάτων . . . 4
1.4.1 Τυπογραφικά Λάθη (wine_type) . . . 4
1.4.2 Μη Αριθμητικές Τιμές . . . 4
1.4.3 Αδύνατες Τιμές . . . 5
1.4.4 Διπλοεγγραφές . . . 5
1.4.5 Ελλείπουσες Τιμές (Missing Values) . . . 5
1.5 Αντιμετώπιση Προβλημάτων . . . 6
1.5.1 Στρατηγική Αντιμετώπισης . . . 6
1.5.2 Διόρθωση Τυπογραφικών Λαθών . . . 6
1.5.3 Γιατί Διάμεσος (Median) και όχι Μέσος Όρος; . . . 6
1.5.4 Γιατί ανά Τύπο Κρασιού; . . . 6
1.6 Αποτελέσματα . . . 7
1.6.1 Συνοπτικός Πίνακας Προβλημάτων . . . 7
1.6.2 Εξέλιξη Μεγέθους Dataset . . . 7
1.6.3 Κατανομή Τελικού Dataset . . . 7
1.7 Συμπεράσματα . . . 7

2 Ερώτημα 2: Γραφήματα Boxplot **8**
2.1 Τι είναι το Boxplot; . . . 8
2.2 Τα Στοιχεία του Boxplot . . . 8
2.3 Πώς Διαβάζουμε ένα Boxplot; . . . 9
2.4 Μαθηματικός Τύπος IQR . . . 9
2.5 Κατασκευή Boxplots στην Python . . . 9

2.6 Boxplots για το Σύνολο των Δεδομένων . . . 10
2.7 Κατανομή Quality (Διακριτή Μεταβλητή) . . . 11
2.8 Boxplots ανά Τύπο Κρασιού . . . 12
2.9 Συμπεράσματα Ερωτήματος 2 . . . 14

3 Ερώτημα 3: Εντοπισμός και Μετασχηματισμός Ακραίων Τιμών 15
3.1 Τι είναι οι Ακραίες Τιμές (Outliers); . . . 15
3.2 Μέθοδος IQR (Interquartile Range) . . . 15
3.2.1 Πώς λειτουργεί η μέθοδος IQR . . . 15
3.2.2 Παράδειγμα . . . 15
3.2.3 Πλεονεκτήματα μεθόδου IQR . . . 16
3.2.4 Κώδικας IQR στην Python . . . 16
3.2.5 Αποτελέσματα μεθόδου IQR . . . 16
3.3 Μέθοδος Z-Score . . . 16
3.3.1 Πώς λειτουργεί η μέθοδος Z-Score . . . 16
3.3.2 Παράδειγμα . . . 17
3.3.3 Πλεονεκτήματα και μειονεκτήματα μεθόδου Z-Score . . . 18
3.3.4 Κώδικας Z-Score στην Python . . . 18
3.3.5 Αποτελέσματα μεθόδου Z-Score ($|z| > 3.5$) . . . 18
3.4 Σύγκριση Μεθόδων IQR vs Z-Score . . . 19
3.5 Clamp Transformation (Μετασχηματισμός Αποκοπής) . . . 19
3.5.1 Τι είναι το Clamp Transformation; . . . 19
3.5.2 Γιατί Clamp αντί για αφαίρεση; . . . 19
3.5.3 Εφαρμογή: Κώδικας Clamp στην Python . . . 19
3.5.4 Αποτελέσματα Clamp Transformation . . . 20
3.6 Boxplots Πριν και Μετά τον Μετασχηματισμό . . . 20
3.7 Συμπεράσματα Ερωτήματος 3 . . . 21

4 Ερώτημα 4: Οπτική Παρουσίαση και Περιγραφικά Στατιστικά 22
4.1 Περιγραφικά Στατιστικά - Συνεχείς Μεταβλητές . . . 22
4.2 Περιγραφικά Στατιστικά - Κατηγορικές Μεταβλητές . . . 23
4.3 Boxplots Τελικού Dataset . . . 23
4.4 Histograms με Κατανομές Πυκνότητας . . . 24
4.5 Correlation Heatmap (Πίνακας Συσχετίσεων) . . . 25
4.6 Scatter Plots Ισχυρών Συσχετίσεων . . . 27
4.7 Violin Plots . . . 27
4.8 Συνοπτικό Dashboard . . . 29
4.9 Συμπεράσματα Ερωτήματος 4 . . . 29

A′ Πλήρης Κώδικας Python 30
A′.1 Κώδικας Ερωτήματος Α: Δειγματοληψία και Καθαρισμός . . . 30
A′.2 Κώδικας Ερωτήματος Β: Boxplots και Κατανομή Quality . . . 31
A′.3 Κώδικας Ερωτήματος Γ: Εντοπισμός Ακραίων Τιμών και Clamp Transformation 34
A′.4 Κώδικας Ερωτήματος Δ: Οπτική Παρουσίαση και Περιγραφικά Στατιστικά . . 36

1 Ερώτημα 1: Δειγματοληψία και Καθαρισμός Δεδομένων

1.1 Εισαγωγή

1.1.1 Σκοπός της Εργασίας

Η παρούσα εργασία αφορά την ανάλυση δεδομένων ποιότητας κρασιού. Οι στόχοι είναι:

1. Επιλογή τυχαίου δείγματος 80% με seed τον AEM
2. Έλεγχος ποιότητας δεδομένων
3. Καθαρισμός δεδομένων

1.1.2 Τι είναι ο Καθαρισμός Δεδομένων;

Ορισμός: Ο καθαρισμός δεδομένων είναι η διαδικασία εντοπισμού και διόρθωσης λανθασμένων, ελλιπών, διπλότυπων ή ασυνεπών εγγραφών. Είναι κρίσιμο βήμα πριν από οποιαδήποτε ανάλυση.

Συνήθη προβλήματα:

- **Τυπογραφικά λάθη:** π.χ. “whte” αντί “white”
- **Ελλείπουσες τιμές:** Κενά πεδία
- **Μη έγκυρες τιμές:** π.χ. pH = 999
- **Διπλοεγγραφές:** Επαναλαμβανόμενες γραμμές

1.2 Περιγραφή Δεδομένων

1.2.1 Μεταβλητές

Το dataset περιέχει τις εξής μεταβλητές:

1. **Fixed acidity** - Σταθερή οξύτητα (g/L)
2. **Volatile acidity** - Πτητική οξύτητα (g/L)
3. **Citric acid** - Κιτρικό οξύ (g/L)
4. **Residual sugar** - Υπολειμματικά σάκχαρα (g/L)
5. **Chlorides** - Χλωριούχα άλατα (g/L)
6. **Free SO2** - Ελεύθερο διοξείδιο του θείου (mg/L)
7. **Total SO2** - Συνολικό διοξείδιο του θείου (mg/L)
8. **Density** - Πυκνότητα (g/cm3)
9. **pH** - Οξύτητα (κλίμακα 2-14)
10. **Sulphates** - Θειικά άλατα (g/L)

11. **Alcohol** - Περιεκτικότητα σε αλκοόλ (%)
12. **Quality** - Βαθμολογία ποιότητας (0-10)
13. **Wine_type** - Τύπος κρασιού (red ή white)

Αρχικό dataset: **8.385** γραμμές × **15** στήλες

1.3 Δειγματοληψία

1.3.1 Τι είναι το Seed και γιατί το χρησιμοποιούμε;

Το **seed** (σπόρος) είναι ένας αριθμός που αρχικοποιεί τη **γεννήτρια τυχαίων αριθμών** του υπολογιστή.

Το πρόβλημα χωρίς seed:

Οι υπολογιστές δεν μπορούν να παράγουν πραγματικά τυχαίους αριθμούς. Αντί αυτού, χρησιμοποιούν μαθηματικούς αλγορίθμους που παράγουν **ψευδοτυχαίους αριθμούς** (pseudo-random numbers) – ακολουθίες αριθμών που φαίνονται τυχαίες αλλά στην πραγματικότητα είναι ντετερμινιστικές.

Αν δεν ορίσουμε seed, κάθε φορά που τρέχουμε τον κώδικα παίρνουμε διαφορετικό δείγμα:

```
# Without seed - different results each time
sample1 = df.sample(frac=0.80)  # rows [5, 12, 3, 99, ...]
sample2 = df.sample(frac=0.80)  # rows [7, 45, 2, 88, ...]  <-
    Different!
```

Η λύση με seed:

Όταν ορίζουμε seed, ο αλγόριθμος ξεκινάει πάντα από το ίδιο σημείο και παράγει την ίδια ακολουθία "τυχαίων" αριθμών:

```
# With seed - same results every time
sample1 = df.sample(frac=0.80, random_state=6931)  # rows [23, 45,
    12, ...]
sample2 = df.sample(frac=0.80, random_state=6931)  # rows [23, 45,
    12, ...] <- Same!
```

Πώς λειτουργεί:

$$\text{seed} = 6931 \xrightarrow{\text{αλγόριθμος}} [0.234, 0.891, 0.456, 0.123, \ldots] \text{ (πάντα η ίδια ακολουθία)}$$

Γιατί χρησιμοποιούμε τον ΑΕΜ ως seed:

1. **Αναπαραγωγιμότητα (Reproducibility):** Ο καθηγητής μπορεί να τρέξει τον ίδιο κώδικα με το ίδιο seed και να επαληθεύσει τα αποτελέσματα
2. **Μοναδικότητα:** Κάθε φοιτητής έχει διαφορετικό ΑΕΜ, άρα εργάζεται με διαφορετικό δείγμα δεδομένων
3. **Επαλήθευση:** Αν χρειαστεί να ξανατρέξουμε την ανάλυση, θα πάρουμε ακριβώς τα ίδια δεδομένα

1.3.2 Εφαρμογή Δειγματοληψίας

Χρησιμοποιούμε **seed = AEM = 6931**:

```
import pandas as pd

df_original = pd.read_csv('Data␣Analysis_2026.csv')
AEM = 6931  # Our unique seed
df = df_original.sample(frac=0.80, random_state=AEM)
df = df.reset_index(drop=True)
```

Τι κάνει κάθε γραμμή:

- `sample(frac=0.80)`: Επιλέγει τυχαία το 80% των γραμμών
- `random_state=AEM`: Ορίζει το seed ώστε το δείγμα να είναι αναπαραγώγιμο
- `reset_index(drop=True)`: Επαναριθμεί τις γραμμές από 0 (αφαιρεί τους παλιούς αριθμούς)

Αποτέλεσμα: 8.385 → **6.708** γραμμές (80%)

1.4 Εντοπισμός Προβλημάτων

1.4.1 Τυπογραφικά Λάθη (wine_type)

Εντοπίστηκαν τα εξής λανθασμένα values στη στήλη wine_type:

- "Redd " (75 εγγραφές) → red
- "whit" (90 εγγραφές) → white
- "r3d" (64 εγγραφές) → red
- "WHITTE" (77 εγγραφές) → white
- "whate" (39 εγγραφές) → white
- 999, 9999, -999, ? (215 εγγραφές) → NaN

Σύνολο τυπογραφικών λαθών: 560

1.4.2 Μη Αριθμητικές Τιμές

Βρέθηκαν μη αριθμητικές τιμές (π.χ. "abc", "?", "N/A") στις αριθμητικές στήλες:

- fixed acidity: 87 μη αριθμητικές τιμές
- volatile acidity: 45
- citric acid: 61
- pH: 151
- alcohol: 105
- κ.ά.

Σύνολο μη αριθμητικών τιμών: 845

1.4.3 Αδύνατες Τιμές

Τιμές όπως 999, -999, 9999 χρησιμοποιούνται συχνά ως κωδικοί για ελλείπουσες τιμές. Επίσης, κάποιες τιμές είναι εκτός λογικών ορίων (π.χ. pH = 999 ενώ το pH κυμαίνεται μεταξύ 0-14).

Λογικά όρια:

- Fixed acidity: 0-20 g/L
- Volatile acidity: 0-5 g/L
- pH: 2-5
- Alcohol: 5-20%
- Quality: 0-10
- Density: 0.9-1.1 g/cm^3

Τιμές εκτός ορίων: 2.037

1.4.4 Διπλοεγγραφές

```
duplicates = df.duplicated()
print(f"Duplicates found: {duplicates.sum()}")
```

Εντοπίστηκαν **1.434** διπλοεγγραφές.

1.4.5 Ελλείπουσες Τιμές (Missing Values)

Μετά τη μετατροπή των μη αριθμητικών και αδύνατων τιμών σε NaN, οι ελλείπουσες τιμές ανά στήλη είναι:

- fixed acidity: 574 (10.9%)
- volatile acidity: 542 (10.3%)
- density: 545 (10.3%)
- pH: 644 (12.2%)
- alcohol: 600 (11.4%)
- quality: 40 (0.8%)

Σύνολο ελλειπουσών τιμών: 3.092

1.5 Αντιμετώπιση Προβλημάτων

1.5.1 Στρατηγική Αντιμετώπισης

1. **Τυπογραφικά λάθη wine_type:** Διόρθωση στη σωστή τιμή ή NaN
2. **Μη αριθμητικές τιμές:** Μετατροπή σε NaN
3. **Αδύνατες τιμές:** Μετατροπή σε NaN
4. **Διπλοεγγραφές:** Αφαίρεση
5. **Missing values:** Συμπλήρωση με διάμεσο ανά τύπο κρασιού

1.5.2 Διόρθωση Τυπογραφικών Λαθών

```
corrections = {
    'Redd␣': 'red', 'r3d': 'red',
    'WHITTE': 'white', 'whit': 'white', 'whate': 'white',
    '999': None, '9999': None, '-999': None, '?': None
}
for wrong, correct in corrections.items():
    df.loc[df['wine_type'] == wrong, 'wine_type'] = correct
```

1.5.3 Γιατί Διάμεσος (Median) και όχι Μέσος Όρος;

Η διάμεσος είναι η τιμή που χωρίζει τα δεδομένα στη μέση (50% πάνω, 50% κάτω). Είναι πιο ανθεκτική σε ακραίες τιμές (outliers) σε αντίθεση με τον μέσο όρο.

Παράδειγμα: Για τιμές [1, 2, 3, 4, 100]:

- Μέσος όρος = 22 (επηρεάζεται από το 100)
- Διάμεσος = 3 (δεν επηρεάζεται)

1.5.4 Γιατί ανά Τύπο Κρασιού;

Τα κόκκινα και λευκά κρασιά έχουν διαφορετικά χημικά χαρακτηριστικά:

- Κόκκινο - Fixed acidity (διάμεσος): 7.80
- Λευκό - Fixed acidity (διάμεσος): 6.80
- Κόκκινο - Total SO2 (διάμεσος): 40
- Λευκό - Total SO2 (διάμεσος): 133

1.6 Αποτελέσματα

1.6.1 Συνοπτικός Πίνακας Προβλημάτων

1. Περιττές στήλες (Unnamed): 2 - Αφαιρέθηκαν
2. Τυπογραφικά λάθη wine_type: 560 - Διορθώθηκαν
3. Μη αριθμητικές τιμές: 845 - Έγιναν NaN
4. Αδύνατες τιμές: 2.037 - Έγιναν NaN
5. Διπλοεγγραφές: 1.434 - Αφαιρέθηκαν
6. Missing values (αρχικά): 3.092 - Συμπληρώθηκαν με διάμεσο
7. Missing values (τελικά): 0

1.6.2 Εξέλιξη Μεγέθους Dataset

1. Αρχικό: 8.385 γραμμές × 15 στήλες
2. Μετά sample (80%): 6.708 γραμμές × 13 στήλες
3. Μετά αφαίρεση duplicates: 5.274 γραμμές × 13 στήλες
4. **Τελικό: 5.274 γραμμές × 13 στήλες**

1.6.3 Κατανομή Τελικού Dataset

- Λευκό κρασί: 3.924 (74.4%)
- Κόκκινο κρασί: 1.350 (25.6%)
- **Σύνολο: 5.274 (100%)**

1.7 Συμπεράσματα

1. Τα πραγματικά δεδομένα περιέχουν πολλαπλά προβλήματα ποιότητας
2. Ο καθαρισμός δεδομένων είναι απαραίτητος πριν από κάθε ανάλυση
3. Κάθε τύπος προβλήματος απαιτεί διαφορετική αντιμετώπιση
4. Οι αποφάσεις καθαρισμού πρέπει να είναι τεκμηριωμένες
5. Η χρήση seed εξασφαλίζει αναπαραγωγιμότητα

Το καθαρισμένο dataset αποθηκεύτηκε στο αρχείο: `cleaned_wine_data_AEM_6931.csv`

2 Ερώτημα 2: Γραφήματα Boxplot

2.1 Τι είναι το Boxplot;

Το **boxplot** (ή box-and-whisker plot) είναι ένα γράφημα που απεικονίζει την κατανομή μιας αριθμητικής μεταβλητής με τρόπο συνοπτικό αλλά πλούσιο σε πληροφορίες. Εφευρέθηκε από τον στατιστικολόγο John Tukey το 1970.

2.2 Τα Στοιχεία του Boxplot

Ένα boxplot αποτελείται από τα εξής στοιχεία:

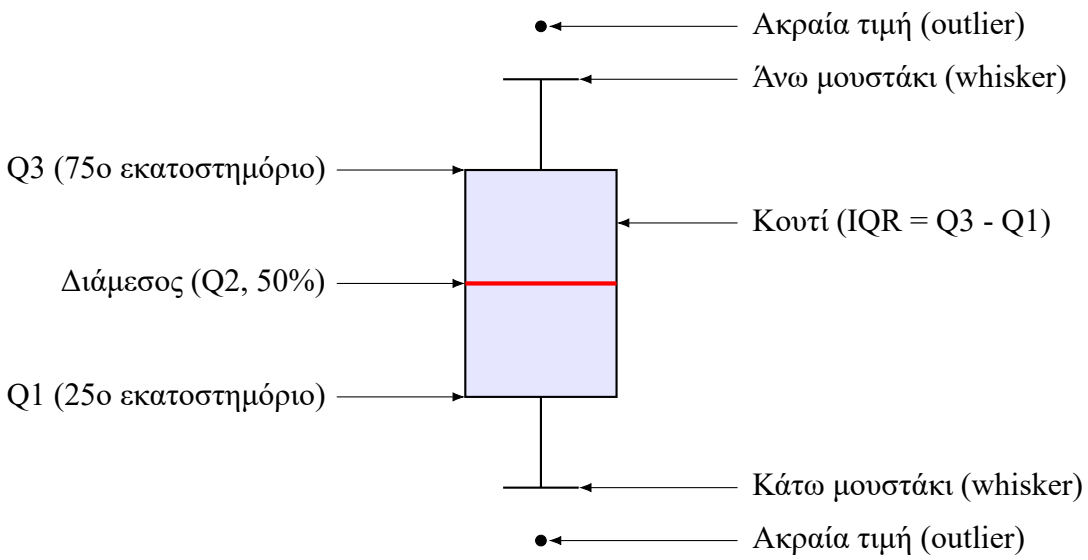

Σχήμα 1: Δομή ενός boxplot: τεταρτημόρια, μουστάκια και ακραίες τιμές

Αναλυτική εξήγηση κάθε στοιχείου:

1. **Το κουτί (Box):**
   - Η κάτω πλευρά του κουτιού είναι το **Q1 (1ο τεταρτημόριο)**: το 25% των τιμών είναι κάτω από αυτό το σημείο
   - Η γραμμή στη μέση είναι η **Διάμεσος (Q2)**: το 50% των τιμών είναι κάτω από αυτό
   - Η πάνω πλευρά είναι το **Q3 (3ο τεταρτημόριο)**: το 75% των τιμών είναι κάτω από αυτό
   - Το **ύψος του κουτιού** είναι το IQR = Q3 - Q1 (Ενδοτεταρτημοριακό Εύρος)
2. **Τα μουστάκια (Whiskers):**
   - Εκτείνονται από το κουτί μέχρι τις πιο ακραίες τιμές που ΔΕΝ θεωρούνται outliers
   - Τυπικά φτάνουν μέχρι 1.5 × IQR από τα άκρα του κουτιού
   - Άνω όριο: Q3 + 1.5 × IQR
   - Κάτω όριο: Q1 - 1.5 × IQR
3. **Οι ακραίες τιμές (Outliers):**

- Τιμές που βρίσκονται πέρα από τα μουστάκια
- Απεικονίζονται ως μεμονωμένα σημεία (κύκλοι ή διαμάντια)
- Υποδεικνύουν πιθανώς ασυνήθιστες ή λανθασμένες τιμές

2.3 Πώς Διαβάζουμε ένα Boxplot;

Το boxplot μας δίνει πολλές πληροφορίες με μια ματιά:

- **Κεντρική τάση:** Η θέση της διαμέσου δείχνει πού "κεντράρονται" τα δεδομένα
- **Διασπορά:** Το μέγεθος του κουτιού (IQR) δείχνει πόσο διασκορπισμένα είναι τα δεδομένα
- **Ασυμμετρία (Skewness):**
  - Αν η διάμεσος είναι στο κέντρο του κουτιού → συμμετρική κατανομή
  - Αν η διάμεσος είναι πιο κοντά στο Q1 → θετική ασυμμετρία (ουρά προς τα δεξιά)
  - Αν η διάμεσος είναι πιο κοντά στο Q3 → αρνητική ασυμμετρία (ουρά προς τα αριστερά)
- **Outliers:** Τα σημεία εκτός των μουστακιών υποδεικνύουν ακραίες τιμές

2.4 Μαθηματικός Τύπος IQR

Το **Ενδοτεταρτημοριακό Εύρος (IQR)** υπολογίζεται ως:

$$\text{IQR} = Q3 - Q1$$

Τα όρια για τον εντοπισμό outliers είναι:

$$\text{Κάτω όριο} = Q1 - 1.5 \times \text{IQR}$$
$$\text{Άνω όριο} = Q3 + 1.5 \times \text{IQR}$$

Οποιαδήποτε τιμή εκτός αυτών των ορίων θεωρείται **outlier**.

2.5 Κατασκευή Boxplots στην Python

```
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd

# Load cleaned data
df = pd.read_csv('cleaned_wine_data_AEM_6931.csv')

# List of continuous variables
continuous_vars = ['fixed␣acidity', 'volatile␣acidity', 'citric␣acid'
    ,
                   'residual␣sugar', 'chlorides', 'free␣sulfur␣
                      dioxide',
```

```
                    'total␣sulfur␣dioxide', 'density', 'pH', '
                       sulphates',
                    'alcohol', 'quality']

# Create boxplots for all data
fig, axes = plt.subplots(3, 4, figsize=(16, 12))
for i, col in enumerate(continuous_vars):
    ax = axes[i//4, i%4]
    df.boxplot(column=col, ax=ax)
    ax.set_title(col)
plt.tight_layout()
plt.savefig('boxplots_all_data.png')
```

2.6 Boxplots για το Σύνολο των Δεδομένων

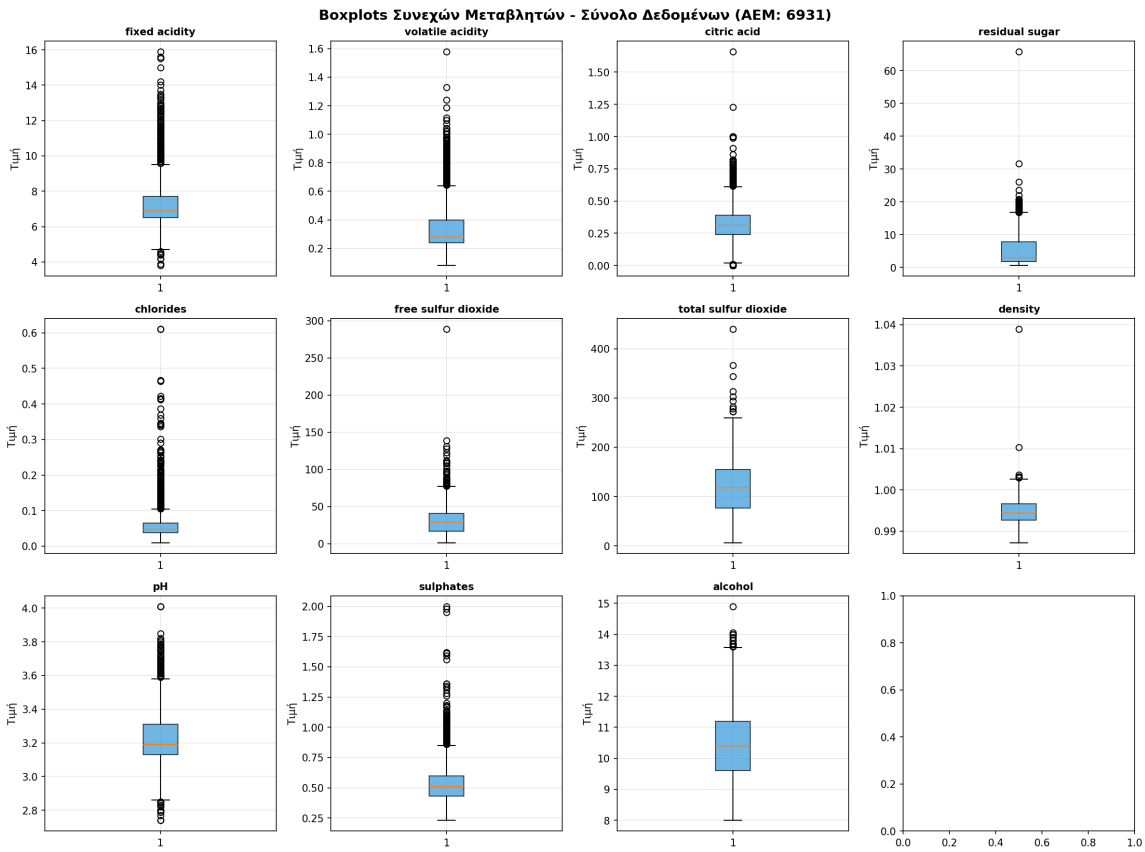

Σχήμα 2: Boxplots όλων των συνεχών μεταβλητών για το σύνολο του dataset

Σχολιασμός:

- **Fixed acidity:** Σχετικά συμμετρική κατανομή με κέντρο περίπου στο 7. Υπάρχουν μερικά outliers στις υψηλές τιμές.
- **Volatile acidity:** Θετικά ασύμμετρη κατανομή (η διάμεσος είναι χαμηλά στο κουτί). Πολλά outliers στις υψηλές τιμές, υποδεικνύοντας ότι λίγα κρασιά έχουν πολύ υψηλή πτητική οξύτητα.

- **Citric acid:** Διάμεσος κοντά στο 0.3 με αρκετά outliers. Η κατανομή είναι ελαφρώς θετικά ασύμμετρη.
- **Residual sugar:** Πολύ θετικά ασύμμετρη κατανομή με πολλά outliers. Τα περισσότερα κρασιά έχουν χαμηλά υπολειμματικά σάκχαρα, αλλά υπάρχουν γλυκά κρασιά με πολύ υψηλές τιμές.
- **Chlorides:** Πολύ συμπαγής κατανομή (μικρό IQR) με πολλά outliers. Οι περισσότερες τιμές είναι κοντά στο 0.05.
- **Free sulfur dioxide:** Θετικά ασύμμετρη με outliers στις υψηλές τιμές.
- **Total sulfur dioxide:** Παρόμοια με το free SO2, θετικά ασύμμετρη κατανομή.
- **Density:** Πολύ συμμετρική κατανομή με κέντρο κοντά στο 0.995. Λίγα outliers.
- **pH:** Σχεδόν τέλεια συμμετρική κατανομή (κανονική). Διάμεσος περίπου 3.2.
- **Sulphates:** Ελαφρώς θετικά ασύμμετρη με outliers στις υψηλές τιμές.
- **Alcohol:** Σχετικά συμμετρική κατανομή με εύρος 8-14%.

2.7 Κατανομή Quality (Διακριτή Μεταβλητή)

Η μεταβλητή **quality** είναι διακριτή (παίρνει ακέραιες τιμές 3-9) και δεν ταιριάζει καλά σε ένα κλασικό boxplot. Γι' αυτό παρουσιάζουμε την κατανομή της με ιστόγραμμα:

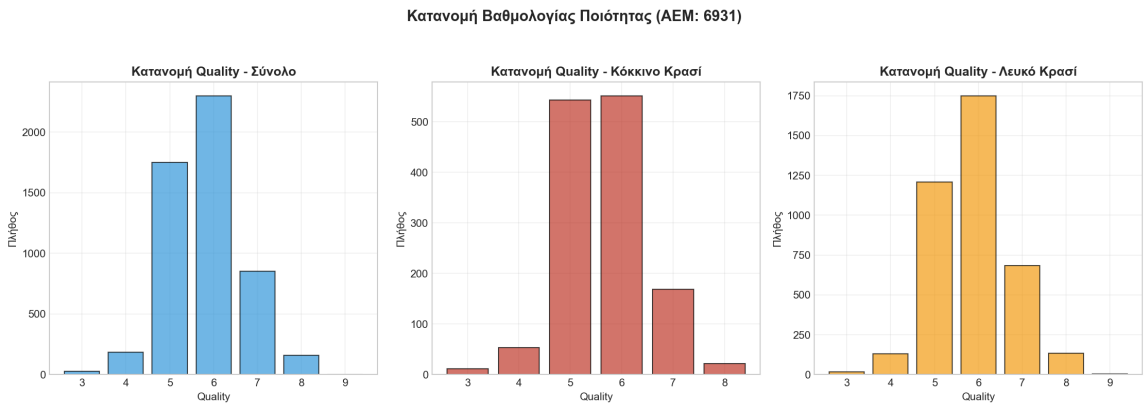

Σχήμα 3: Κατανομή της Quality - Συνολικά και ανά τύπο κρασιού

Σχολιασμός:

- Η συνολική κατανομή της quality είναι **κανονική προς τα αριστερά**, με τη μεγαλύτερη συχνότητα στο score 6 (2.299 κρασιά)
- **Κόκκινα κρασιά:** Περισσότερα κρασιά με χαμηλές βαθμολογίες (5-6), με λίγα εξαιρετικά κρασιά (8-9)
- **Λευκά κρασιά:** Πιο ευρεία κατανομή με αρκετά κρασιά στις μεσαίες βαθμολογίες (5-7)
- Η μεσοελάχιστη κατανομή υποδεικνύει ότι είναι δύσκολο να παράξεις κρασί με πολύ υψηλή ή πολύ χαμηλή ποιότητα

2.8 Boxplots ανά Τύπο Κρασιού

```
# Boxplots by wine type
fig, axes = plt.subplots(3, 4, figsize=(16, 12))
for i, col in enumerate(continuous_vars):
    ax = axes[i//4, i%4]
    df.boxplot(column=col, by='wine_type', ax=ax)
    ax.set_title(col)
    ax.set_xlabel('')
plt.suptitle('Boxplots␣by␣Wine␣Type', y=1.02)
plt.tight_layout()
plt.savefig('boxplots_by_wine_type.png')
```

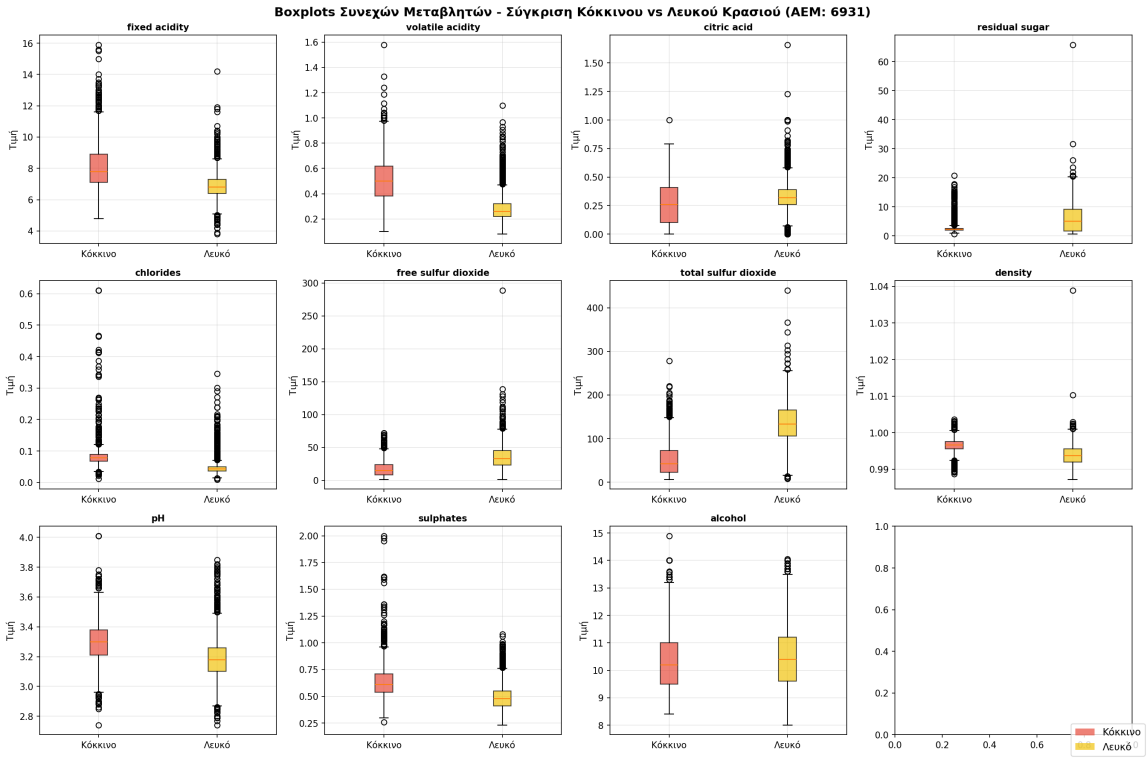

Σχήμα 4: Boxplots όλων των συνεχών μεταβλητών ξεχωριστά για κόκκινο και λευκό κρασί

Σχολιασμός - Διαφορές μεταξύ κόκκινου και λευκού κρασιού:

1. **Fixed acidity:**
   - Κόκκινο: Υψηλότερη διάμεσος (7.8) και μεγαλύτερη διασπορά
   - Λευκό: Χαμηλότερη διάμεσος (6.8) και πιο συμπαγής κατανομή
   - *Ερμηνεία:* Τα κόκκινα κρασιά τείνουν να έχουν υψηλότερη σταθερή οξύτητα
2. **Volatile acidity:**
   - Κόκκινο: Σημαντικά υψηλότερη (διάμεσος 0.5)
   - Λευκό: Πολύ χαμηλότερη (διάμεσος 0.26)

- Το κουτί των κόκκινων είναι μεγαλύτερο, άρα μεγαλύτερη διασπορά (IQR) στην πτητική οξύτητα
- *Ερμηνεία:* Η πτητική οξύτητα σχετίζεται με οξικό οξύ - τα λευκά κρασιά είναι πιο "καθαρά"

3. **Citric acid:**
   - Κόκκινο: Διάμεσος 0.25
   - Λευκό: Διάμεσος 0.32
   - Παρόμοιες κατανομές με μικρές διαφορές
4. **Residual sugar:**
   - Κόκκινο: Πολύ χαμηλά επίπεδα (διάμεσος 2.2), τα περισσότερα είναι "dry"
   - Λευκό: Υψηλότερα επίπεδα (διάμεσος 5), μεγαλύτερη ποικιλία (dry έως sweet)
   - Στα λευκά το κουτί είναι σαφώς μεγαλύτερο, δείχνοντας πολύ μεγαλύτερη διασπορά στα υπολειμματικά σάκχαρα
   - *Ερμηνεία:* Τα λευκά κρασιά συχνά είναι πιο γλυκά
5. **Chlorides:**
   - Κόκκινο: Υψηλότερα (0.078)
   - Λευκό: Χαμηλότερα (0.043)
   - Το κουτί είναι σχετικά μικρό και στους δύο τύπους, άρα η κύρια μάζα τιμών είναι συγκεντρωμένη κοντά στη διάμεσο
6. **Free & Total sulfur dioxide:**
   - Κόκκινο: Πολύ χαμηλά επίπεδα (total SO2 διάμεσος 42, free SO2 15)
   - Λευκό: Πολύ υψηλότερα επίπεδα (total SO2 διάμεσος 133, free SO2 33)
   - Για το total SO2, το κουτί των λευκών είναι μεγαλύτερο, άρα και μεγαλύτερη διασπορά στη μεσαία περιοχή τιμών
   - *Ερμηνεία:* Τα λευκά κρασιά χρειάζονται περισσότερο SO2 ως συντηρητικό επειδή είναι πιο ευαίσθητα στην οξείδωση
7. **Density:**
   - Κόκκινο: Διάμεσος 0.997
   - Λευκό: Διάμεσος 0.994
   - Ελαφρώς υψηλότερη πυκνότητα στα κόκκινα λόγω υψηλότερων σακχάρων και εκχυλισμάτων
8. **pH:**
   - Κόκκινο: Διάμεσος 3.30
   - Λευκό: Διάμεσος 3.18
   - Τα λευκά είναι ελαφρώς πιο όξινα

9. **Sulphates:**
   - Κόκκινο: Υψηλότερα (0.61)
   - Λευκό: Χαμηλότερα (0.48)
10. **Alcohol:**
   - Παρόμοια κατανομή και για τους δύο τύπους
   - Διάμεσος περίπου 10-10.5% και για τα δύο
   - Παρόμοιο μέγεθος κουτιού, άρα παρόμοια διασπορά (IQR) στο αλκοόλ
11. **Quality:**
   - Παρόμοια κατανομή με διάμεσο 6 και για τα δύο
   - Τα λευκά έχουν ελαφρώς μεγαλύτερο εύρος βαθμολογιών
   - Το σχετικά μικρό κουτί και στους δύο τύπους δείχνει ότι οι περισσότερες τιμές συγκεντρώνονται γύρω από 5-6

2.9 Συμπεράσματα Ερωτήματος 2

Από την ανάλυση των boxplots προκύπτουν τα εξής βασικά συμπεράσματα:

1. **Οι περισσότερες μεταβλητές έχουν outliers**, ιδιαίτερα οι residual sugar, chlorides, και sulfur dioxide.
2. **Πολλές κατανομές είναι θετικά ασύμμετρες** (ουρά προς τα δεξιά), κάτι που είναι συνηθισμένο σε χημικές μετρήσεις.
3. **Τα κόκκινα και λευκά κρασιά διαφέρουν σημαντικά** σε πολλές μεταβλητές:
   - Τα κόκκινα έχουν υψηλότερη πτητική οξύτητα και θειικά άλατα
   - Τα λευκά έχουν υψηλότερα επίπεδα SO2 και υπολειμματικών σακχάρων
4. **Τα boxplots αποκαλύπτουν outliers** που μπορεί να επηρεάσουν τις αναλύσεις και πρέπει να αντιμετωπιστούν (βλ. Ερώτημα 3).
5. **Η διαχωρισμός ανά τύπο κρασιού είναι απαραίτητος** για σωστή ερμηνεία, καθώς οι δύο τύποι έχουν διαφορετικά χημικά χαρακτηριστικά.

3 Ερώτημα 3: Εντοπισμός και Μετασχηματισμός Ακραίων Τιμών

3.1 Τι είναι οι Ακραίες Τιμές (Outliers);

Οι **ακραίες τιμές** (outliers) είναι παρατηρήσεις που απέχουν σημαντικά από τις υπόλοιπες τιμές ενός δείγματος. Μπορεί να οφείλονται σε:

- **Σφάλματα μέτρησης** ή καταχώρησης
- **Πραγματικές ακραίες τιμές** (π.χ. ένα εξαιρετικά γλυκό κρασί)
- **Φυσική ποικιλομορφία** στα δεδομένα

Οι outliers μπορούν να παραμορφώσουν τα αποτελέσματα μιας στατιστικής ανάλυσης (π.χ. τον μέσο όρο, τη διασπορά, τη συσχέτιση), γι' αυτό πρέπει να εντοπίζονται και να αντιμετωπίζονται κατάλληλα.

3.2 Μέθοδος IQR (Interquartile Range)

3.2.1 Πώς λειτουργεί η μέθοδος IQR

Η μέθοδος IQR χρησιμοποιεί τα τεταρτημόρια (quartiles) για να ορίσει τα όρια εκτός των οποίων μια τιμή θεωρείται ακραία. Υπολογίζεται ως εξής:

Βήμα 1: Υπολογισμός τεταρτημορίων

- $Q1$ = 25ο εκατοστημόριο (το 25% των τιμών είναι μικρότερες)
- $Q3$ = 75ο εκατοστημόριο (το 75% των τιμών είναι μικρότερες)

Βήμα 2: Υπολογισμός IQR

$$\text{IQR} = Q3 - Q1$$

Βήμα 3: Υπολογισμός ορίων

$$\text{Κάτω όριο} = Q1 - 1.5 \times \text{IQR}$$

$$\text{Άνω όριο} = Q3 + 1.5 \times \text{IQR}$$

Βήμα 4: Κάθε τιμή x που ικανοποιεί $x <$ Κάτω όριο ή $x >$ Άνω όριο θεωρείται **outlier**.

3.2.2 Παράδειγμα

Έστω ότι έχουμε τιμές pH: $Q1 = 3.13$, $Q3 = 3.31$.

$$\text{IQR} = 3.31 - 3.13 = 0.18$$

$$\text{Κάτω όριο} = 3.13 - 1.5 \times 0.18 = 2.86$$

$$\text{Άνω όριο} = 3.31 + 1.5 \times 0.18 = 3.58$$

Κάθε κρασί με pH < 2.86 ή pH > 3.58 θεωρείται outlier.

3.2.3 Πλεονεκτήματα μεθόδου IQR

- Δεν επηρεάζεται από ακραίες τιμές (βασίζεται σε τεταρτημόρια, όχι μέσο όρο)
- Δεν απαιτεί κανονική κατανομή
- Εύκολη στην κατανόηση και εφαρμογή

3.2.4 Κώδικας IQR στην Python

```
for var in continuous_vars:
    Q1 = df[var].quantile(0.25)
    Q3 = df[var].quantile(0.75)
    IQR = Q3 - Q1

    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    outliers = (df[var] < lower_bound) | (df[var] > upper_bound)
    print(f"{var}: {outliers.sum()} outliers")
```

3.2.5 Αποτελέσματα μεθόδου IQR

- Fixed acidity: 270 outliers (5.1%)
- Volatile acidity: 308 outliers (5.8%)
- Citric acid: 327 outliers (6.2%)
- Residual sugar: 124 outliers (2.4%)
- Chlorides: 232 outliers (4.4%)
- Free sulfur dioxide: 48 outliers (0.9%)
- Total sulfur dioxide: 10 outliers (0.2%)
- Density: 7 outliers (0.1%)
- pH: 104 outliers (2.0%)
- Sulphates: 146 outliers (2.8%)
- Alcohol: 29 outliers (0.5%)
- Quality: 188 outliers (3.6%)

Σύνολο ακραίων τιμών (IQR): 1.793

3.3 Μέθοδος Z-Score

3.3.1 Πώς λειτουργεί η μέθοδος Z-Score

Η μέθοδος Z-Score μετράει πόσες **τυπικές αποκλίσεις** (σ) απέχει κάθε τιμή από τον **μέσο όρο** (μ) της μεταβλητής.

Τι είναι η Τυπική Απόκλιση; Η **τυπική απόκλιση** (standard deviation, σ) είναι ένα μέτρο που μας δείχνει **πόσο διασκορπισμένες είναι οι τιμές γύρω από τον μέσο όρο**. Με άλλα λόγια:

- Αν η τυπική απόκλιση είναι **μικρή**, οι τιμές είναι **κοντά στον μέσο όρο** (δεν υπάρχει μεγάλη διασπορά)
- Αν η τυπική απόκλιση είναι **μεγάλη**, οι τιμές είναι **απλωμένες πολύ** (υπάρχει μεγάλη διασπορά)

Υπολογίζεται με τη εξίσωση:

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2}$$

δηλαδή, η τετραγωνική ρίζα του μέσου όρου των τετραγώνων των αποκλίσεων από τον μέσο όρο.

Στα δεδομένα μας (κρασιά):

Για τη μεταβλητή alcohol:

- Μέσος όρος (μ) = 10.49%
- Τυπική απόκλιση (σ) = 1.11%

Αυτό σημαίνει ότι οι περισσότερες τιμές κυμαίνονται περίπου μεταξύ $10.49 - 1.11 = 9.38\%$ και $10.49 + 1.11 = 11.60\%$.

Βήμα 1: Υπολογισμός Z-Score κάθε τιμής

$$z = \frac{x - \mu}{\sigma}$$

όπου:

- x = η τιμή που εξετάζουμε
- μ = ο μέσος όρος της μεταβλητής
- σ = η τυπική απόκλιση της μεταβλητής

Το Z-Score μας λέει πόσες τυπικές αποκλίσεις απέχει μια τιμή από τον μέσο.

Βήμα 2: Αν $|z| > 3.5$ (δηλαδή η τιμή απέχει πάνω από 3.5 τυπικές αποκλίσεις), θεωρείται **outlier**.

Αυτά τα όρια μεταφράζονται σε:

$$\text{Κάτω όριο} = \mu - 3.5 \times \sigma$$

$$\text{Άνω όριο} = \mu + 3.5 \times \sigma$$

3.3.2 Παράδειγμα

Για τη μεταβλητή alcohol, αν $\mu = 10.49$ και $\sigma = 1.11$:

$$\text{Κάτω όριο} = 10.49 - 3.5 \times 1.11 = 6.60$$

$$\text{Άνω όριο} = 10.49 + 3.5 \times 1.11 = 14.38$$

Ένα κρασί με alcohol = 15% θα θεωρηθεί outlier αφού $15 > 14.38$.

3.3.3 Πλεονεκτήματα και μειονεκτήματα μεθόδου Z-Score

Πλεονεκτήματα:

- Βασίζεται σε μαθηματικά σαφή κριτήρια
- Ρυθμιζόμενο threshold (στην περίπτωσή μας 3.5)

Μειονεκτήματα:

- Ο μέσος όρος και η τυπική απόκλιση επηρεάζονται από τις ίδιες τις ακραίες τιμές
- Υποθέτει (ιδανικά) κανονική ή σχεδόν κανονική κατανομή

3.3.4 Κώδικας Z-Score στην Python

```
z_threshold = 3.5
for var in continuous_vars:
    mean = df[var].mean()
    std = df[var].std()

    lower_bound = mean - z_threshold * std
    upper_bound = mean + z_threshold * std

    outliers = (df[var] < lower_bound) | (df[var] > upper_bound)
    print(f"{var}: {outliers.sum()} outliers")
```

3.3.5 Αποτελέσματα μεθόδου Z-Score ($|z| > 3.5$)

- Fixed acidity: 76 outliers (1.4%)
- Volatile acidity: 39 outliers (0.7%)
- Citric acid: 12 outliers (0.2%)
- Residual sugar: 5 outliers (0.1%)
- Chlorides: 56 outliers (1.1%)
- Free sulfur dioxide: 18 outliers (0.3%)
- Total sulfur dioxide: 4 outliers (0.1%)
- Density: 2 outliers (0.04%)
- pH: 16 outliers (0.3%)
- Sulphates: 39 outliers (0.7%)
- Alcohol: 1 outlier (0.02%)
- Quality: 3 outliers (0.1%)

Σύνολο ακραίων τιμών (Z-Score): 271

3.4 Σύγκριση Μεθόδων IQR vs Z-Score

- Η μέθοδος **IQR εντοπίζει 1.793 outliers** ενώ η μέθοδος **Z-Score εντοπίζει 271**
- Η IQR είναι πιο **ευαίσθητη** (αυστηρότερη) – εντοπίζει περισσότερες ακραίες τιμές
- Η Z-Score με threshold 3.5 είναι πιο **συντηρητική** – εντοπίζει μόνο τις πολύ ακραίες τιμές
- Η διαφορά οφείλεται στο ότι:
  - Η IQR ορίζει τα όρια βάσει τεταρτημορίων ($1.5 \times$ IQR)
  - Η Z-Score ορίζει τα όρια βάσει τυπικών αποκλίσεων ($3.5 \times \sigma$)
  - Σε ασύμμετρες κατανομές (όπως πολλές μεταβλητές κρασιού), τα όρια IQR γίνονται στενότερα
- Στην πράξη, η επιλογή μεθόδου εξαρτάται από το context: αν θέλουμε να είμαστε αυστηροί, χρησιμοποιούμε IQR· αν θέλουμε μόνο τα πιο ακραία σημεία, Z-Score

3.5 Clamp Transformation (Μετασχηματισμός Αποκοπής)

3.5.1 Τι είναι το Clamp Transformation;

Το **Clamp Transformation** (ή Winsorization) είναι μια τεχνική αντιμετώπισης ακραίων τιμών που **δεν αφαιρεί** τις παρατηρήσεις, αλλά τις **αντικαθιστά** με τις πλησιέστερες αποδεκτές τιμές:

- Αν $x <$ Κάτω όριο $\rightarrow x =$ Κάτω όριο
- Αν $x >$ Άνω όριο $\rightarrow x =$ Άνω όριο
- Αν η τιμή είναι εντός ορίων $\rightarrow$ παραμένει ως έχει

3.5.2 Γιατί Clamp αντί για αφαίρεση;

- **Διατήρηση μεγέθους δείγματος:** Δεν χάνουμε εγγραφές, πράγμα σημαντικό αν το dataset δεν είναι πολύ μεγάλο
- **Μείωση επίδρασης outliers:** Οι ακραίες τιμές μετριάζονται χωρίς να εξαφανίζονται
- **Διατήρηση δομής:** Δεν αλλάζει η σειρά (ranking) των τιμών

3.5.3 Εφαρμογή: Κώδικας Clamp στην Python

Εφαρμόζουμε Clamp με βάση τα όρια της μεθόδου IQR:

```python
for var in continuous_vars:
    Q1 = df[var].quantile(0.25)
    Q3 = df[var].quantile(0.75)
    IQR = Q3 - Q1
    lower = Q1 - 1.5 * IQR
    upper = Q3 + 1.5 * IQR

    # Clamp: clip values to [lower, upper]
    df[var] = df[var].clip(lower=lower, upper=upper)
```

3.5.4 Αποτελέσματα Clamp Transformation

Η εφαρμογή του Clamp μετασχηματισμού αφορά **1.793 τιμές** (βάσει IQR) και μετά τον μετασχηματισμό:

- Δεν χάθηκε καμία εγγραφή (παραμένουν 5.274 γραμμές)
- Δεν υπάρχουν πλέον outliers βάσει IQR
- Οι κατανομές γίνονται πιο συμπαγείς

3.6 Boxplots Πριν και Μετά τον Μετασχηματισμό

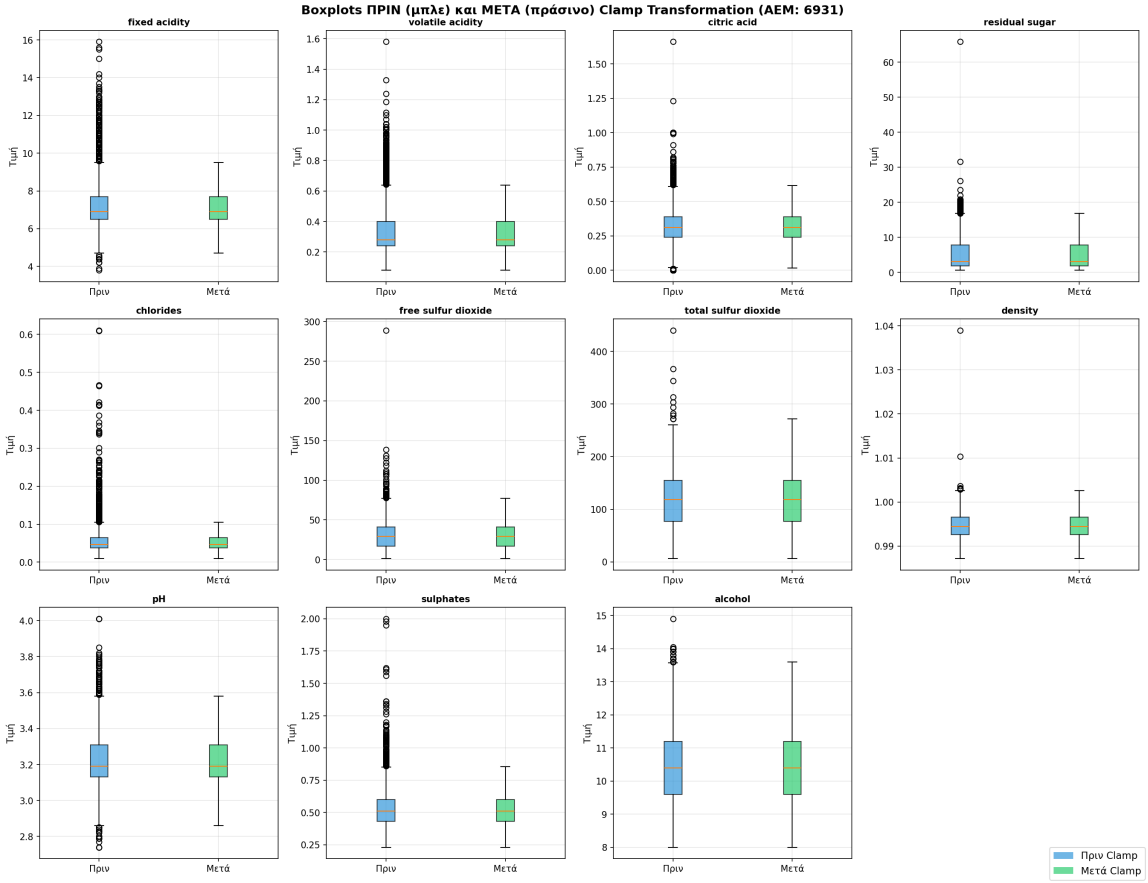

Σχήμα 5: Σύγκριση boxplots πριν (μπλε) και μετά (πράσινο) τον Clamp μετασχηματισμό

Σχολιασμός:

- Μετά το Clamp, τα μουστάκια τερματίζουν ακριβώς στα όρια IQR
- Οι κατανομές γίνονται πιο ομοιόμορφες, χωρίς ακραία σημεία
- Οι μεταβλητές με τη μεγαλύτερη αλλαγή (πολλά outliers) είναι: citric acid (327), volatile acidity (308), fixed acidity (270), chlorides (232) και quality (188)
- Οι μεταβλητές density (7), total sulfur dioxide (10) και alcohol (29) επηρεάστηκαν ελάχιστα

3.7 Συμπεράσματα Ερωτήματος 3

1. Η μέθοδος **IQR** εντόπισε 1.793 ακραίες τιμές σε 12 μεταβλητές
2. Η μέθοδος **Z-Score** (threshold 3.5) εντόπισε μόλις 271, επιβεβαιώνοντας τον πιο συντηρητικό χαρακτήρα της
3. Ο **Clamp μετασχηματισμός** εφαρμόστηκε βάσει IQR, αντικαθιστώντας τις ακραίες τιμές με τα όρια
4. Το μετασχηματισμένο dataset αποθηκεύτηκε στο αρχείο `transformed_wine_data_AEM_6931.csv`
5. Η επιλογή μεταξύ IQR και Z-Score εξαρτάται από το πλαίσιο: η IQR είναι καταλληλότερη για ασύμμετρες κατανομές, η Z-Score για κανονικές

4 Ερώτημα 4: Οπτική Παρουσίαση και Περιγραφικά Στατιστικά

Σε αυτό το ερώτημα παρουσιάζουμε το τελικό "καθαρό" σύνολο δεδομένων (μετά τον Clamp μετασχηματισμό) με οπτικοποιήσεις και περιγραφικά στατιστικά.

4.1 Περιγραφικά Στατιστικά - Συνεχείς Μεταβλητές

Ο παρακάτω πίνακας παρουσιάζει τα βασικά περιγραφικά στατιστικά για τις 11 συνεχείς μεταβλητές του dataset:

Πίνακας 1: Περιγραφικά Στατιστικά Συνεχών Μεταβλητών (N = 5.274)

Μεταβλητή	N	Missing	Μέση Τιμή	Διάμεσος	Τυπ. Απόκλ.	Min	Max
fixed acidity	5274	0	7.12	6.90	1.00	4.70	9.50
volatile acidity	5274	0	0.33	0.28	0.14	0.08	0.64
citric acid	5274	0	0.31	0.31	0.13	0.02	0.62
residual sugar	5274	0	5.25	3.00	4.44	0.60	16.80
chlorides	5274	0	0.053	0.047	0.021	0.009	0.106
free sulfur dioxide	5274	0	30.20	29.00	16.76	1.00	77.00
total sulfur dioxide	5274	0	115.52	118.00	55.75	6.00	271.81
density	5274	0	0.9946	0.9944	0.0028	0.9871	1.0026
pH	5274	0	3.22	3.19	0.15	2.86	3.58
sulphates	5274	0	0.53	0.51	0.13	0.23	0.86
alcohol	5274	0	10.49	10.40	1.11	8.00	13.60

Πίνακας 2: Επιπλέον Στατιστικά Συνεχών Μεταβλητών

Μεταβλητή	Q1 (25%)	Q3 (75%)	IQR	Εύρος	Ασυμμετρία	Cardinality
fixed acidity	6.50	7.70	1.20	4.80	0.63	53
volatile acidity	0.24	0.40	0.16	0.56	0.89	105
citric acid	0.24	0.39	0.15	0.60	-0.05	62
residual sugar	1.80	7.80	6.00	16.20	1.10	248
chlorides	0.038	0.065	0.027	0.097	0.95	95
free sulfur dioxide	17.00	41.00	24.00	76.00	0.51	98
total sulfur dioxide	77.13	155.00	77.88	265.81	-0.04	262
density	0.9926	0.9966	0.0040	0.0155	0.04	931
pH	3.13	3.31	0.18	0.72	0.24	74
sulphates	0.43	0.60	0.17	0.63	0.63	63
alcohol	9.60	11.20	1.60	5.60	0.62	95

Παρατηρήσεις:

- **Δεν υπάρχουν missing values** σε καμία μεταβλητή (μετά τον καθαρισμό)
- **Υψηλή ασυμμετρία** (Skewness > 0.5) παρατηρείται στα: residual sugar (1.10), volatile acidity (0.89), chlorides (0.95)
- **Υψηλό cardinality** έχει η density (931 μοναδικές τιμές), ενώ χαμηλό cardinality έχει η fixed acidity (53)
- Οι τιμές είναι περιορισμένες στα όρια του Clamp (βλ. min/max)

4.2 Περιγραφικά Στατιστικά - Κατηγορικές Μεταβλητές

Πίνακας 3: Περιγραφικά Στατιστικά Κατηγορικών Μεταβλητών

Μεταβλητή	**N**	**Missing**	**Cardinality**	**Mode**	**Συχν. Mode**	**%**
wine_type	5274	0	2	white	3924	74.4%
quality	5274	0	7	6	2299	43.6%

Κατανομή Wine Type:

- **Λευκά κρασιά:** 3.924 (74.4%)
- **Κόκκινα κρασιά:** 1.350 (25.6%)

Κατανομή Quality:

- Score 3: 28 (0.5%)
- Score 4: 184 (3.5%)
- Score 5: 1.751 (33.2%)
- Score 6: 2.299 (43.6%) – *Πιθανότερη τιμή*
- Score 7: 852 (16.2%)
- Score 8: 157 (3.0%)
- Score 9: 3 (0.06%)

4.3 Boxplots Τελικού Dataset

Τα boxplots απεικονίζουν την κατανομή κάθε συνεχούς μεταβλητής, ξεχωριστά για κόκκινο και λευκό κρασί:

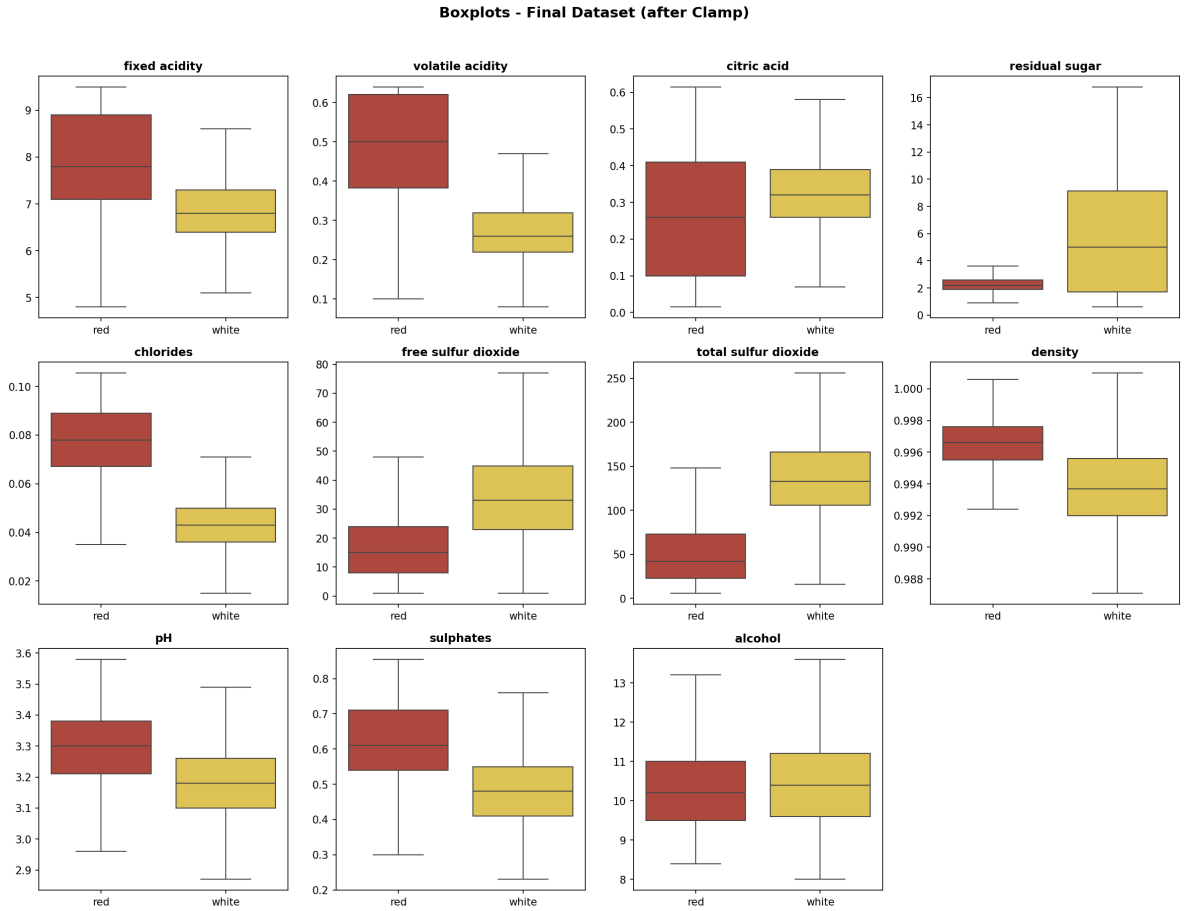

Σχήμα 6: Boxplots Συνεχών Μεταβλητών - Τελικό Dataset (μετά Clamp)

Παρατηρήσεις:

- Μετά τον Clamp μετασχηματισμό, τα boxplots **δεν εμφανίζουν outliers** (οι ακραίες τιμές έχουν αντικατασταθεί)
- Οι διαφορές μεταξύ κόκκινων και λευκών κρασιών είναι εμφανείς, ιδιαίτερα στα: volatile acidity, total sulfur dioxide, density

4.4 Histograms με Κατανομές Πυκνότητας

Τα histograms με καμπύλη KDE (Kernel Density Estimation) δείχνουν την πυκνότητα κατανομής κάθε μεταβλητής:

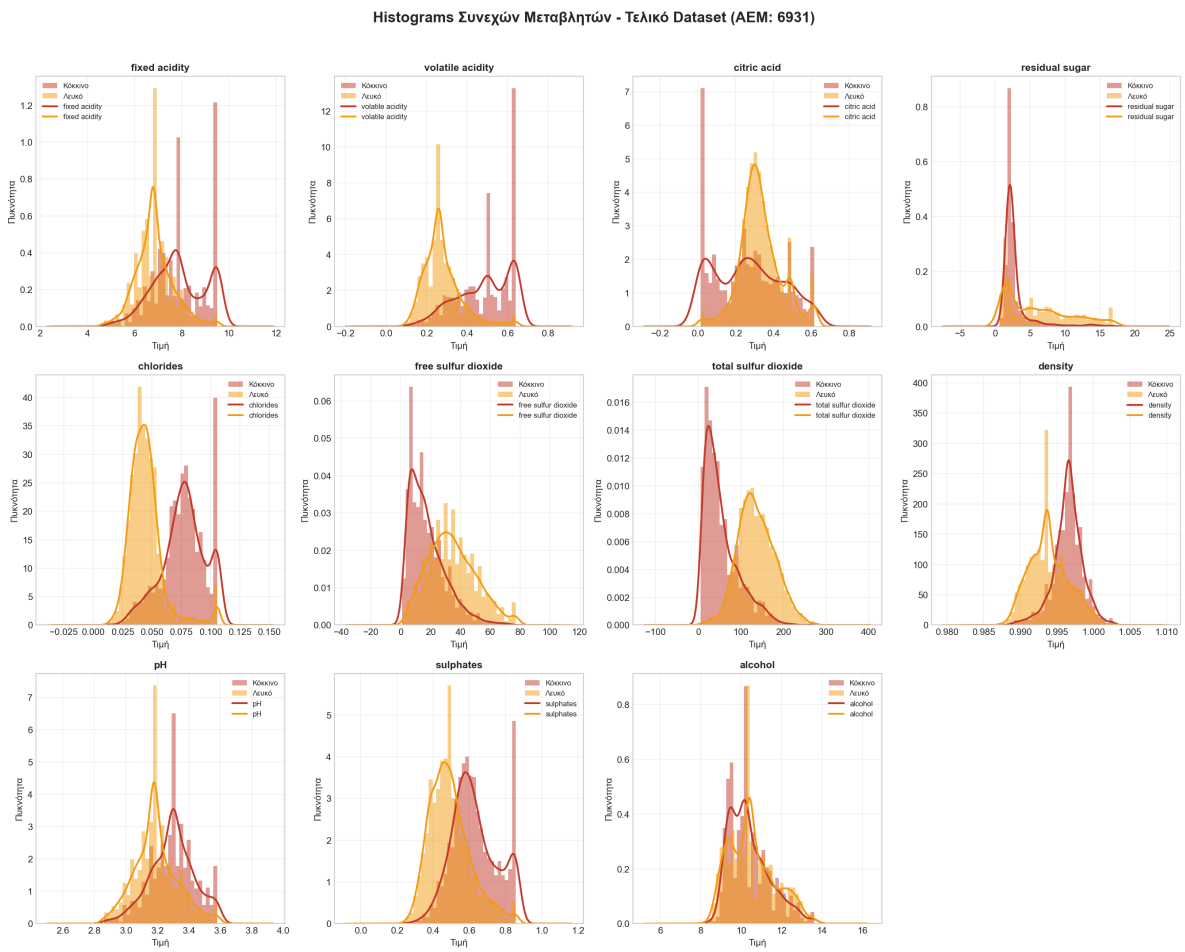

Σχήμα 7: Histograms με Καμπύλη Πυκνότητας (KDE) ανά Τύπο Κρασιού

Παρατηρήσεις:

- Τα **λευκά κρασιά** (κίτρινο) κυριαρχούν ποσοτικά σε κάθε σχήμα
- Ορισμένες μεταβλητές έχουν **διαφορετική κατανομή** μεταξύ τύπων κρασιού:
  - **Volatile acidity:** Τα κόκκινα έχουν υψηλότερες τιμές
  - **Total sulfur dioxide:** Τα λευκά έχουν πολύ υψηλότερες τιμές
  - **Residual sugar:** Τα λευκά έχουν ευρύτερο εύρος
- Μεταβλητές με σχεδόν **κανονική κατανομή**: pH, density
- Μεταβλητές με **θετική ασυμμετρία**: residual sugar, chlorides

4.5 Correlation Heatmap (Πίνακας Συσχετίσεων)

Ο πίνακας συσχετίσεων (correlation matrix) αποκαλύπτει τις γραμμικές σχέσεις μεταξύ των μεταβλητών:

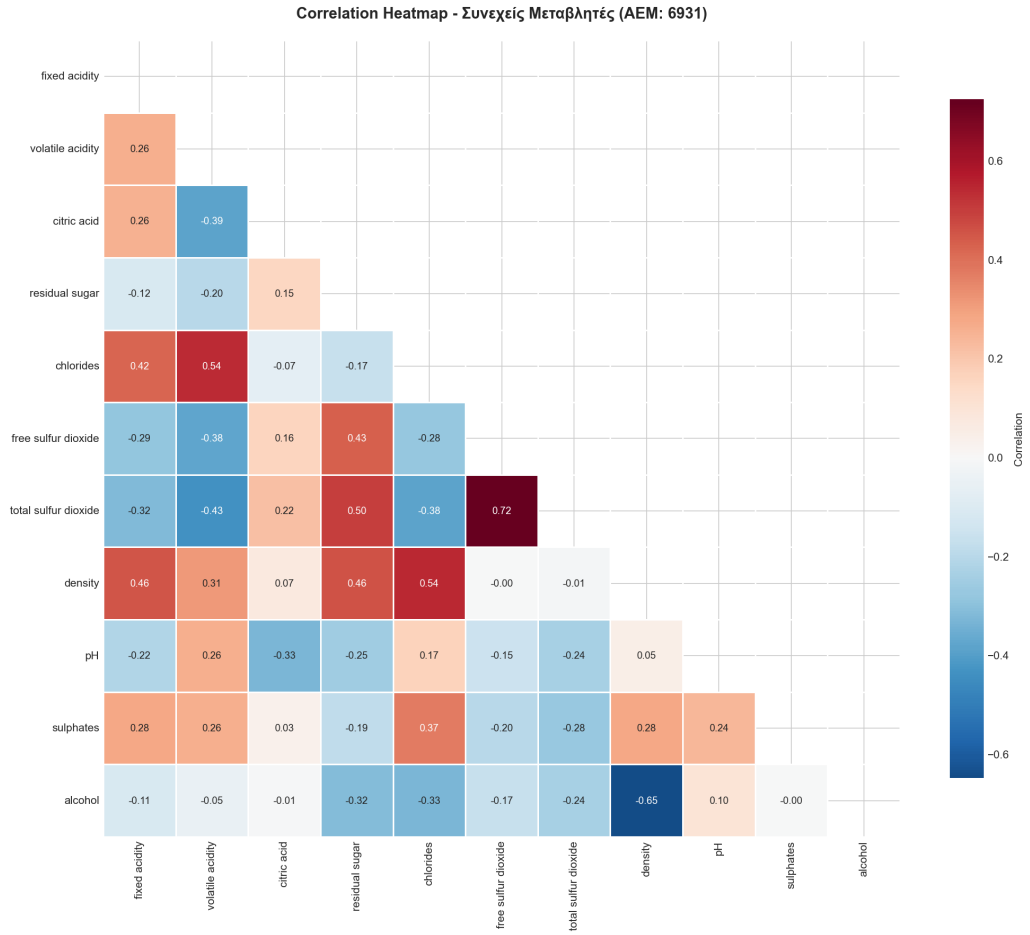

Σχήμα 8: Correlation Heatmap - Συντελεστές Pearson μεταξύ Συνεχών Μεταβλητών

Ισχυρές Συσχετίσεις ($|r| > 0.5$):

Πίνακας 4: Ισχυρές Συσχετίσεις μεταξύ Μεταβλητών

Μεταβλητή 1	**Μεταβλητή 2**	**r**	**Ερμηνεία**
free SO_2	total SO_2	+0.72	Θετική (αναμενόμενη)
density	alcohol	-0.65	Αρνητική (φυσική σχέση)
chlorides	density	+0.54	Θετική
volatile acidity	chlorides	+0.54	Θετική
residual sugar	total SO_2	+0.50	Θετική

Ερμηνεία:

- Η ισχυρότερη θετική συσχέτιση είναι μεταξύ **free και total SO_2** ($r = 0.72$), πράγμα λογικό αφού το ελεύθερο SO_2 αποτελεί μέρος του συνολικού
- Η ισχυρότερη αρνητική συσχέτιση είναι μεταξύ **density και alcohol** ($r = -0.65$): τα κρασιά με υψηλότερο αλκοόλ έχουν χαμηλότερη πυκνότητα (το αλκοόλ είναι ελαφρύτερο από το νερό)
- Η συσχέτιση **volatile acidity - chlorides** ($r = 0.54$) μπορεί να σχετίζεται με διαδικασίες ζύμωσης

4.6 Scatter Plots Ισχυρών Συσχετίσεων

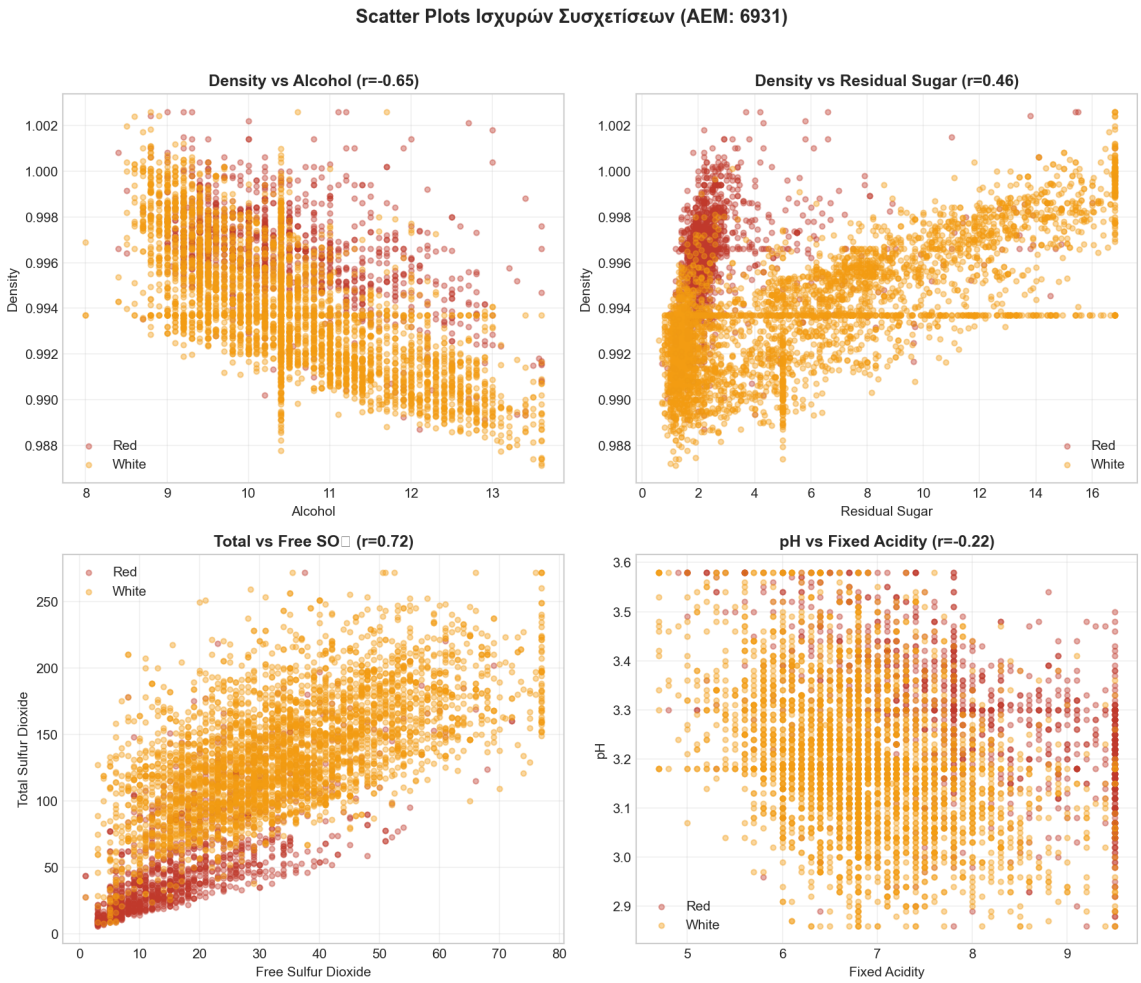

Σχήμα 9: Scatter Plots των Ζευγαριών με τις Ισχυρότερες Συσχετίσεις

Τα scatter plots επιβεβαιώνουν οπτικά τις συσχετίσεις:

- **Density vs Alcohol:** Σαφής αρνητική γραμμική τάση
- **Density vs Residual Sugar:** Θετική τάση, ιδιαίτερα έντονη στα λευκά κρασιά
- **Total vs Free SO_2:** Ισχυρή θετική γραμμική σχέση
- **pH vs Fixed Acidity:** Αρνητική τάση (υψηλή οξύτητα → χαμηλό pH)

4.7 Violin Plots

Τα violin plots συνδυάζουν την πληροφορία του boxplot με την κατανομή πυκνότητας:

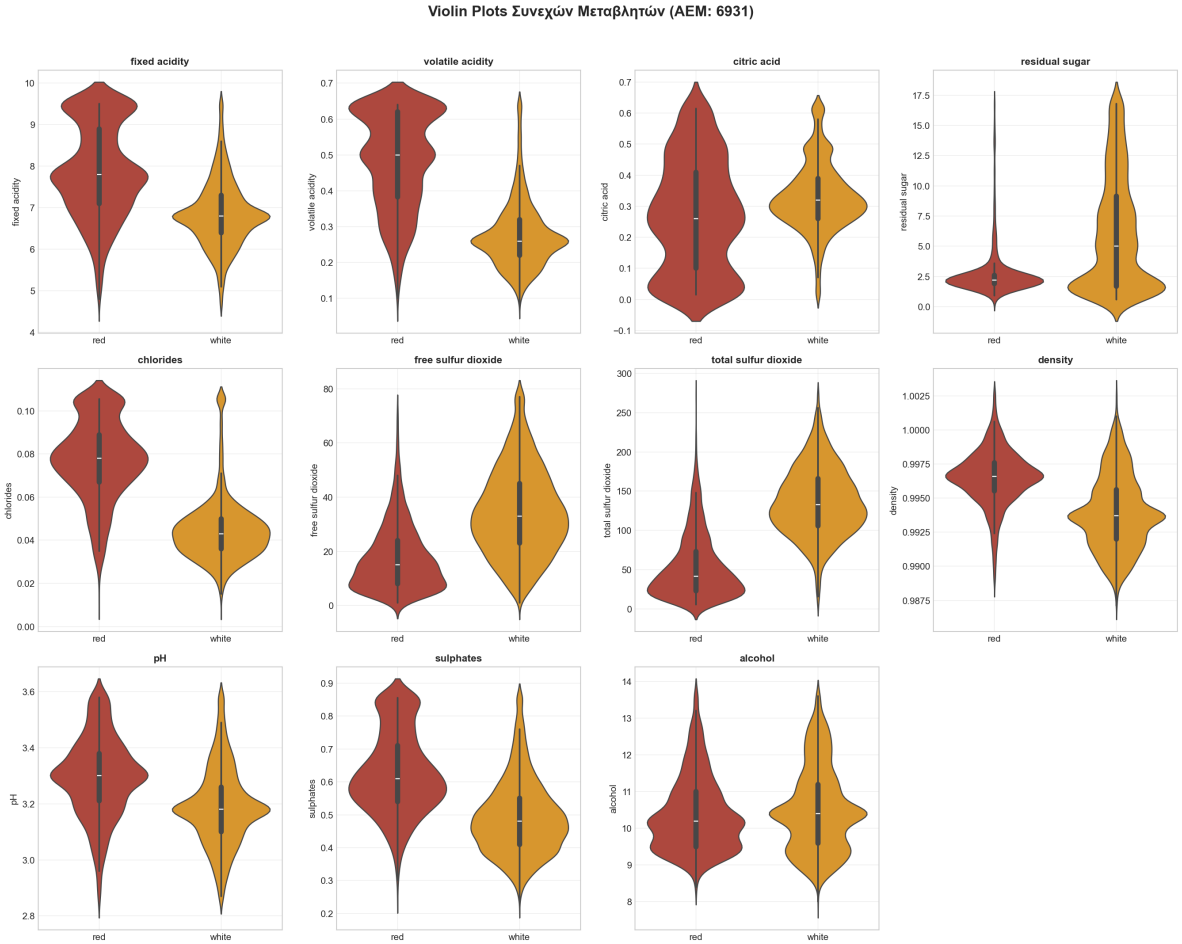

Σχήμα 10: Violin Plots - Κατανομή και Πυκνότητα ανά Τύπο Κρασιού

4.8 Συνοπτικό Dashboard

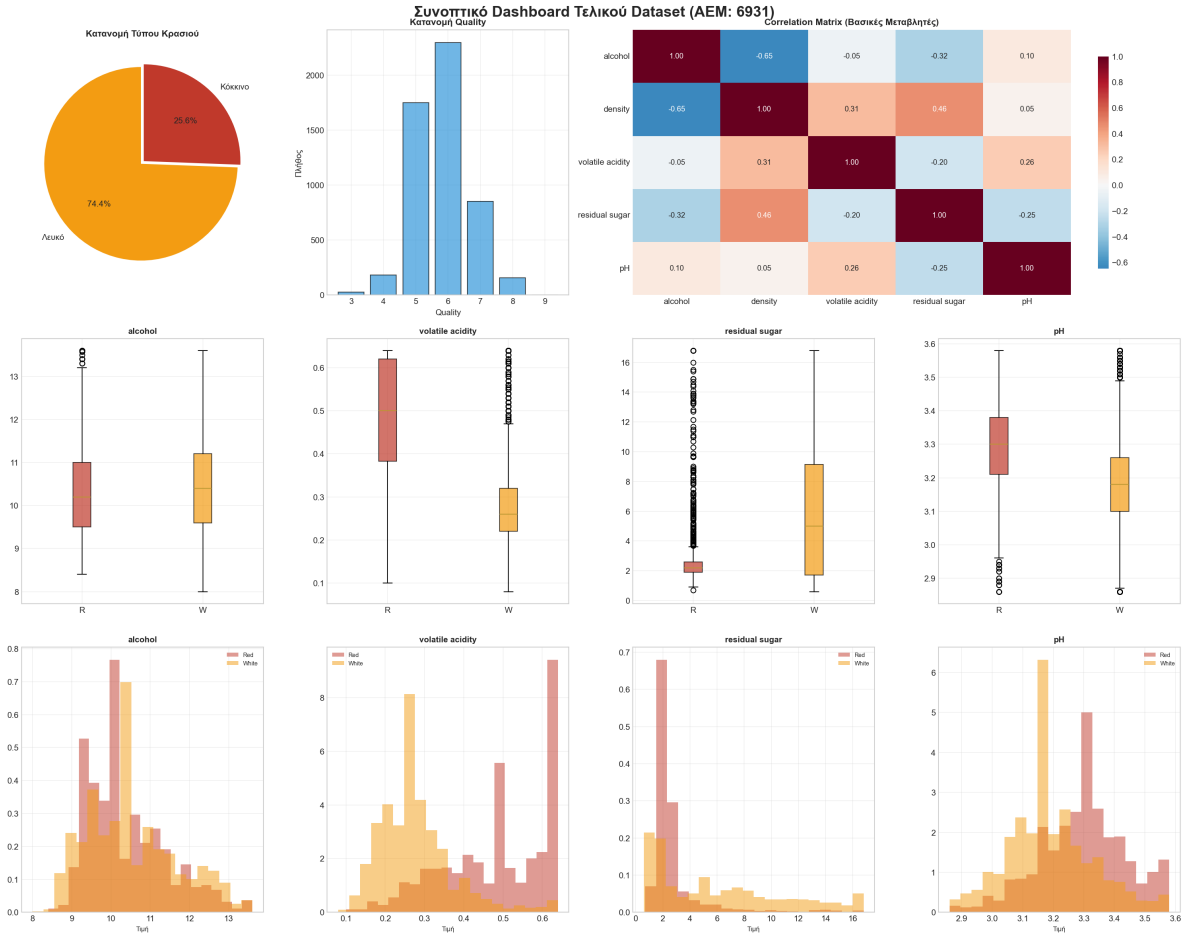

Σχήμα 11: Συνοπτικό Dashboard του Τελικού Dataset

4.9 Συμπεράσματα Ερωτήματος 4

1. Το τελικό dataset περιλαμβάνει **5.274 εγγραφές** και **13 μεταβλητές** (11 συνεχείς + 2 κατηγορικές)

2. Τα **λευκά κρασιά αποτελούν το 74.4%** του δείγματος, τα κόκκινα το 25.6%

3. Η πιθανότερη βαθμολογία ποιότητας είναι **6** (43.6% των κρασιών)

4. Οι πιο ισχυρές συσχετίσεις είναι:

   - Free SO_2 ↔ Total SO_2 (θετική, $r = 0.72$)
   - Density ↔ Alcohol (αρνητική, $r = -0.65$)

5. Οι κατανομές είναι **χωρίς outliers** μετά τον Clamp μετασχηματισμό

6. Υπάρχουν σαφείς **διαφορές μεταξύ κόκκινων και λευκών κρασιών** σε πολλές μεταβλητές, ιδιαίτερα στα: volatile acidity, total sulfur dioxide, residual sugar

Α′ Πλήρης Κώδικας Python

Α′.1 Κώδικας Ερωτήματος Α: Δειγματοληψία και Καθαρισμός

```
import pandas as pd
import numpy as np

# Load data
df = pd.read_csv('Data␣Analysis_2026␣1st␣Case_Data.csv')

# Remove unnamed columns
unnamed = [c for c in df.columns if 'Unnamed' in c]
df = df.drop(columns=unnamed)

# Sample 80%
AEM = 6931
df = df.sample(frac=0.80, random_state=AEM)
df = df.reset_index(drop=True)
print(f"After␣sampling:␣{len(df)}␣rows")

# Fix wine_type typos
fixes = {
    'Redd␣':'red', 'r3d':'red',
    'WHITTE':'white', 'whit':'white', 'whate':'white',
    '999':np.nan, '9999':np.nan, '-999':np.nan, '?':np.nan
}
for wrong, correct in fixes.items():
    df.loc[df['wine_type']==wrong, 'wine_type'] = correct

# Convert numeric columns
num_cols = ['fixed␣acidity', 'volatile␣acidity',
            'citric␣acid', 'residual␣sugar', 'chlorides',
            'free␣sulfur␣dioxide', 'total␣sulfur␣dioxide',
            'density', 'pH', 'sulphates', 'alcohol', 'quality']

for col in num_cols:
    df[col] = pd.to_numeric(df[col], errors='coerce')

# Replace impossible values with NaN
limits = {
    'fixed␣acidity': (0, 20),
    'volatile␣acidity': (0, 5),
    'citric␣acid': (0, 3),
    'residual␣sugar': (0, 100),
    'chlorides': (0, 1),
    'free␣sulfur␣dioxide': (0, 300),
    'total␣sulfur␣dioxide': (0, 500),
    'density': (0.9, 1.1),
    'pH': (2, 5),
    'sulphates': (0, 3),
    'alcohol': (5, 20),
```

```
    'quality': (0, 10)
}

for col, (min_val, max_val) in limits.items():
    mask = (df[col] < min_val) | (df[col] > max_val)
    df.loc[mask, col] = np.nan

# Remove duplicates
df = df.drop_duplicates().reset_index(drop=True)
print(f"After removing duplicates: {len(df)} rows")

# Fill missing values with median by wine type
df['wine_type'].fillna(df['wine_type'].mode()[0], inplace=True)

for col in num_cols:
    for wine in ['red', 'white']:
        mask = (df['wine_type'] == wine) & (df[col].isna())
        median = df.loc[df['wine_type'] == wine, col].median()
        df.loc[mask, col] = median

# Verify no missing values
print(f"Missing values: {df.isna().sum().sum()}")
print(f"Final shape: {df.shape}")

# Save cleaned data
df.to_csv('cleaned_wine_data_AEM_6931.csv', index=False)
print("Saved to cleaned_wine_data_AEM_6931.csv")
```

A′.2 Κώδικας Ερωτήματος B: Boxplots και Κατανομή Quality

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.patches import Patch

# Load cleaned data
AEM = 6931
df = pd.read_csv(f'cleaned_wine_data_AEM_{AEM}.csv')

# Continuous variables (excluding quality - it's discrete)
continuous_vars = ['fixed acidity', 'volatile acidity', 'citric acid',
                   'residual sugar', 'chlorides', 'free sulfur dioxide',
                   'total sulfur dioxide', 'density', 'pH', 'sulphates',
                   'alcohol']

colors = {'all': '#3498db', 'red': '#e74c3c', 'white': '#f1c40f'}

```

```python
# ============================================================
# Boxplots for all data (11 continuous variables)
# ============================================================
fig, axes = plt.subplots(3, 4, figsize=(16, 12))
fig.suptitle('Boxplots Συνεχών Μεταβλητών - Σύνολο Δεδομένων AEM(: 6931)',
             fontsize=14, fontweight='bold')

for idx, var in enumerate(continuous_vars):
    row = idx // 4
    col = idx % 4
    ax = axes[row, col]

    bp = ax.boxplot(df[var].dropna(), patch_artist=True)
    bp['boxes'][0].set_facecolor(colors['all'])
    bp['boxes'][0].set_alpha(0.7)

    ax.set_title(var, fontsize=10, fontweight='bold')
    ax.set_ylabel('Τιμή')
    ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.savefig('boxplots_all_data.png', dpi=150, bbox_inches='tight')
plt.close()

# ============================================================
# Quality Distribution (Discrete Variable)
# ============================================================
fig, axes = plt.subplots(1, 2, figsize=(14, 5))
fig.suptitle('Κατανομή Quality Διακριτή( Μεταβλητή) - AEM: 6931',
             fontsize=14, fontweight='bold')

# Overall distribution
quality_counts = df['quality'].value_counts().sort_index()
axes[0].bar(quality_counts.index, quality_counts.values, color=colors['all'],
            alpha=0.7, edgecolor='black')
axes[0].set_title('Συνολική Κατανομή', fontweight='bold')
axes[0].set_xlabel('Quality Score')
axes[0].set_ylabel('Συχνότητα')
axes[0].grid(True, alpha=0.3, axis='y')

# Distribution by wine type
quality_red = df[df['wine_type'] == 'red']['quality'].value_counts().sort_index()
quality_white = df[df['wine_type'] == 'white']['quality'].value_counts().sort_index()

x = np.arange(len(quality_counts.index))
width = 0.35

```

```python
axes[1].bar(x - width/2, [quality_red.get(i, 0) for i in quality_counts.index],
            width, label='Κόκκινο', color=colors['red'], alpha=0.7, edgecolor='black')
axes[1].bar(x + width/2, [quality_white.get(i, 0) for i in quality_counts.index],
            width, label='Λευκό', color=colors['white'], alpha=0.7, edgecolor='black')
axes[1].set_title('Σύγκριση: Κόκκινο vs Λευκό', fontweight='bold')
axes[1].set_xlabel('Quality Score')
axes[1].set_ylabel('Συχνότητα')
axes[1].set_xticks(x)
axes[1].set_xticklabels(quality_counts.index)
axes[1].legend()
axes[1].grid(True, alpha=0.3, axis='y')

plt.tight_layout()
plt.savefig('quality_distribution.png', dpi=150, bbox_inches='tight')
plt.close()

# ============================================================
# Boxplots by Wine Type
# ============================================================
df_red = df[df['wine_type'] == 'red']
df_white = df[df['wine_type'] == 'white']

fig, axes = plt.subplots(3, 4, figsize=(18, 12))
fig.suptitle('Boxplots Συνεχών Μεταβλητών - Σύγκριση Κόκκινου vs Λευκού AEM(: 6931)',
             fontsize=14, fontweight='bold')

for idx, var in enumerate(continuous_vars):
    row = idx // 4
    col = idx % 4
    ax = axes[row, col]

    data_to_plot = [df_red[var].dropna(), df_white[var].dropna()]
    bp = ax.boxplot(data_to_plot, patch_artist=True, labels=['Κόκκινο', 'Λευκό'])

    bp['boxes'][0].set_facecolor(colors['red'])
    bp['boxes'][1].set_facecolor(colors['white'])
    for box in bp['boxes']:
        box.set_alpha(0.7)

    ax.set_title(var, fontsize=10, fontweight='bold')
    ax.set_ylabel('Τιμή')
    ax.grid(True, alpha=0.3)

legend_elements = [Patch(facecolor=colors['red'], alpha=0.7, label='Κόκκινο'),
```

```
                    Patch(facecolor=colors['white'], alpha=0.7, label=
                        'Λευκό')]
fig.legend(handles=legend_elements, loc='lower␣right', fontsize=11)

plt.tight_layout()
plt.savefig('boxplots_by_wine_type.png', dpi=150, bbox_inches='tight'
    )
plt.close()

print('Saved:␣boxplots_all_data.png')
print('Saved:␣quality_distribution.png')
print('Saved:␣boxplots_by_wine_type.png')
```

A′.3 Κώδικας Ερωτήματος Γ: Εντοπισμός Ακραίων Τιμών και Clamp Transformation

```
import pandas as pd
import matplotlib.pyplot as plt
from matplotlib.patches import Patch

# Load cleaned data
AEM = 6931
df = pd.read_csv(f'cleaned_wine_data_AEM_{AEM}.csv')

continuous_vars = ['fixed␣acidity', 'volatile␣acidity', 'citric␣acid'
    ,
                    'residual␣sugar', 'chlorides', 'free␣sulfur␣
                        dioxide',
                    'total␣sulfur␣dioxide', 'density', 'pH', '
                        sulphates',
                    'alcohol', 'quality']

# Copy for transformation
df_transformed = df.copy()

# ============================================================
# IQR Method
# ============================================================
iqr_outliers = {}
iqr_bounds = {}

for var in continuous_vars:
    Q1 = df[var].quantile(0.25)
    Q3 = df[var].quantile(0.75)
    IQR = Q3 - Q1

    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    outliers_mask = (df[var] < lower_bound) | (df[var] > upper_bound)
```

```python
    n_outliers = outliers_mask.sum()

    iqr_outliers[var] = n_outliers
    iqr_bounds[var] = (lower_bound, upper_bound)

    print(f"{var}: {n_outliers} outliers "
          f"[{lower_bound:.4f}, {upper_bound:.4f}]")

print(f"Total IQR outliers: {sum(iqr_outliers.values())}")

# ============================================================
# Z-Score Method (threshold = 3.5)
# ============================================================
zscore_outliers = {}
z_threshold = 3.5

for var in continuous_vars:
    mean = df[var].mean()
    std = df[var].std()

    lower_bound = mean - z_threshold * std
    upper_bound = mean + z_threshold * std

    outliers_mask = (df[var] < lower_bound) | (df[var] > upper_bound)
    n_outliers = outliers_mask.sum()

    zscore_outliers[var] = n_outliers

    print(f"{var}: {n_outliers} outliers "
          f"[{lower_bound:.4f}, {upper_bound:.4f}]")

print(f"Total Z-score outliers: {sum(zscore_outliers.values())}")

# ============================================================
# Clamp Transformation (based on IQR bounds)
# ============================================================
for var in continuous_vars:
    lower_bound, upper_bound = iqr_bounds[var]
    df_transformed[var] = df_transformed[var].clip(
        lower=lower_bound, upper=upper_bound)

# ============================================================
# Boxplots Before and After Clamp
# ============================================================
fig, axes = plt.subplots(3, 4, figsize=(18, 14))
fig.suptitle('Boxplots BEFORE (blue) and AFTER (green) '
             'Clamp Transformation (AEM: 6931)',
             fontsize=14, fontweight='bold')

for idx, var in enumerate(continuous_vars):
    row = idx // 4
```

```
    col = idx % 4
    ax = axes[row, col]

    data_before = df[var].dropna()
    data_after = df_transformed[var].dropna()

    bp = ax.boxplot([data_before, data_after],
                    patch_artist=True,
                    labels=['Before', 'After'])

    bp['boxes'][0].set_facecolor('#3498db')
    bp['boxes'][1].set_facecolor('#2ecc71')
    for box in bp['boxes']:
        box.set_alpha(0.7)

    ax.set_title(var, fontsize=10, fontweight='bold')
    ax.set_ylabel('Value')
    ax.grid(True, alpha=0.3)

legend_elements = [
    Patch(facecolor='#3498db', alpha=0.7, label='Before␣Clamp'),
    Patch(facecolor='#2ecc71', alpha=0.7, label='After␣Clamp')]
fig.legend(handles=legend_elements, loc='lower␣right',
           fontsize=11)

plt.tight_layout()
plt.savefig('boxplots_before_after_clamp.png',
            dpi=150, bbox_inches='tight')
plt.close()

# Save transformed data
output_file = f'transformed_wine_data_AEM_{AEM}.csv'
df_transformed.to_csv(output_file, index=False)
print(f'Saved:␣{output_file}')
```

Α′.4 Κώδικας Ερωτήματος Δ: Οπτική Παρουσίαση και Περιγραφικά Στατιστικά

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

# Load transformed data
AEM = 6931
df = pd.read_csv(f'transformed_wine_data_AEM_{AEM}.csv')

# Define variables
continuous_vars = ['fixed␣acidity', 'volatile␣acidity', 'citric␣acid'
    ,
```

```
                    'residual␣sugar', 'chlorides', 'free␣sulfur␣dioxide',
                    'total␣sulfur␣dioxide', 'density', 'pH', 'sulphates',
                    'alcohol']
categorical_vars = ['wine_type', 'quality']
colors = {'red': '#c0392b', 'white': '#f39c12', 'all': '#3498db'}

# ============================================================
# 1. Descriptive Statistics - Continuous Variables
# ============================================================
continuous_stats = pd.DataFrame()
for var in continuous_vars:
    stats = {
        'Variable': var,
        'N': df[var].count(),
        'Missing': df[var].isna().sum(),
        'Mean': df[var].mean(),
        'Median': df[var].median(),
        'Std': df[var].std(),
        'Min': df[var].min(),
        'Max': df[var].max(),
        'Q1': df[var].quantile(0.25),
        'Q3': df[var].quantile(0.75),
        'IQR': df[var].quantile(0.75) - df[var].quantile(0.25),
        'Skewness': df[var].skew(),
        'Cardinality': df[var].nunique()
    }
    continuous_stats = pd.concat([continuous_stats,
                                  pd.DataFrame([stats])],
                                 ignore_index=True)
continuous_stats.to_csv('descriptive_stats_continuous.csv', index=False)

# ============================================================
# 2. Descriptive Statistics - Categorical Variables
# ============================================================
categorical_stats = pd.DataFrame()
for var in categorical_vars:
    value_counts = df[var].value_counts()
    stats = {
        'Variable': var,
        'N': df[var].count(),
        'Missing': df[var].isna().sum(),
        'Cardinality': df[var].nunique(),
        'Mode': df[var].mode()[0],
        'Mode_Freq': value_counts.iloc[0],
        'Mode_Pct': (value_counts.iloc[0] / len(df)) * 100
    }
    categorical_stats = pd.concat([categorical_stats,
                                   pd.DataFrame([stats])],
```

```
                                    ignore_index=True)
categorical_stats.to_csv('descriptive_stats_categorical.csv', index=
    False)

# ============================================================
# 3. Boxplots (Final Dataset)
# ============================================================
fig, axes = plt.subplots(3, 4, figsize=(18, 14))
fig.suptitle('Boxplots␣-␣Final␣Dataset␣(AEM:␣6931)',
             fontsize=16, fontweight='bold')
df_red = df[df['wine_type'] == 'red']
df_white = df[df['wine_type'] == 'white']

for idx, var in enumerate(continuous_vars):
    ax = axes[idx // 4, idx % 4]
    bp = ax.boxplot([df_red[var], df_white[var]],
                    patch_artist=True, labels=['Red', 'White'])
    bp['boxes'][0].set_facecolor(colors['red'])
    bp['boxes'][1].set_facecolor(colors['white'])
    ax.set_title(var, fontweight='bold')
    ax.grid(True, alpha=0.3)
axes[2, 3].axis('off')
plt.tight_layout()
plt.savefig('final_boxplots.png', dpi=150, bbox_inches='tight')
plt.close()

# ============================================================
# 4. Histograms with KDE
# ============================================================
fig, axes = plt.subplots(3, 4, figsize=(18, 14))
fig.suptitle('Histograms␣with␣KDE␣(AEM:␣6931)',
             fontsize=16, fontweight='bold')

for idx, var in enumerate(continuous_vars):
    ax = axes[idx // 4, idx % 4]
    ax.hist(df_red[var], bins=30, alpha=0.5, label='Red',
            color=colors['red'], density=True)
    ax.hist(df_white[var], bins=30, alpha=0.5, label='White',
            color=colors['white'], density=True)
    df_red[var].plot(kind='kde', ax=ax, color=colors['red'])
    df_white[var].plot(kind='kde', ax=ax, color=colors['white'])
    ax.set_title(var, fontweight='bold')
    ax.legend(fontsize=8)
    ax.grid(True, alpha=0.3)
axes[2, 3].axis('off')
plt.tight_layout()
plt.savefig('final_histograms.png', dpi=150, bbox_inches='tight')
plt.close()

# ============================================================
# 5. Correlation Heatmap
```

```python
# ============================================================
corr_matrix = df[continuous_vars].corr()
plt.figure(figsize=(14, 12))
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
sns.heatmap(corr_matrix, mask=mask, annot=True, fmt='.2f',
            cmap='RdBu_r', center=0, square=True,
            linewidths=0.5, cbar_kws={'shrink': 0.8})
plt.title('Correlation␣Heatmap␣(AEM:␣6931)',
          fontsize=14, fontweight='bold')
plt.tight_layout()
plt.savefig('correlation_heatmap.png', dpi=150, bbox_inches='tight')
plt.close()

# Print strong correlations
print("Strong␣Correlations␣(|r|␣>␣0.5):")
for i in range(len(corr_matrix.columns)):
    for j in range(i+1, len(corr_matrix.columns)):
        r = corr_matrix.iloc[i, j]
        if abs(r) > 0.5:
            print(f"␣␣{corr_matrix.columns[i]}␣<->␣"
                  f"{corr_matrix.columns[j]}:␣r␣=␣{r:.3f}")

# ============================================================
# 6. Violin Plots
# ============================================================
fig, axes = plt.subplots(3, 4, figsize=(18, 14))
fig.suptitle('Violin␣Plots␣(AEM:␣6931)',
             fontsize=16, fontweight='bold')

for idx, var in enumerate(continuous_vars):
    ax = axes[idx // 4, idx % 4]
    sns.violinplot(data=df, x='wine_type', y=var, ax=ax,
                   palette={'red': colors['red'],
                            'white': colors['white']},
                   inner='box')
    ax.set_title(var, fontweight='bold')
    ax.set_xlabel('')
    ax.grid(True, alpha=0.3)
axes[2, 3].axis('off')
plt.tight_layout()
plt.savefig('violin_plots.png', dpi=150, bbox_inches='tight')
plt.close()

print("All␣visualizations␣saved␣successfully!")
```