Ανάλυση Δεδομένων 2025-26

2η Εργασία: Ανάλυση Παλινδρόμησης

Πρόβλεψη Ποιότητας Κρασιού

Ρακοβαλής Παύλος
ΑΕΜ: 6931

23 Μαρτίου 2026

Περίληψη

Στην παρούσα εργασία διερευνάται κατά πόσο οι φυσικοχημικές ιδιότητες του κρασιού μπορούν να προβλέψουν τη βαθμολογία ποιότητάς του. Χρησιμοποιούνται 5.274 παρατηρήσεις (τυχαίο δείγμα βάσει ΑΕΜ 6931) με 11 συνεχείς μεταβλητές-προβλέπτες και μεταβλητή απόκρισης τη βαθμολογία ποιότητας (`quality`). Εφαρμόζονται μέθοδοι απλής και πολλαπλής γραμμικής παλινδρόμησης, πρόσω επιλογή μεταβλητών, πολυωνυμική παλινδρόμηση και διαγνωστικοί έλεγχοι. Το βέλτιστο γραμμικό μοντέλο εξηγεί περίπου το 27,7% της μεταβλητότητας, με σημαντικότερους προβλέπτες το αλκοόλ, την πτητική οξύτητα και τα θειικά. Ο διαγνωστικός έλεγχος αποκαλύπτει παραβιάσεις βασικών υποθέσεων, υποδεικνύοντας ότι εναλλακτικές μέθοδοι (τακτική λογιστική παλινδρόμηση, αλγόριθμοι μηχανικής μάθησης) θα ήταν καταλληλότερες.

Περιεχόμενα

1 Εισαγωγή **2**
1.1 Σκοπός 2
1.2 Δεδομένα 2

2 Απλή Γραμμική Παλινδρόμηση (Υποερώτημα 1) **2**
2.1 Μεθοδολογία 2
2.2 Αποτελέσματα 3

3 Πολλαπλή Γραμμική Παλινδρόμηση (Υποερώτημα 2) **4**
3.1 Μεθοδολογία 4
3.2 Αποτελέσματα 5

4 Πρόσω Επιλογή Μεταβλητών (Υποερώτημα 3) **5**
4.1 Μεθοδολογία 5

4.2 Αποτελέσματα 6

5 Πολυωνυμική Παλινδρόμηση (Υποερώτημα 4) 7
5.1 Μεθοδολογία 7
5.2 Αποτελέσματα 7

6 Κριτική Αξιολόγηση Μοντέλου (Υποερώτημα 5) 9
6.1 Διαγνωστικοί έλεγχοι 9
6.2 Πολυσυγγραμμικότητα (VIF) 10
6.3 Εντοπισμένα προβλήματα 10
6.4 Εναλλακτικές προσεγγίσεις 10

7 Συμπεράσματα 10

1 Εισαγωγή

1.1 Σκοπός

Σκοπός της εργασίας είναι η διερεύνηση της σχέσης μεταξύ των φυσικοχημικών χαρακτηριστικών του κρασιού και της βαθμολογίας ποιότητάς του, μέσω τεχνικών γραμμικής παλινδρόμησης.

1.2 Δεδομένα

Χρησιμοποιούνται τα καθαρισμένα δεδομένα της 1ης εργασίας:

- **Μεταβλητή απόκρισης** (Y): `quality` – ακέραιες τιμές 3–9
- **Προβλέπτες** ($X_1, \ldots, X_{11}$): fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulphates, alcohol
- **Παρατηρήσεις**: $n = 5.274$

2 Απλή Γραμμική Παλινδρόμηση (Υποερώτημα 1)

2.1 Μεθοδολογία

Προσαρμόστηκαν 11 μοντέλα απλής γραμμικής παλινδρόμησης της μορφής:

$$Y = \beta_0 + \beta_1 X_j + \varepsilon, \quad j = 1, \ldots, 11 \tag{1}$$

με τη μέθοδο ελαχίστων τετραγώνων (OLS). Για κάθε μοντέλο εκτιμήθηκαν οι συντελεστές $\hat{\beta}_0$, $\hat{\beta}_1$ και ελέγχθηκε η μηδενική υπόθεση $H_0 : \beta_1 = 0$ έναντι $H_1 : \beta_1 \neq 0$ σε επίπεδο σημαντικότητας $\alpha = 0.05$.

2.2 Αποτελέσματα

Πίνακας 1: Αποτελέσματα απλής γραμμικής παλινδρόμησης (ταξινομημένα κατά R^2)

Μεταβλητή	$\hat{\beta}_1$	**t-stat**	**p-value**	R^2	**Σημαντ.**
alcohol	$+0.343$	35.13	≈ 0	0.1897	Ναι
density	-94.21	-23.40	2.6×10^{-115}	0.0941	Ναι
volatile acidity	-1.386	-19.08	1.6×10^{-78}	0.0646	Ναι
chlorides	-5.078	-15.09	2.2×10^{-50}	0.0414	Ναι
citric acid	$+0.566$	6.86	7.5×10^{-12}	0.0089	Ναι
fixed acidity	-0.052	-5.24	1.7×10^{-7}	0.0052	Ναι
residual sugar	-0.010	-3.88	1.0×10^{-4}	0.0029	Ναι
total sulfur dioxide	-0.001	-3.79	1.5×10^{-4}	0.0027	Ναι
free sulfur dioxide	$+0.003$	3.79	1.6×10^{-4}	0.0027	Ναι
sulphates	$+0.253$	3.09	2.0×10^{-3}	0.0018	Ναι
pH	$+0.175$	2.19	2.8×10^{-2}	0.0009	Ναι

Η $H_0 : \beta_1 = 0$ **απορρίπτεται** και για τις 11 μεταβλητές ($p < 0.05$). Ο ισχυρότερος μεμονωμένος προβλέπτης είναι το αλκοόλ ($R^2 = 0.19$), ακολουθούμενο από την πυκνότητα ($R^2 = 0.09$) και την πτητική οξύτητα ($R^2 = 0.06$). Ωστόσο, κανένας μεμονωμένος προβλέπτης δεν εξηγεί ικανοποιητικό ποσοστό της μεταβλητότητας.

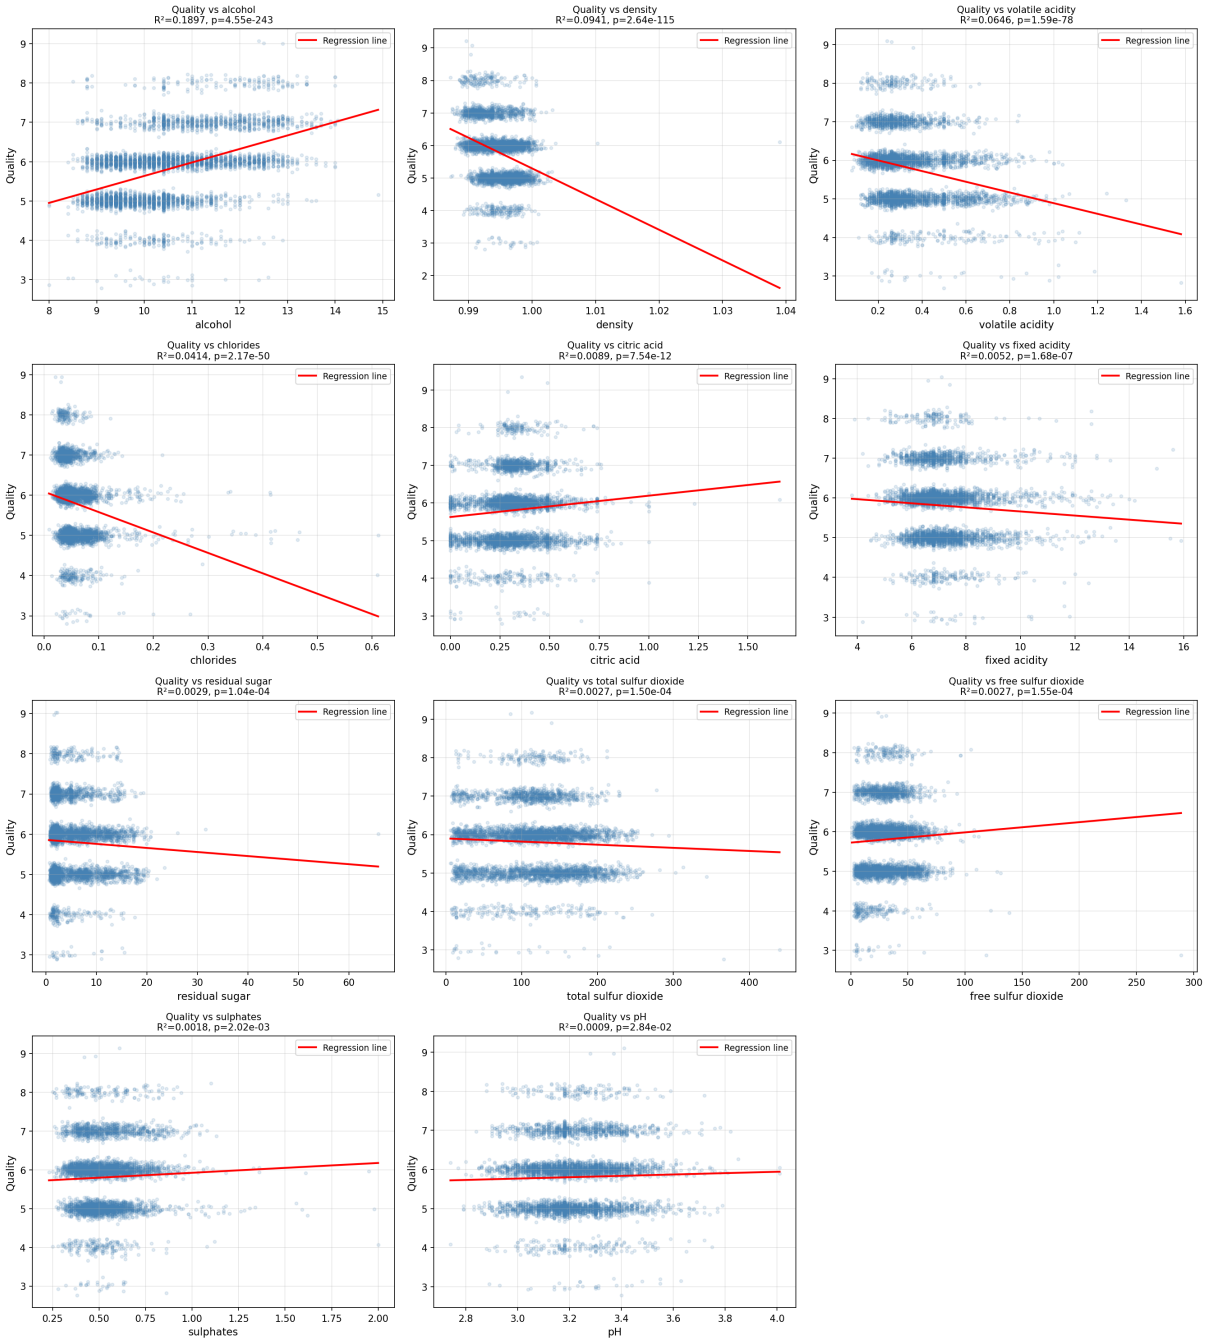

Σχήμα 1: Διαγράμματα διασποράς (με ευθεία παλινδρόμησης) για τους σημαντικούς μεμονωμένους προβλέπτες.

3 Πολλαπλή Γραμμική Παλινδρόμηση (Υποερώτημα 2)

3.1 Μεθοδολογία

Προσαρμόστηκε μοντέλο πολλαπλής γραμμικής παλινδρόμησης με όλες τις 11 μεταβλητές:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_{11} X_{11} + \varepsilon \tag{2}$$

Ελέγχθηκε πρώτα η συνολική σημαντικότητα μέσω F-ελέγχου ($H_0 : \beta_1 = \beta_2 = \cdots = \beta_{11} = 0$) και στη συνέχεια η σημαντικότητα κάθε μεταβλητής μέσω μερικού t-ελέγχου ($H_0 : \beta_j = 0$, $j = 1, \ldots, 11$).

3.2 Αποτελέσματα

Συνολική αξιολόγηση μοντέλου:

- $R^2 = 0.2771$, $R^2_{adj} = 0.2756$
- $F(11, 5262) = 183.41$, $p \approx 0 \Rightarrow$ απόρριψη H_0 – το μοντέλο είναι συνολικά σημαντικό
- $AIC = 11880.85$, $BIC = 11959.70$

Πίνακας 2: Συντελεστές πολλαπλής γραμμικής παλινδρόμησης

Μεταβλητή	$\hat{\beta}_j$	**SE**	**t-stat**	**p-value**	$H_0 : \beta_j = 0$
Σταθερά	44.231	8.847	5.00	5.9×10^{-7}	Απορρίπτεται
fixed acidity	0.042	0.014	3.03	2.5×10^{-3}	Απορρίπτεται
volatile acidity	−1.250	0.087	−14.39	4.4×10^{-46}	Απορρίπτεται
citric acid	0.131	0.088	1.49	1.4×10^{-1}	**Δεν απορρ.**
residual sugar	0.029	0.004	7.09	1.5×10^{-12}	Απορρίπτεται
chlorides	−1.354	0.369	−3.67	2.4×10^{-4}	Απορρίπτεται
free sulfur dioxide	0.007	0.001	8.26	1.8×10^{-16}	Απορρίπτεται
total sulfur dioxide	−0.003	0.0003	−9.84	1.2×10^{-22}	Απορρίπτεται
density	−43.092	9.006	−4.79	1.8×10^{-6}	Απορρίπτεται
pH	0.408	0.088	4.62	4.0×10^{-6}	Απορρίπτεται
sulphates	0.773	0.083	9.34	1.4×10^{-20}	Απορρίπτεται
alcohol	0.272	0.015	18.51	4.0×10^{-74}	Απορρίπτεται

Η $H_0 : \beta_j = 0$ απορρίπτεται για **10 από τις 11** μεταβλητές. Μοναδική εξαίρεση αποτελεί το citric acid ($p = 0.138$), η πληροφορία του οποίου αλληλοεπικαλύπτεται με τις υπόλοιπες μεταβλητές οξύτητας (πολυσυγγραμμικότητα). Αξίζει να σημειωθεί ότι στην απλή παλινδρόμηση η ίδια μεταβλητή ήταν στατιστικά σημαντική ($p = 7.5 \times 10^{-12}$).

Επιπλέον, η μεταβλητή residual sugar αλλάζει πρόσημο (από -0.010 στην απλή σε $+0.029$ στην πολλαπλή παλινδρόμηση), φαινόμενο γνωστό ως παράδοξο Simpson.

4 Πρόσω Επιλογή Μεταβλητών (Υποερώτημα 3)

4.1 Μεθοδολογία

Εφαρμόστηκε η μέθοδος πρόσω επιλογής (forward selection) με κριτήριο εισόδου $p < 0.05$. Σε κάθε βήμα, προστίθεται η μεταβλητή με τη μικρότερη p-value (δεδομένων των ήδη εισηγμένων), εφόσον αυτή πληροί το κριτήριο.

Η διαδικασία τερματίζεται όταν καμία εναπομείνασα μεταβλητή δεν είναι σημαντική.

4.2 Αποτελέσματα

Πίνακας 3: Βήματα πρόσω επιλογής μεταβλητών

Βήμα	**Μεταβλητή**	**p-value**	R^2_{adj}	ΔR^2_{adj}	**AIC**
1	alcohol	4.5×10^{-243}	0.1895	$+0.190$	12463
2	volatile acidity	1.1×10^{-79}	0.2425	$+0.053$	12108
3	sulphates	2.1×10^{-18}	0.2533	$+0.011$	12033
4	free sulfur dioxide	2.6×10^{-6}	0.2563	$+0.003$	12013
5	total sulfur dioxide	5.6×10^{-16}	0.2653	$+0.009$	11950
6	residual sugar	8.8×10^{-8}	0.2692	$+0.004$	11923
7	chlorides	6.7×10^{-6}	0.2718	$+0.003$	11905
8	density	6.0×10^{-3}	0.2727	$+0.001$	11899
9	pH	2.5×10^{-3}	0.2739	$+0.001$	11892
10	fixed acidity	3.7×10^{-4}	0.2755	$+0.002$	11881
11	citric acid (απόρριψη)	0.138	–	–	–

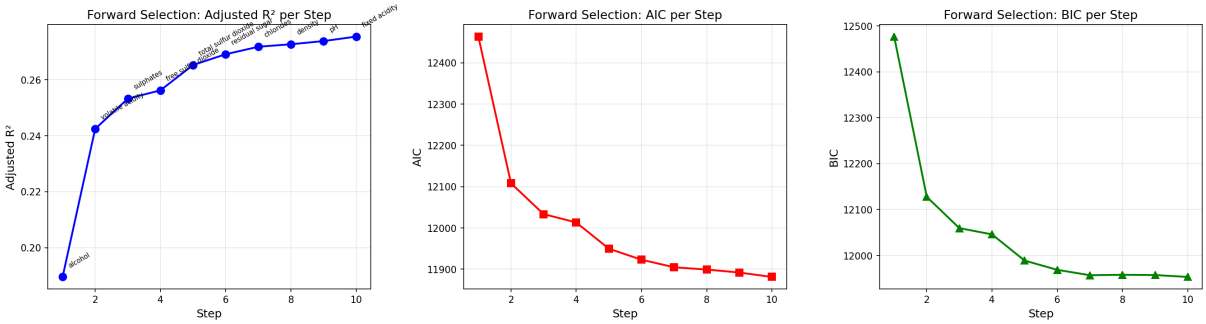

Σχήμα 2: Εξέλιξη R^2_{adj}, AIC και BIC κατά τα βήματα της πρόσω επιλογής.

Η πρόσω επιλογή επέλεξε **10 από τις 11** μεταβλητές, αποκλείοντας το citric acid – σε συμφωνία με τα αποτελέσματα του Υποερωτήματος 2. Το τελικό μοντέλο ($R^2_{adj} = 0.2755$) είναι ουσιαστικά ισοδύναμο με το πλήρες μοντέλο 11 μεταβλητών ($R^2_{adj} = 0.2756$).

Αξιοσημείωτη είναι η φθίνουσα οριακή απόδοση: οι 3 πρώτες μεταβλητές (alcohol, volatile acidity, sulphates) εξηγούν $R^2_{adj} = 0.253$, δηλαδή το 92% της ερμηνευτικής ικανότητας του πλήρους μοντέλου, ενώ οι υπόλοιπες 7 προσθέτουν μόλις $+0.022$.

5 Πολυωνυμική Παλινδρόμηση (Υποερώτημα 4)

5.1 Μεθοδολογία

Για τις μεταβλητές residual sugar, chlorides και alcohol προσαρμόστηκαν μοντέλα πολυωνυμικής παλινδρόμησης βαθμού 1, 2 και 3:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \varepsilon \tag{3}$$

Η σημαντικότητα των ανώτερων όρων (β_2, β_3) αξιολογήθηκε μέσω t-ελέγχων, ενώ η σύγκριση μοντέλων έγινε μέσω R^2_{adj}, AIC και BIC.

5.2 Αποτελέσματα

Πίνακας 4: Σύγκριση γραμμικών, τετραγωνικών και κυβικών μοντέλων

Μεταβλητή	**Μοντέλο**	R^2	R^2_{adj}	**AIC**	**p-value (ανωτ. όρος)**
residual sugar	Γραμμικό	0.0029	0.0027	13557	–
	Τετραγωνικό	0.0031	0.0027	13558	0.297 (ΜΣ)
	Κυβικό	0.0072	0.0066	13539	3.0×10^{-6}
chlorides	Γραμμικό	0.0414	0.0412	13350	–
	Τετραγωνικό	0.0583	0.0579	13258	3.9×10^{-22}
	Κυβικό	0.0708	0.0702	13190	4.9×10^{-17}
alcohol	Γραμμικό	0.1897	0.1895	12463	–
	Τετραγωνικό	0.1903	0.1900	12461	0.046
	Κυβικό	0.1947	0.1943	12434	6.6×10^{-8}

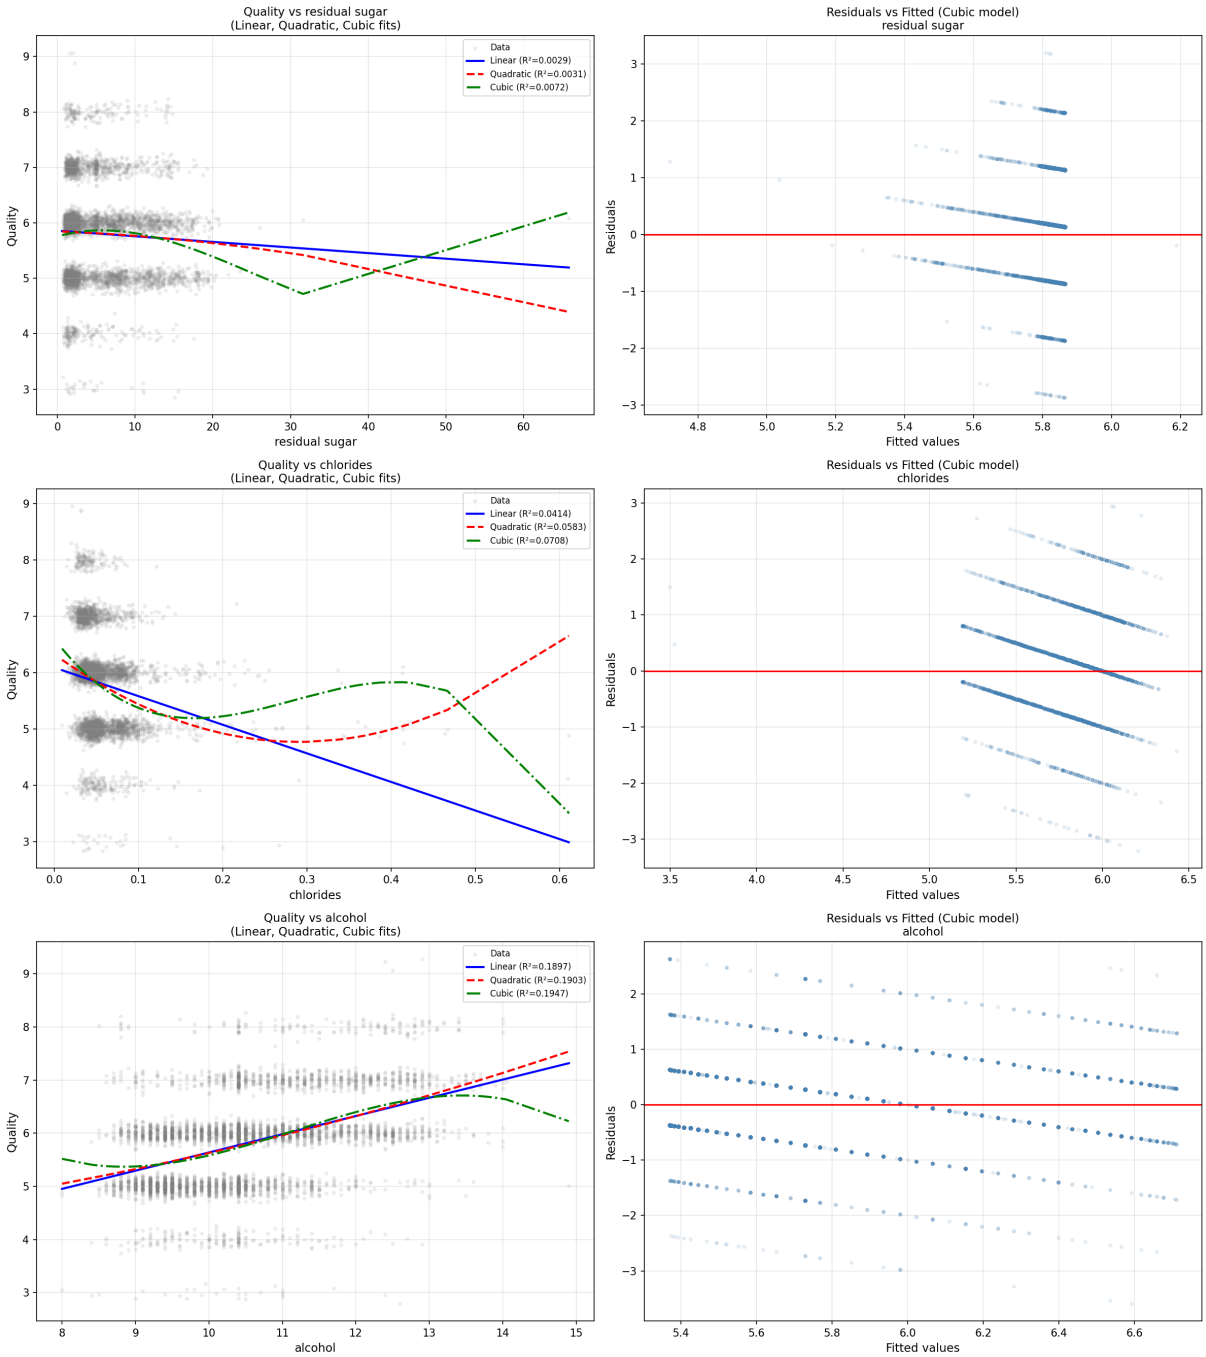

Σχήμα 3: Πολυωνυμική παλινδρόμηση: καμπύλες προσαρμογής (αριστερά) και υπόλοιπα (δεξιά).

Και οι τρεις μεταβλητές εμφανίζουν στατιστικά σημαντικές ενδείξεις μη γραμμικότητας. Τα chlorides παρουσιάζουν τη σαφέστερη μη γραμμική σχέση (τόσο β_2 όσο και β_3 σημαντικοί). Ωστόσο, η πρακτική βελτίωση σε R^2 είναι περιορισμένη σε όλες τις περιπτώσεις, υποδεικνύοντας ότι η μη γραμμικότητα δεν αποτελεί τον κύριο λόγο της χαμηλής ερμηνευτικής ικανότητας.

6 Κριτική Αξιολόγηση Μοντέλου (Υποερώτημα 5)

6.1 Διαγνωστικοί έλεγχοι

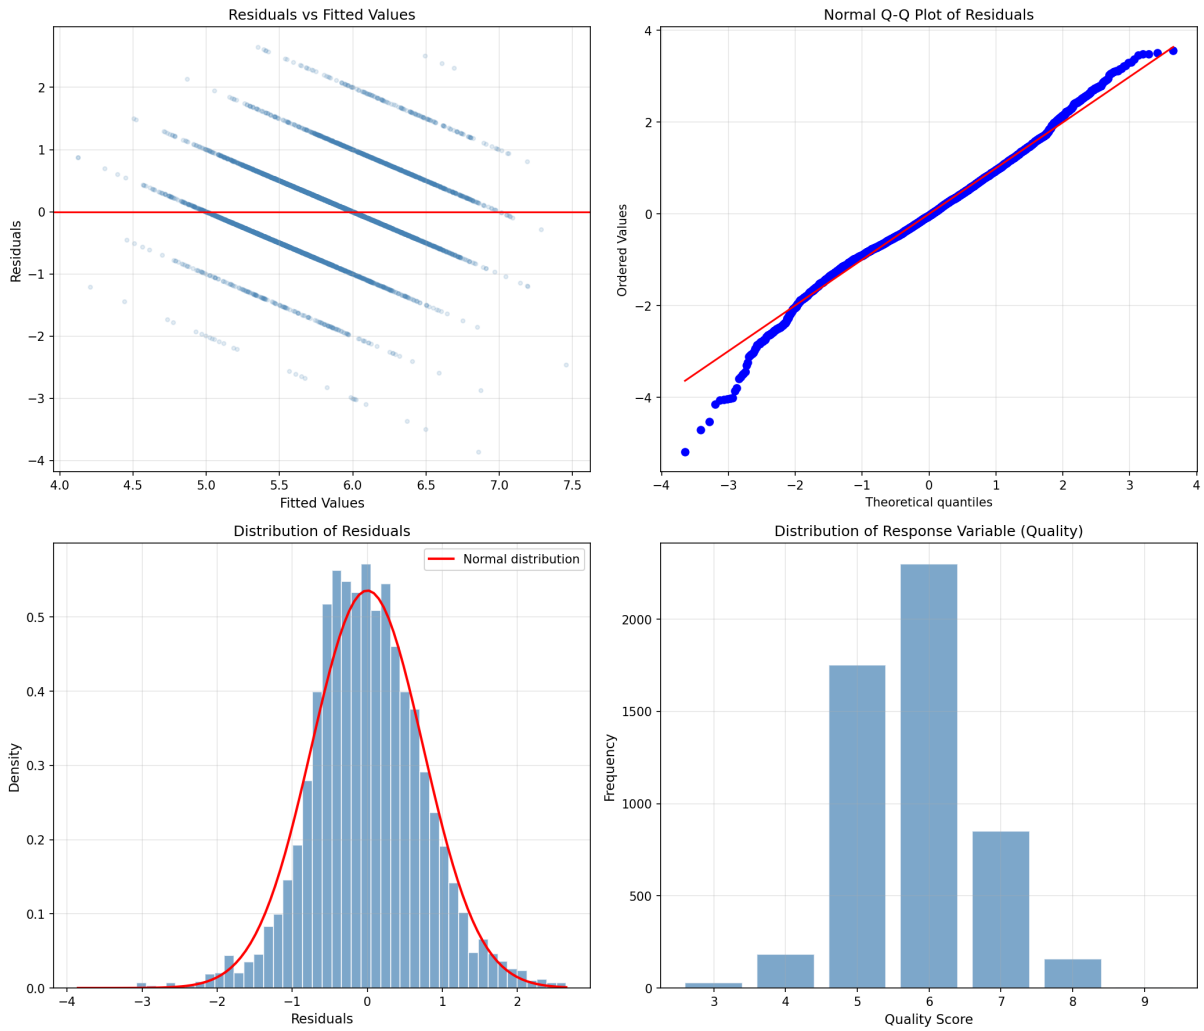

Σχήμα 4: Διαγνωστικά γραφήματα: (α) υπόλοιπα vs προβλεπόμενες τιμές, (β) Q-Q plot, (γ) κατανομή υπολοίπων, (δ) κατανομή μεταβλητής απόκρισης.

Πίνακας 5: Αποτελέσματα διαγνωστικών ελέγχων

Έλεγχος	**Στατιστική**	**p-value**	**Αποτέλεσμα**
Κανονικότητα (Jarque-Bera)	$JB = 222.07$	6.0×10^{-49}	Απορρίπτεται
Κανονικότητα (Shapiro-Wilk)	$W = 0.991$	4.4×10^{-17}	Απορρίπτεται
Ομοσκεδαστικότητα (Breusch-Pagan)	$BP = 75.01$	1.4×10^{-11}	Απορρίπτεται
Αυτοσυσχέτιση (Durbin-Watson)	$DW = 2.041$	–	Αποδεκτό

6.2 Πολυσυγγραμμικότητα (VIF)

Πίνακας 6: Παράγοντας πληθωρισμού διακύμανσης (VIF)

Μεταβλητή	**VIF**	**Αξιολόγηση**
fixed acidity	2.70	Αποδεκτό
volatile acidity	1.85	Αποδεκτό
citric acid	1.56	Αποδεκτό
residual sugar	3.38	Αποδεκτό
chlorides	1.59	Αποδεκτό
free sulfur dioxide	2.09	Αποδεκτό
total sulfur dioxide	2.79	Αποδεκτό
density	6.26	Μέτρια πολυσυγγρ.
pH	1.70	Αποδεκτό
sulphates	1.41	Αποδεκτό
alcohol	2.53	Αποδεκτό

6.3 Εντοπισμένα προβλήματα

1. **Διακριτή μεταβλητή απόκρισης**: Η `quality` λαμβάνει ακέραιες τιμές (3–9), παραβιάζοντας την υπόθεση συνεχούς απόκρισης. Αυτό δημιουργεί χαρακτηριστικές λωρίδες στα υπόλοιπα.
2. **Χαμηλή ερμηνευτική ικανότητα**: $R^2 \approx 27.7\%$ – το μοντέλο αφήνει ανεξήγητο το 72.3% της μεταβλητότητας.
3. **Μη κανονικά υπόλοιπα**: Οι έλεγχοι Shapiro-Wilk και Jarque-Bera απορρίπτουν κατηγορηματικά την υπόθεση κανονικότητας.
4. **Ετεροσκεδαστικότητα**: Ο έλεγχος Breusch-Pagan υποδεικνύει μη σταθερή διακύμανση σφαλμάτων.
5. **Πολυσυγγραμμικότητα**: Η πυκνότητα εμφανίζει μέτρια πολυσυγγραμμικότητα ($VIF = 6.26$).
6. **Μη γραμμικές σχέσεις**: Στατιστικά σημαντικοί πολυωνυμικοί όροι (Υποερώτημα 4).

6.4 Εναλλακτικές προσεγγίσεις

- **Τακτική λογιστική παλινδρόμηση**: Κατάλληλη για τη διακριτή φύση της μεταβλητής απόκρισης.
- **Random Forest / Gradient Boosting**: Χειρίζονται μη γραμμικότητα και αλληλεπιδράσεις.
- **Ridge / LASSO παλινδρόμηση**: Αντιμετωπίζουν πολυσυγγραμμικότητα.
- **Παλινδρόμηση Poisson**: Κατάλληλη για δεδομένα μέτρησης.

7 Συμπεράσματα

1. **Απλή παλινδρόμηση**: Όλες οι 11 μεταβλητές σχετίζονται σημαντικά με την ποιότητα μεμονωμένα. Ισχυρότερος προβλέπτης: αλκοόλ ($R^2 = 0.19$).

2. **Πολλαπλή παλινδρόμηση**: Το πλήρες μοντέλο ($R^2 = 0.277$, $F = 183.41$, $p \approx 0$) αναδεικνύει 10 σημαντικούς προβλέπτες. Το citric acid δεν προσφέρει σημαντική επιπλέον πληροφορία ($p = 0.138$).
3. **Πρόσω επιλογή**: Επιβεβαιώνει τον αποκλεισμό του citric acid. Οι 3 κορυφαίες μεταβλητές (alcohol, volatile acidity, sulphates) εξηγούν το 92% της ερμηνευτικής ικανότητας.
4. **Πολυωνυμική παλινδρόμηση**: Υπάρχουν ενδείξεις μη γραμμικότητας (κυρίως για chlorides), αλλά η πρακτική βελτίωση είναι περιορισμένη.
5. **Κριτική**: Η γραμμική παλινδρόμηση παραβιάζει αρκετές υποθέσεις (διακριτή απόκριση, μη κανονικά υπόλοιπα, ετεροσκεδαστικότητα). Εναλλακτικές μέθοδοι (τακτική λογιστική παλινδρόμηση, αλγόριθμοι μηχανικής μάθησης) θα ήταν καταλληλότερες.

Συνολικά, παρά τους περιορισμούς, η ανάλυση αποκάλυψε ότι οι φυσικοχημικές ιδιότητες εξηγούν ένα σημαντικό αλλά μη πλήρες μέρος ($\approx 28\%$) της μεταβλητότητας στην ποιότητα κρασιού, με το αλκοόλ, την πτητική οξύτητα και τα θειικά να αποτελούν τους κυρίαρχους προβλέπτες.