Ανάλυση Δεδομένων 2025-26

2η Εργασία: Ανάλυση Παλινδρόμησης

Πρόβλεψη Ποιότητας Κρασιού

ΑΕΜ: 6931

Ρακοβαλής Παύλος

23 Μαρτίου 2026

Περιεχόμενα

1 Εισαγωγή **4**
1.1 Σκοπός της εργασίας 4
1.2 Τι είναι η ανάλυση παλινδρόμησης; 4
1.3 Τα δεδομένα μας 4
1.4 Δομή της αναφοράς 5

2 Απλή Γραμμική Παλινδρόμηση (Υποερώτημα 1) **6**
2.1 Θεωρητικό υπόβαθρο 6
2.1.1 Τι είναι η απλή γραμμική παλινδρόμηση; 6
2.1.2 Η μέθοδος ελαχίστων τετραγώνων (OLS) 7
2.1.3 Ο συντελεστής προσδιορισμού R^2 7
2.1.4 Έλεγχος στατιστικής σημαντικότητας 8
2.2 Αποτελέσματα: Μοντέλα απλής γραμμικής παλινδρόμησης . . 14
2.2.1 Ερμηνεία αποτελεσμάτων 15
2.3 Διαγράμματα διασποράς 15

3 Πολλαπλή Γραμμική Παλινδρόμηση (Υποερώτημα 2) **18**
3.1 Θεωρητικό υπόβαθρο 18
3.1.1 Γιατί δεν αρκεί η απλή παλινδρόμηση; 18
3.1.2 Τι είναι η πολλαπλή γραμμική παλινδρόμηση; 19
3.1.3 Πώς υπολογίζεται η πολλαπλή παλινδρόμηση; 20
3.1.4 Ο διορθωμένος R^2: Γιατί χρειαζόμαστε νέο δείκτη; . . . 20
3.1.5 Ο F-έλεγχος: Αξίζει καν το μοντέλο μας; 21
3.1.6 Ο t-έλεγχος κάθε μεταβλητής: «Βοηθάει αυτή η μεταβλητή;» 22
3.1.7 Τι σημαίνει «Standard Error» (τυπικό σφάλμα); 23
3.2 Εφαρμογή στα δεδομένα μας 23
3.2.1 Τι ακριβώς κάναμε 23
3.2.2 Αποτελέσματα: Ο πίνακας συντελεστών 24

3.2.3 Στατιστικά συνολικού μοντέλου 25
3.3 Ερμηνεία: Για ποιες μεταβλητές απορρίπτεται η $H_0 : \beta_j = 0$; . . 25
3.3.1 Η «μυστηριώδης» περίπτωση του citric acid 26
3.4 Αναλυτική ερμηνεία κάθε μεταβλητής 27
3.4.1 Μεταβλητές με θετική επίδραση 27
3.4.2 Μεταβλητές με αρνητική επίδραση 27
3.4.3 Σύγκριση: Απλή vs Πολλαπλή Παλινδρόμηση 28

4 Πρόσω Επιλογή Μεταβλητών (Υποερώτημα 3) 30
4.1 Θεωρητικό υπόβαθρο 30
4.1.1 Το πρόβλημα: Γιατί χρειαζόμαστε επιλογή μεταβλητών; 30
4.1.2 Οι τρεις βασικές μέθοδοι επιλογής μεταβλητών 31
4.1.3 Η μέθοδος πρόσω επιλογής – Βήμα προς βήμα 31
4.1.4 Η έννοια της «μοναδικής συνεισφοράς» 33
4.1.5 Κριτήρια αξιολόγησης μοντέλων: AIC και BIC 33
4.1.6 Ο ρόλος του R^2_{adj} στην επιλογή μεταβλητών 34
4.2 Εφαρμογή: Βήμα-βήμα η πρόσω επιλογή στα δεδομένα μας . . . 35
4.2.1 Βήμα 1: Ποια μεταβλητή εξηγεί μόνη της την ποιότητα καλύτερα; 35
4.2.2 Βήμα 2: Τι λείπει από το μοντέλο; 35
4.2.3 Βήμα 3: Τα sulphates ως τρίτη δύναμη 36
4.2.4 Βήματα 4–7: Τα sulfur dioxide και τα υπόλοιπα χημικά . 36
4.2.5 Βήματα 8–10: Οι τελευταίες προσθήκες 36
4.2.6 Βήμα 11: Η στιγμή που σταματάει ο αλγόριθμος 37
4.3 Συγκεντρωτικά αποτελέσματα 37
4.4 Ερμηνεία αποτελεσμάτων 38
4.4.1 Κεντρικά ευρήματα 38
4.4.2 Γιατί η σειρά εισόδου διαφέρει από την απλή παλινδρόμηση; 38
4.4.3 Σύγκριση με το πλήρες μοντέλο (Υποερώτημα 2) 39
4.4.4 Πρακτική σημασία: Αν είχαμε μόνο 3 μεταβλητές; 39

5 Πολυωνυμική Παλινδρόμηση (Υποερώτημα 4) 41
5.1 Θεωρητικό υπόβαθρο 41
5.1.1 Πέρα από τη γραμμικότητα 41
5.1.2 Πώς ελέγχουμε τη μη γραμμικότητα; 41
5.2 Αποτελέσματα 42
5.2.1 Residual Sugar (Υπολειπόμενη ζάχαρη) 42
5.2.2 Chlorides (Χλωριούχα) 42
5.2.3 Alcohol (Αλκοόλ) 43
5.2.4 Συνολική αξιολόγηση 45

6 Κριτική Αξιολόγηση του Μοντέλου (Υποερώτημα 5) 46
6.1 Θεωρητικό υπόβαθρο: Υποθέσεις της γραμμικής παλινδρόμησης 46
6.2 Διαγνωστικοί έλεγχοι 47
6.2.1 Έλεγχος 1: Κανονικότητα υπολοίπων 47
6.2.2 Έλεγχος 2: Ομοσκεδαστικότητα 48
6.2.3 Έλεγχος 3: Αυτοσυσχέτιση 48
6.2.4 Έλεγχος 4: Πολυσυγγραμμικότητα (VIF) 49

6.3 Κριτική αξιολόγηση: Είναι η παλινδρόμηση κατάλληλη; 50
6.4 Εναλλακτικές προσεγγίσεις 51

7 Συμπεράσματα 52

1 Εισαγωγή

1.1 Σκοπός της εργασίας

Η παρούσα εργασία αποτελεί τη 2η εργασία του μαθήματος **Ανάλυση Δεδομένων** και έχει ως στόχο τη διερεύνηση κατά πόσο οι φυσικοχημικές ιδιότητες του κρασιού μπορούν να χρησιμοποιηθούν για την πρόβλεψη και ερμηνεία της **βαθμολογίας ποιότητας** (quality). Χρησιμοποιούνται τα καθαρισμένα δεδομένα από την 1η εργασία (τυχαίο δείγμα βάσει ΑΕΜ 6931, 5.274 παρατηρήσεις).

1.2 Τι είναι η ανάλυση παλινδρόμησης;

Ορισμός: Ανάλυση Παλινδρόμησης

Η **ανάλυση παλινδρόμησης** (regression analysis) είναι μια στατιστική μέθοδος που μας επιτρέπει να μελετήσουμε τη σχέση μεταξύ μιας **εξαρτημένης μεταβλητής** (ή μεταβλητή απόκρισης) και μιας ή περισσότερων **ανεξάρτητων μεταβλητών** (ή προβλεπτικών μεταβλητών).
Στην ουσία, προσπαθούμε να απαντήσουμε στο ερώτημα: *«Μπορούμε να προβλέψουμε/εξηγήσουμε την τιμή μιας μεταβλητής χρησιμοποιώντας τις τιμές άλλων μεταβλητών;»*

Παράδειγμα από την καθημερινότητα

Φανταστείτε ότι θέλετε να προβλέψετε τον βαθμό ενός φοιτητή σε ένα μάθημα. Ποιοι παράγοντες θα μπορούσαν να τον επηρεάσουν;

- Ώρες μελέτης (όσο περισσότερο μελετάει, τόσο υψηλότερος ο βαθμός)
- Παρακολούθηση μαθημάτων (θετική επίδραση)
- Ώρες ύπνου πριν τις εξετάσεις (θετική επίδραση)

Η παλινδρόμηση μας δίνει μια **μαθηματική εξίσωση** που ποσοτικοποιεί αυτές τις σχέσεις.

1.3 Τα δεδομένα μας

Χρησιμοποιούμε τα καθαρισμένα δεδομένα κρασιού από την 1η εργασία:

- **Μεταβλητή απόκρισης** (Y): `quality` – η βαθμολογία ποιότητας του κρασιού (ακέραιες τιμές 3–9)
- **Προβλεπτικές μεταβλητές** ($X_1, X_2, \ldots, X_{11}$):
  1. `fixed acidity` – σταθερή οξύτητα

2. `volatile acidity` – πτητική οξύτητα
3. `citric acid` – κιτρικό οξύ
4. `residual sugar` – υπολειπόμενη ζάχαρη
5. `chlorides` – χλωριούχα
6. `free sulfur dioxide` – ελεύθερο διοξείδιο του θείου
7. `total sulfur dioxide` – ολικό διοξείδιο του θείου
8. `density` – πυκνότητα
9. `pH` – δείκτης οξύτητας
10. `sulphates` – θειικά
11. `alcohol` – αλκοόλ

- **Πλήθος παρατηρήσεων**: 5.274

1.4 Δομή της αναφοράς

Η αναφορά οργανώνεται ως εξής:

- **Ενότητα 2**: Απλή γραμμική παλινδρόμηση – εξετάζουμε κάθε μεταβλητή ξεχωριστά
- **Ενότητα 3**: Πολλαπλή γραμμική παλινδρόμηση – χρησιμοποιούμε όλες τις μεταβλητές μαζί
- **Ενότητα 4**: Πρόσω επιλογή μεταβλητών – βρίσκουμε το βέλτιστο μοντέλο
- **Ενότητα 5**: Πολυωνυμική παλινδρόμηση – μη γραμμικές σχέσεις
- **Ενότητα 6**: Κριτική αξιολόγηση του μοντέλου

2 Απλή Γραμμική Παλινδρόμηση (Υποερώτημα 1)

2.1 Θεωρητικό υπόβαθρο

2.1.1 Τι είναι η απλή γραμμική παλινδρόμηση;

Ορισμός: Απλή Γραμμική Παλινδρόμηση

Η **απλή γραμμική παλινδρόμηση** (Simple Linear Regression – SLR) είναι η απλούστερη μορφή παλινδρόμησης. Μελετά τη σχέση μεταξύ **μίας** ανεξάρτητης μεταβλητής X και μιας εξαρτημένης μεταβλητής Y μέσω ενός **γραμμικού μοντέλου**:

$$Y = \beta_0 + \beta_1 X + \varepsilon \tag{1}$$

όπου:

- Y = η μεταβλητή απόκρισης (αυτό που θέλουμε να προβλέψουμε)
- X = η προβλεπτική μεταβλητή (αυτό που χρησιμοποιούμε για πρόβλεψη)
- β_0 = η **τεταγμένη επί την αρχή** (intercept) – η τιμή του Y όταν $X = 0$
- β_1 = η **κλίση** (slope) – πόσο αλλάζει το Y όταν το X αυξάνεται κατά 1 μονάδα
- ε = το **σφάλμα** (error) – η τυχαία διακύμανση που δεν εξηγείται από το μοντέλο

Γεωμετρική ερμηνεία

Φανταστείτε ότι σχεδιάζετε τα σημεία (X, Y) σε ένα γράφημα. Η γραμμική παλινδρόμηση «περνάει» μια ευθεία γραμμή μέσα από αυτά τα σημεία, με τρόπο τέτοιο ώστε η γραμμή να βρίσκεται **όσο πιο κοντά γίνεται** σε όλα τα σημεία.
Η β_0 μας λέει πού «ξεκινάει» η γραμμή (στον κάθετο άξονα), και η β_1 μας λέει αν η γραμμή **ανεβαίνει** ($\beta_1 > 0$, θετική σχέση) ή **κατεβαίνει** ($\beta_1 < 0$, αρνητική σχέση).

2.1.2 Η μέθοδος ελαχίστων τετραγώνων (OLS)

Πώς υπολογίζονται οι συντελεστές;

Η μέθοδος **Ελαχίστων Τετραγώνων** (Ordinary Least Squares – OLS) βρίσκει τις τιμές β_0 και β_1 που **ελαχιστοποιούν** το άθροισμα των τετραγώνων των σφαλμάτων:

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_i)^2 \tag{2}$$

Δηλαδή, βρίσκει τη γραμμή που κάνει τα «λάθη» (τις αποστάσεις μεταξύ πραγματικών και προβλεπόμενων τιμών) **όσο μικρότερα γίνεται**. Τα σφάλματα υψώνονται στο τετράγωνο για δύο λόγους:

1. Ώστε τα θετικά και αρνητικά σφάλματα να μην αλληλοεξουδετερώνονται
2. Ώστε τα μεγάλα σφάλματα να «τιμωρούνται» περισσότερο

2.1.3 Ο συντελεστής προσδιορισμού R^2

Ορισμός: Συντελεστής Προσδιορισμού R^2

Ο R^2 (R-squared) μας λέει **τι ποσοστό** της μεταβλητότητας του Y εξηγείται από το μοντέλο:

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2} \tag{3}$$

όπου:

- SS_{res} = Residual Sum of Squares (μεταβλητότητα που **δεν** εξηγείται)
- SS_{tot} = Total Sum of Squares (συνολική μεταβλητότητα)
- $\hat{Y}_i$ = η προβλεπόμενη τιμή για την παρατήρηση i
- $\bar{Y}$ = ο μέσος όρος του Y

Ερμηνεία:

- $R^2 = 0$: Το μοντέλο δεν εξηγεί τίποτα (τόσο καλό όσο να προβλέπαμε πάντα τον μέσο όρο)
- $R^2 = 1$: Το μοντέλο εξηγεί τα πάντα (τέλεια πρόβλεψη)
- $R^2 = 0.60$: Το μοντέλο εξηγεί το 60% της μεταβλητότητας

2.1.4 Έλεγχος στατιστικής σημαντικότητας

Μέχρι τώρα μάθαμε πώς να φτιάχνουμε ένα μοντέλο παλινδρόμησης και πώς να μετράμε πόσο καλά ταιριάζει στα δεδομένα (R^2). Αλλά υπάρχει ένα κρίσιμο ερώτημα που **δεν** έχουμε απαντήσει ακόμα:

Αυτή η σχέση που βρήκαμε, είναι πραγματική ή απλά τυχαία;

Αναλογία: Το νόμισμα και η τύχη

Φανταστείτε ότι ρίχνετε ένα νόμισμα 10 φορές και πέφτει **7 φορές κορώνα**. Είναι το νόμισμα «πειραγμένο» ή απλά τυχαίνει;

- Αν ρίξετε 10 φορές και πέσει 7 κορώνες, λέτε: «Μπα, μπορεί να είναι τύχη»
- Αν ρίξετε 1000 φορές και πέσει 700 κορώνες, λέτε: «Σίγουρα κάτι παίζει!»

Ακριβώς αυτό κάνει ο **έλεγχος στατιστικής σημαντικότητας**: μας βοηθά να αποφασίσουμε αν αυτό που βλέπουμε στα δεδομένα μας είναι **πραγματικό φαινόμενο** ή απλά **τυχαίο θόρυβο**.

Βήμα 1: Ορίζουμε δύο αντίθετες υποθέσεις. Πριν κάνουμε τον έλεγχο, πρέπει να διατυπώσουμε ακριβώς τι θέλουμε να ελέγξουμε. Για κάθε μεταβλητή X ορίζουμε δύο **υποθέσεις**:

Ορισμός: Μηδενική και Εναλλακτική Υπόθεση

- $H_0 : \beta_1 = 0$ **Μηδενική υπόθεση** (Null Hypothesis)

  Σημαίνει: «Η μεταβλητή X **δεν** επηρεάζει **καθόλου** το Y. Η κλίση της γραμμής είναι μηδέν, δηλαδή η γραμμή είναι εντελώς **οριζόντια**. Δεν υπάρχει καμία σχέση.»

- $H_1 : \beta_1 \neq 0$ **Εναλλακτική υπόθεση** (Alternative Hypothesis)

  Σημαίνει: «Η μεταβλητή X **επηρεάζει** το Y. Η κλίση δεν είναι μηδέν – η γραμμή ανεβαίνει ή κατεβαίνει, άρα υπάρχει σχέση.»

Αναλογία: Δικαστήριο – «Αθώος μέχρι αποδείξεως του εναντίου»

Ο έλεγχος υποθέσεων λειτουργεί ακριβώς σαν δικαστήριο:

1. **Ξεκινάμε υποθέτοντας αθωότητα**: Η H_0 λέει «δεν υπάρχει σχέση» – αυτή είναι η «αθωότητα». Την θεωρούμε αληθή εξ αρχής.
2. **Ψάχνουμε αποδείξεις**: Κοιτάμε τα δεδομένα μας. Αν τα δεδομένα δείχνουν ισχυρή σχέση, αυτό είναι «απόδειξη» κατά της αθωότητας.

3. **Αποφασίζουμε**: Αν οι αποδείξεις είναι αρκετά ισχυρές (πέρα από κάθε λογική αμφιβολία), τότε «καταδικάζουμε» – δηλαδή **απορρίπτουμε** την H_0 και λέμε ότι υπάρχει σχέση. Αν δεν είναι αρκετές, «αθωώνουμε» – **δεν απορρίπτουμε** την H_0.

Σημαντικό: Ακριβώς όπως στο δικαστήριο δεν λέμε ποτέ «αποδείχθηκε η αθωότητα» (απλά «δεν αποδείχθηκε η ενοχή»), έτσι και εδώ δεν λέμε ποτέ «αποδείξαμε ότι δεν υπάρχει σχέση». Λέμε απλά «δεν βρήκαμε αρκετές αποδείξεις για σχέση».

Βήμα 2: Υπολογίζουμε την «απόδειξη» – ο t-έλεγχος. Τώρα χρειαζόμαστε ένα **αριθμητικό μέτρο** για το πόσο ισχυρή είναι η «απόδειξη» κατά της H_0. Αυτό το μέτρο λέγεται **t-στατιστική** (t-statistic):

Ορισμός: Η t-στατιστική

$$t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \tag{4}$$

Ας αναλύσουμε κάθε κομμάτι:

- $\hat{\beta}_1$ = η **κλίση** που υπολόγισε το μοντέλο μας. Αυτή είναι η «εκτίμησή» μας για τη σχέση μεταξύ X και Y.
- $SE(\hat{\beta}_1)$ = το **τυπικό σφάλμα** (Standard Error) της κλίσης. Αυτή είναι η «αβεβαιότητα» στην εκτίμησή μας – πόσο θα μπορούσε να διαφέρει η $\hat{\beta}_1$ αν είχαμε πάρει **διαφορετικό** δείγμα κρασιών.

Με λόγια: η t-στατιστική μετράει **πόσες φορές μεγαλύτερη** είναι η κλίση που βρήκαμε σε σχέση με την αβεβαιότητα.

Αναλογία: Σήμα εναντίον θορύβου στο ραδιόφωνο

Φανταστείτε ότι ακούτε ραδιόφωνο στο αυτοκίνητο:

- **Η κλίση $\hat{\beta}_1$ είναι η «φωνή»** (σήμα): Πόσο δυνατά ακούγεται ο εκφωνητής. Αν η κλίση είναι μεγάλη, η «φωνή» είναι δυνατή – βλέπουμε ισχυρή σχέση.
- **Το τυπικό σφάλμα SE είναι ο «θόρυβος»**: Πόση παρασιτική βοή υπάρχει. Αν το SE είναι μεγάλο, σημαίνει ότι η εκτίμησή μας είναι αναξιόπιστη – υπάρχει πολύς «θόρυβος».
- **Η t-στατιστική είναι η αναλογία σήματος προς θόρυβο**: Πόσο καθαρά ακούτε τον εκφωνητή πάνω από τη βοή.

Παράδειγμα: Αν $\hat{\beta}_1 = 0.343$ και $SE = 0.00977$:

$$t = \frac{0.343}{0.00977} = 35.1$$

Αυτό σημαίνει: η κλίση είναι **35 φορές** μεγαλύτερη από την αβεβαιότητα! Ένα τεράστιο σήμα – σαν να ακούτε εκφωνητή σε ένα ήσυχο δωμάτιο.
Αντίθετα, αν είχαμε $\hat{\beta}_1 = 0.01$ και $SE = 0.02$:

$$t = \frac{0.01}{0.02} = 0.5$$

Η κλίση είναι **μικρότερη** από την αβεβαιότητα! Ένα πολύ αδύναμο σήμα – σαν να προσπαθείτε να ακούσετε κάποιον να ψιθυρίζει σε συναυλία ροκ.
Κανόνας: Όσο πιο μακριά είναι η $|t|$ από το μηδέν, τόσο πιο ισχυρή η «απόδειξη» ότι η σχέση είναι πραγματική.

Τι είναι ακριβώς το Τυπικό Σφάλμα (Standard Error);

Ας καταλάβουμε γιατί χρειαζόμαστε το SE:
Φανταστείτε ότι πηγαίνετε σε 100 διαφορετικά σούπερ μάρκετ και δοκιμάζετε κρασιά. Σε κάθε σούπερ μάρκετ θα βρείτε **λίγο διαφορετική** σχέση μεταξύ αλκοόλ και ποιότητας, γιατί σε κάθε κατάστημα υπάρχουν **διαφορετικά** κρασιά.

- Ένα σούπερ μάρκετ μπορεί να δώσει $\hat{\beta}_1 = 0.32$
- Ένα άλλο $\hat{\beta}_1 = 0.36$
- Ένα τρίτο $\hat{\beta}_1 = 0.34$

Αν **τα περισσότερα σούπερ μάρκετ** δίνουν παρόμοια αποτελέσματα (π.χ. 0.32–0.36), τότε η εκτίμησή μας είναι **σταθερή** και αξιόπιστη $\Rightarrow$ **μικρό** SE.
Αν τα αποτελέσματα κυμαίνονται ευρέως (π.χ. -0.10 ως $+0.80$), τότε δεν μπορούμε να εμπιστευτούμε κανένα μεμονωμένο αποτέλεσμα $\Rightarrow$ **μεγάλο** SE.
Το SE μας λέει πόσο **θα «κουνιόταν»** η εκτίμησή μας αν επαναλαμβάναμε το πείραμα πολλές φορές.

Βήμα 3: Μετατρέπουμε το t σε πιθανότητα – η p-value. Η t-στατιστική μας λέει πόσο ισχυρό είναι το σήμα, αλλά χρειαζόμαστε κάτι πιο κατανοητό: μια **πιθανότητα**. Εδώ μπαίνει η p-value.

Ορισμός: Η p-value – Βήμα προς βήμα

Η **p-value** απαντάει στο εξής ερώτημα:

«Αν η H_0 ήταν αληθής (δηλαδή αν πραγματικά **δεν** υπήρχε καμία σχέση μεταξύ X και Y), ποια θα ήταν η πιθανότητα να παρατηρούσαμε t-στατιστική τόσο ακραία ή πιο ακραία από αυτή που βρήκαμε;»

Με πιο απλά λόγια: «Πόσο πιθανό είναι η τύχη να «μιμηθεί» μια τόσο ισχυρή σχέση;»

Αναλογία: Ρίψεις νομίσματος – Κατανόηση της p-value

Ας γυρίσουμε στο παράδειγμα με το νόμισμα:
Σενάριο: Ένας φίλος σας λέει ότι το νόμισμά του είναι δίκαιο (H_0: πιθανότητα κορώνας = 50%). Εσείς θέλετε να ελέγξετε αν λέει αλήθεια.
Πείραμα 1: Ρίχνετε 10 φορές, πέφτουν 7 κορώνες.

- Ρωτάτε: «Αν το νόμισμα ΕΙΝΑΙ δίκαιο, πόσο πιθανό είναι να πέσουν 7+ κορώνες στις 10;»
- Η απάντηση (η p-value): περίπου 17%
- Ερμηνεία: «Ε, ένα δίκαιο νόμισμα θα έδινε 7+ κορώνες περίπου 1 στις 6 φορές. Δεν είναι τόσο ασυνήθιστο. Πιθανόν απλά τύχη.»
- **Δεν απορρίπτουμε** την H_0. Δεν μπορούμε να πούμε ότι το νόμισμα είναι πειραγμένο.

Πείραμα 2: Ρίχνετε 1000 φορές, πέφτουν 700 κορώνες.

- Ρωτάτε: «Αν το νόμισμα ΕΙΝΑΙ δίκαιο, πόσο πιθανό είναι να πέσουν 700+ κορώνες στις 1000;»
- Η απάντηση (η p-value): πρακτικά 0% (κάτι σαν 10^{-50})
- Ερμηνεία: «Θα ήταν σχεδόν αδύνατο ένα δίκαιο νόμισμα να δώσει 700 κορώνες στις 1000. Κάτι άλλο συμβαίνει.»
- **Απορρίπτουμε** την H_0. Το νόμισμα σχεδόν σίγουρα δεν είναι δίκαιο.

Στην παλινδρόμηση: Αντί για νομίσματα, ρωτάμε: «Αν ΠΡΑΓΜΑΤΙΚΑ δεν υπήρχε σχέση μεταξύ αλκοόλ και ποιότητας, πόσο πιθανό θα ήταν να βρούμε $t = 35.1$;». Η p-value $= 4.55 \times 10^{-243}$ – ένας αριθμός τόσο κοντά στο μηδέν που είναι **αδιανόητο** να πρόκειται για τύχη.

Βήμα 4: Αποφασίζουμε – το κατώφλι $\alpha = 0.05$.

Ορισμός: Το επίπεδο σημαντικότητας α

Πριν κάνουμε τον έλεγχο, ορίζουμε ένα **κατώφλι**: πόσο μικρή πρέπει να είναι η p-value για να μας πείσει. Αυτό το κατώφλι λέγεται **επίπεδο σημαντικότητας** (significance level) και συμβολίζεται α.
Η σύμβαση: Στις περισσότερες επιστήμες χρησιμοποιούμε $\alpha = 0.05$ (5%). Αυτό σημαίνει:
«Αν η πιθανότητα να βλέπουμε τέτοιο αποτέλεσμα τυχαία είναι μικρότερη από 5%, τότε λέμε ότι η σχέση είναι **στατιστικά σημαντική**.»
Ο κανόνας απόφασης:

- Αν p-value $< \alpha = 0.05 \Rightarrow$ **Απορρίπτουμε** την $H_0 \Rightarrow$ Η σχέση **είναι** στατιστικά σημαντική
- Αν p-value $\geq \alpha = 0.05 \Rightarrow$ **Δεν απορρίπτουμε** την $H_0 \Rightarrow$ **Δεν μπορούμε** να πούμε ότι υπάρχει σχέση

title

Η τιμή 0.05 (5%) είναι μια **σύμβαση**, όχι φυσικός νόμος. Επιλέχθηκε ιστορικά (από τον Ronald Fisher, τη δεκαετία του 1920) ως ένα λογικό ισοζύγιο:

- Πολύ αυστηρό κατώφλι (π.χ. $\alpha = 0.001$): Θα χάναμε πολλές αληθινές σχέσεις (θα λέγαμε «δεν υπάρχει σχέση» ενώ υπάρχει)
- Πολύ χαλαρό κατώφλι (π.χ. $\alpha = 0.20$): Θα «βρίσκαμε» σχέσεις που δεν υπάρχουν (θα πέφταμε θύματα της τύχης)
- Το 5% θεωρείται αποδεκτός συμβιβασμός: «Δέχομαι 5% πιθανότητα να κάνω λάθος»

Σε ορισμένα πεδία χρησιμοποιούνται αυστηρότερα κατώφλια. Π.χ. στη φυσική σωματιδίων, η ανακάλυψη του Higgs boson απαιτούσε $\alpha = 0.0000003$ («5 sigma»)!

Ας δούμε ολόκληρη τη διαδικασία με ένα πραγματικό παράδειγμα.

Πλήρες παράδειγμα: Αλκοόλ $\rightarrow$ Ποιότητα

Ερώτηση: «Επηρεάζει το αλκοόλ την ποιότητα του κρασιού, ή είναι τυχαίο;»
Βήμα 1 – Υποθέσεις:

- H_0: Το αλκοόλ **δεν** επηρεάζει την ποιότητα ($\beta_1 = 0$)
- H_1: Το αλκοόλ **επηρεάζει** την ποιότητα ($\beta_1 \neq 0$)

Βήμα 2 – Υπολογισμός:

- Από τα δεδομένα μας βρίσκουμε: $\hat{\beta}_1 = 0.3430$ (η κλίση)

- Η αβεβαιότητα αυτής της εκτίμησης: $SE = 0.00977$
- Η t-στατιστική: $t = \frac{0.3430}{0.00977} = 35.13$
- Η κλίση είναι **35 φορές** μεγαλύτερη από την αβεβαιότητα!

Βήμα 3 – p-value:

- Ρωτάμε: «Αν δεν υπήρχε ΚΑΜΙΑ σχέση, πόσο πιθανό θα ήταν να βρούμε $t = 35.13$;»
- Απάντηση: $p = 4.55 \times 10^{-243}$
- Αυτός ο αριθμός είναι ένα 0 ακολουθούμενο από 242 μηδενικά και μετά ένα 455. Για αναφορά, τα άτομα στο σύμπαν είναι περίπου 10^{80} – αυτή η p-value είναι ασύλληπτα μικρή.

Βήμα 4 – Απόφαση:

- $4.55 \times 10^{-243} < 0.05$; **ΝΑΙ**, κατά πολύ!
- **Απορρίπτουμε** την H_0
- **Συμπέρασμα**: Η σχέση μεταξύ αλκοόλ και ποιότητας είναι **στατιστικά σημαντική**. Δεν πρόκειται για τύχη.

title

Η p-value είναι ίσως η πιο **παρεξηγημένη** έννοια στη στατιστική. Ας ξεκαθαρίσουμε τρία λάθη:
Παρανόηση 1: «Η p-value μας λέει πόσο ισχυρή είναι η σχέση.»

- **ΛΑΘΟΣ**! Η p-value μας λέει μόνο αν η σχέση είναι **στατιστικά σημαντική** (δηλαδή, αν δεν οφείλεται σε τύχη), ΟΧΙ πόσο ισχυρή είναι.
- Παράδειγμα: Με πολλά δεδομένα (π.χ. 5.320 κρασιά), ακόμα και μια **πολύ αδύναμη** σχέση μπορεί να δώσει πολύ μικρή p-value.
- Το pH έχει p-value = 0.028 (στατιστικά σημαντική) αλλά $R^2 = 0.0009$ – εξηγεί μόλις 0.09% της μεταβλητότητας!
- **Για την ισχύ κοιτάμε τον R^2, όχι τη p-value**.

Παρανόηση 2: «Αν η p-value > 0.05, σημαίνει ότι δεν υπάρχει σχέση.»

- **ΛΑΘΟΣ**! Σημαίνει μόνο ότι **δεν βρήκαμε αρκετές αποδείξεις** για να πούμε ότι υπάρχει σχέση. Ίσως υπάρχει αλλά δεν είχαμε αρκετά δεδομένα, ή ίσως η σχέση δεν είναι γραμμική.
- Η «απουσία απόδειξης» δεν είναι «απόδειξη απουσίας».

Παρανόηση 3: «Η p-value = 0.03 σημαίνει ότι υπάρχει 3% πιθανότητα η H_0 να είναι αληθής.»

- **ΛΑΘΟΣ**! Η p-value δεν μας λέει την πιθανότητα της H_0. Μας λέει: «αν η H_0 ΗΤΑΝ αληθής, πόσο πιθανά θα ήταν τα δεδομένα μας;» – αυτό είναι **τελείως διαφορετικό** ερώτημα.
- Αναλογία: Αν βρέχει, η πιθανότητα ο δρόμος να είναι βρεγμένος είναι 100%. Αλλά αν ο δρόμος είναι βρεγμένος, δεν σημαίνει 100% ότι βρέχει (μπορεί να πέρασε βυτιοφόρο)!

Σύνοψη: Πώς λειτουργεί ο έλεγχος σε 4 βήματα

1. **Υποθέτουμε** ότι δεν υπάρχει σχέση ($H_0 : \beta_1 = 0$)
2. **Μετράμε** πόσο ισχυρή είναι η σχέση σε σύγκριση με τον θόρυβο (t-στατιστική $= \frac{\text{σήμα}}{\text{θόρυβος}}$)
3. **Υπολογίζουμε** πόσο πιθανό θα ήταν να βλέπαμε τέτοιο σήμα αν δεν υπήρχε σχέση (p-value)
4. **Αποφασίζουμε**: αν η p-value < 0.05, η σχέση είναι πραγματική. Αν η p-value ≥ 0.05, δεν μπορούμε να αποφανθούμε.

2.2 Αποτελέσματα: Μοντέλα απλής γραμμικής παλινδρόμησης

Για κάθε μία από τις 11 προβλεπτικές μεταβλητές, εφαρμόστηκε ένα μοντέλο της μορφής:

$$\text{quality} = \beta_0 + \beta_1 \cdot X_j + \varepsilon$$

Τα αποτελέσματα παρουσιάζονται στον Πίνακα 1, ταξινομημένα κατά φθίνουσα σειρά R^2 (δηλαδή, πρώτα η μεταβλητή που εξηγεί τη μεγαλύτερη μεταβλητότητα).

Πίνακας 1: Αποτελέσματα Απλής Γραμμικής Παλινδρόμησης: quality $\sim$ κάθε μεταβλητή

Μεταβλητή	$\hat{\beta}_1$	**t-stat**	**p-value**	R^2	**Σημαντ.**
alcohol	0.3430	35.13	4.55×10^{-243}	0.1897	Ναι
density	-94.21	-23.40	2.64×10^{-115}	0.0941	Ναι
volatile acidity	-1.386	-19.08	1.59×10^{-78}	0.0646	Ναι
chlorides	-5.078	-15.09	2.17×10^{-50}	0.0414	Ναι
citric acid	0.5662	6.86	7.54×10^{-12}	0.0089	Ναι
fixed acidity	-0.0516	-5.24	1.68×10^{-7}	0.0052	Ναι
residual sugar	-0.0101	-3.88	1.04×10^{-4}	0.0029	Ναι
total sulfur dioxide	-0.0008	-3.79	1.50×10^{-4}	0.0027	Ναι
free sulfur dioxide	0.0026	3.79	1.55×10^{-4}	0.0027	Ναι
sulphates	0.2528	3.09	2.02×10^{-3}	0.0018	Ναι
pH	0.1745	2.19	2.84×10^{-2}	0.0009	Ναι

2.2.1 Ερμηνεία αποτελεσμάτων

Βασικά ευρήματα:

1. **Όλες** οι 11 μεταβλητές έχουν **στατιστικά σημαντική** σχέση με την ποιότητα ($p < 0.05$).
2. Ωστόσο, η **ισχύς** αυτής της σχέσης ποικίλλει δραματικά:
   - Το **αλκοόλ** (alcohol) είναι μακράν ο ισχυρότερος μεμονωμένος προβλέπτης ($R^2 = 0.19$), εξηγώντας σχεδόν 19% της μεταβλητότητας. Κάθε αύξηση κατά 1 βαθμό αλκοόλ αντιστοιχεί σε αύξηση βαθμολογίας κατά 0.34 μονάδες.
   - Η **πυκνότητα** (density) ακολουθεί ($R^2 = 0.094$) με αρνητική σχέση – τα πιο πυκνά κρασιά τείνουν να βαθμολογούνται χαμηλότερα.
   - Η **πτητική οξύτητα** (volatile acidity) έχει $R^2 = 0.065$ με ισχυρά αρνητική σχέση – μεγαλύτερη πτητική οξύτητα σημαίνει χαμηλότερη ποιότητα (η πτητική οξύτητα συνδέεται με δυσάρεστη ξινή γεύση).
   - Οι υπόλοιπες μεταβλητές έχουν πολύ χαμηλό R^2 (< 0.05), υποδεικνύοντας ασθενείς μεμονωμένες σχέσεις.
3. **Κατεύθυνση σχέσεων**:
   - **Θετική** (υψηλότερες τιμές $\Rightarrow$ υψηλότερη ποιότητα): alcohol, citric acid, free sulfur dioxide, sulphates, pH
   - **Αρνητική** (υψηλότερες τιμές $\Rightarrow$ χαμηλότερη ποιότητα): density, volatile acidity, chlorides, fixed acidity, residual sugar, total sulfur dioxide

Γιατί τα R^2 είναι τόσο χαμηλά;

Ακόμα και η καλύτερη μεταβλητή (alcohol) εξηγεί μόνο 19% της μεταβλητότητας. Αυτό σημαίνει ότι η ποιότητα του κρασιού είναι ένα **πολυπαράγοντικό** φαινόμενο – καμία μεμονωμένη μεταβλητή δεν αρκεί για να την εξηγήσει. Γι' αυτό χρειαζόμαστε την **πολλαπλή** παλινδρόμηση (Ενότητα 3).

2.3 Διαγράμματα διασποράς

Στο Σχήμα 1 παρουσιάζονται τα διαγράμματα διασποράς για τις στατιστικά σημαντικές μεταβλητές, μαζί με τη γραμμή παλινδρόμησης.

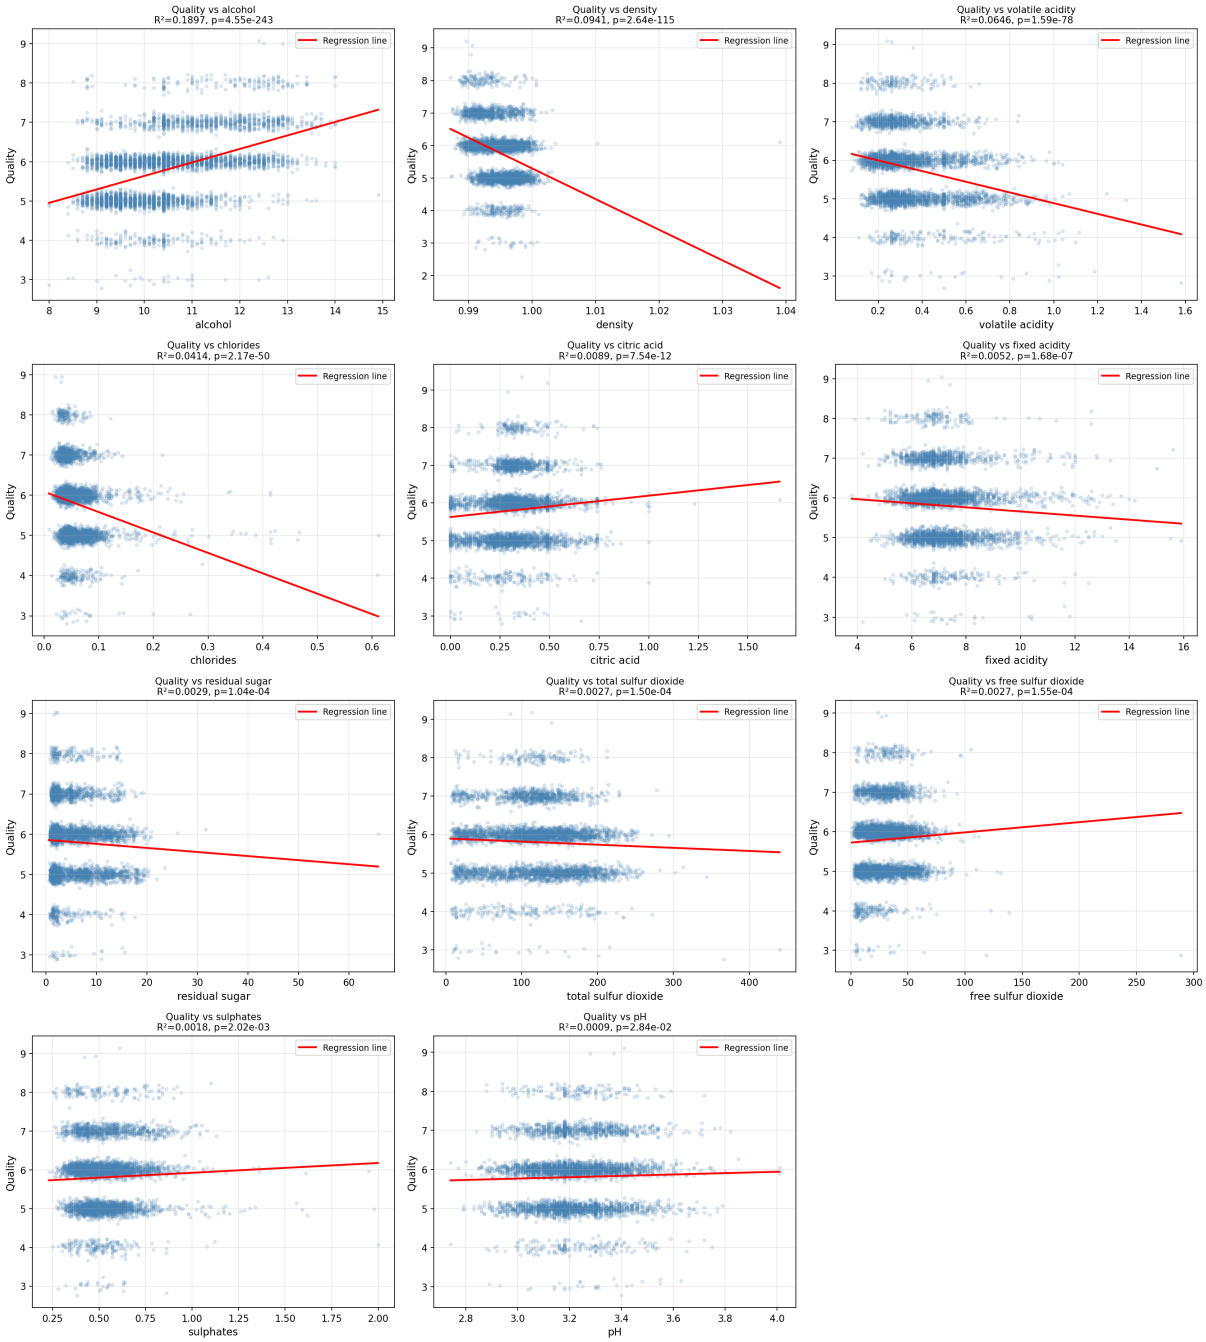

Σχήμα 1: Διαγράμματα διασποράς μεταξύ ποιότητας και κάθε μεταβλητής. Η κόκκινη γραμμή αντιπροσωπεύει τη γραμμή παλινδρόμησης. Ένα μικρό τυχαίο jitter έχει προστεθεί στη μεταβλητή quality για καλύτερη οπτικοποίηση (η quality παίρνει ακέραιες τιμές).

Τι είναι το διάγραμμα διασποράς;

Ένα **διάγραμμα διασποράς** (scatter plot) είναι ένα γράφημα όπου κάθε **σημείο** αντιπροσωπεύει μία παρατήρηση. Η θέση του σημείου καθορίζεται από τις τιμές δύο μεταβλητών (μία σε κάθε άξονα).
Αν τα σημεία σχηματίζουν ένα **ανοδικό νέφος**, η σχέση είναι θετική. Αν **καθοδικό**, αρνητική. Αν είναι **τυχαία διασκορπισμένα**,

δεν υπάρχει γραμμική σχέση.

3 Πολλαπλή Γραμμική Παλινδρόμηση (Υποερώτημα 2)

3.1 Θεωρητικό υπόβαθρο

3.1.1 Γιατί δεν αρκεί η απλή παλινδρόμηση;

Στο Υποερώτημα 1 εφαρμόσαμε 11 ξεχωριστά μοντέλα απλής παλινδρόμησης – ένα για κάθε μεταβλητή. Αλλά αυτή η προσέγγιση έχει ένα βασικό πρόβλημα: κάθε μοντέλο κοιτάει τη σχέση μιας μεταβλητής με την ποιότητα **αγνοώντας εντελώς** τις υπόλοιπες.

Αναλογία: Γιατρός που εξετάζει ένα σύμπτωμα τη φορά

Φανταστείτε έναν γιατρό που προσπαθεί να διαγνώσει μια ασθένεια. Αν κοιτάξει **μόνο** τον πυρετό, μπορεί να πει «έχεις γρίπη». Αν κοιτάξει **μόνο** τον πονόλαιμο, μπορεί πάλι να πει «έχεις γρίπη». Αλλά αν κοιτάξει **ταυτόχρονα** πυρετό, πονόλαιμο, βήχα, εξάνθημα και αποτελέσματα αίματος, μπορεί να κάνει πολύ πιο ακριβή διάγνωση.
Η **απλή παλινδρόμηση** είναι σαν τον γιατρό που κοιτάει ένα σύμπτωμα τη φορά.
Η **πολλαπλή παλινδρόμηση** είναι σαν τον γιατρό που βλέπει ΟΛΑ τα συμπτώματα μαζί.

Το πρόβλημα με τα ξεχωριστά μοντέλα

Υπάρχουν δύο σοβαροί λόγοι που τα 11 ξεχωριστά μοντέλα δεν αρκούν:

1. **Πλασματικές σχέσεις** (spurious correlations): Αν δύο μεταβλητές (X_1 και X_2) συσχετίζονται μεταξύ τους, τότε η φαινομενική σχέση $X_1 \to Y$ μπορεί να οφείλεται εν μέρει στην πραγματική σχέση $X_2 \to Y$.

   Παράδειγμα: Στο Υποερώτημα 1 βρήκαμε ότι η πυκνότητα (density) σχετίζεται αρνητικά με την ποιότητα ($R^2 = 0.094$). Αλλά μήπως αυτό συμβαίνει απλά επειδή τα κρασιά με υψηλό αλκοόλ (που είναι και καλύτερα) έχουν χαμηλότερη πυκνότητα; Χωρίς να «ελέγξουμε» για το αλκοόλ, δεν μπορούμε να ξέρουμε.

2. **Αδυναμία «ελέγχου» παραγόντων**: Στην πραγματική ζωή, οι μεταβλητές αλλάζουν **ταυτόχρονα**. Ένα κρασί δεν αλλάζει μόνο ένα χαρακτηριστικό κρατώντας σταθερά τα υπόλοιπα. Χρειαζόμαστε ένα εργαλείο που να μπορεί να «ξεμπερδεύει» αυτές τις αλληλεπιδράσεις.

Η **πολλαπλή παλινδρόμηση** κάνει ακριβώς αυτό: μας δίνει την **καθαρή επίδραση** κάθε μεταβλητής, αφού «αφαιρέσει» την επίδραση όλων των άλλων.

3.1.2 Τι είναι η πολλαπλή γραμμική παλινδρόμηση;

Ορισμός: Πολλαπλή Γραμμική Παλινδρόμηση

Η **πολλαπλή γραμμική παλινδρόμηση** (Multiple Linear Regression – MLR) είναι η επέκταση της απλής παλινδρόμησης σε **πολλές** προβλεπτικές μεταβλητές ταυτόχρονα:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \varepsilon \tag{5}$$

Τι σημαίνει κάθε σύμβολο:

- Y = η μεταβλητή που θέλουμε να εξηγήσουμε (στα δεδομένα μας: η **ποιότητα** του κρασιού)
- $X_1, X_2, \ldots, X_p$ = οι p μεταβλητές που χρησιμοποιούμε ως «εξηγήσεις» (στα δεδομένα μας: οι 11 χημικές ιδιότητες)
- β_0 = η **σταθερά** (intercept). Η τιμή του Y όταν **όλα** τα X είναι μηδέν. Στα δεδομένα μας, δεν έχει πρακτική ερμηνεία (δεν υπάρχει κρασί με μηδενικό αλκοόλ, μηδενική οξύτητα κ.λπ.), αλλά χρειάζεται μαθηματικά.
- β_j = η **μερική κλίση** (partial slope) της μεταβλητής X_j. Αυτός είναι ο πιο σημαντικός αριθμός! Μας λέει:

  «Αν αυξήσω τη μεταβλητή X_j κατά 1 μονάδα, **κρατώντας σταθερές ΟΛΕΣ τις υπόλοιπες μεταβλητές**, πόσο αλλάζει η ποιότητα;»
- ε = το **σφάλμα** – αυτό που δεν μπορεί να εξηγήσει το μοντέλο (η «τύχη»)

Η κρίσιμη φράση: «Κρατώντας σταθερές τις υπόλοιπες»

Αυτή η φράση (στα αγγλικά: «ceteris paribus» ή «holding all else constant») είναι η **καρδιά** της πολλαπλής παλινδρόμησης. Ας το εξηγήσουμε με παράδειγμα:
Ας υποθέσουμε ότι βρίσκουμε $\beta_{\text{alcohol}} = 0.272$. Αυτό σημαίνει:
«Αν πάρουμε δύο κρασιά που είναι **ακριβώς ίδια** σε ΟΛΑ τα χαρακτηριστικά τους (ίδια οξύτητα, ίδια σάκχαρα, ίδια πυκνότητα, κ.λπ.) αλλά το ένα έχει 1% περισσότερο αλκοόλ, τότε αναμένουμε αυτό με το περισσότερο αλκοόλ να βαθμολογηθεί $+0.272$ μονάδες υψηλότερα.»
Αυτή είναι η **καθαρή επίδραση** του αλκοόλ – δεν «μπερδεύεται» με κανέναν άλλο παράγοντα!
Αντίθεση με την απλή παλινδρόμηση: Στο Υποερώτημα 1 βρήκαμε $\beta_{\text{alcohol}} = 0.343$. Γιατί διαφέρει; Γιατί εκεί, η κλίση 0.343 περιλαμβάνει **και** την έμμεση επίδραση του αλκοόλ (π.χ. τα κρασιά με πολύ αλκοόλ τυχαίνει να έχουν και χαμηλή πτητική οξύτητα, που κι αυτή βελτιώνει την ποιότητα). Η πολλαπλή παλινδρόμηση «καθαρίζει» αυτές τις

αλληλεπιδράσεις.

3.1.3 Πώς υπολογίζεται η πολλαπλή παλινδρόμηση;

Η μέθοδος OLS στην πολλαπλή παλινδρόμηση

Όπως και στην απλή παλινδρόμηση, η μέθοδος **Ελαχίστων Τετραγώνων** (OLS) βρίσκει τους συντελεστές $\beta_0, \beta_1, \ldots, \beta_p$ που ελαχιστοποιούν το άθροισμα των τετραγώνων των σφαλμάτων:

$$\min_{\beta_0,\beta_1,\ldots,\beta_p} \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_{i1} - \beta_2 X_{i2} - \cdots - \beta_p X_{ip})^2 \tag{6}$$

Απλοποίηση: Φανταστείτε ότι κάθε παρατήρηση (κρασί) είναι ένα σημείο σε έναν 12-διάστατο χώρο (11 μεταβλητές + ποιότητα). Η OLS βρίσκει το «υπερεπίπεδο» (ένα επίπεδο σε πολλές διαστάσεις – η γενίκευση μιας ευθείας γραμμής) που περνάει όσο πιο κοντά γίνεται σε όλα τα σημεία.
Δεν χρειάζεται να κατανοήσετε τα μαθηματικά σε βάθος – ο υπολογιστής τα κάνει αυτόματα! Αυτό που χρειάζεται να κατανοήσετε είναι τι **σημαίνουν** τα αποτελέσματα.

3.1.4 Ο διορθωμένος R^2: Γιατί χρειαζόμαστε νέο δείκτη;

title

Στο Υποερώτημα 1 χρησιμοποιήσαμε τον R^2 για να μετρήσουμε πόσο καλά εξηγεί το μοντέλο τα δεδομένα. Αλλά ο R^2 έχει ένα σοβαρό ελάττωμα στην πολλαπλή παλινδρόμηση:
Κάθε φορά που προσθέτουμε μια μεταβλητή, ο R^2 αυξάνεται ή μένει ίδιος – ΠΟΤΕ δεν μειώνεται. Ακόμα κι αν βάλουμε εντελώς τυχαίες μεταβλητές (π.χ. τον αριθμό εγγραφής κάθε κρασιού), ο R^2 θα αυξηθεί λίγο!
Αυτό συμβαίνει γιατί ο R^2 «επιβραβεύει» κάθε νέα μεταβλητή, χωρίς να «τιμωρεί» την αυξημένη πολυπλοκότητα.

Λύση: Ο διορθωμένος R^2_{adj}

Ο **διορθωμένος** R^2 (adjusted R^2) λύνει αυτό το πρόβλημα:

$$R^2_{adj} = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1} \tag{7}$$

όπου:

- n = αριθμός παρατηρήσεων (στα δεδομένα μας: 5.274 κρασιά)
- p = αριθμός μεταβλητών στο μοντέλο (στα δεδομένα μας: 11)

Πώς λειτουργεί: Ο R^2_{adj} προσθέτει μια «ποινή» για κάθε νέα μεταβλητή. Αν η νέα μεταβλητή βελτιώνει αρκετά το μοντέλο, ο R^2_{adj} αυξάνεται. Αν δεν βελτιώνει αρκετά, ο R^2_{adj} **μειώνεται** – σήμα ότι η μεταβλητή δεν αξίζει τον κόπο.

Αναλογία: R^2 vs R^2_{adj} στο ψώνισμα

Φανταστείτε ότι ψωνίζετε ρούχα:

- Ο R^2 είναι σαν να μετράτε πόσο «ωραία φαίνεστε» κάθε φορά που αγοράζετε ένα νέο ρούχο. Πάντα νιώθετε λίγο πιο ωραία – ακόμα κι αν το ρούχο δεν ταιριάζει!
- Ο R^2_{adj} είναι σαν να βάζετε και τον **λογαριασμό** στην εξίσωση. Ναι, φαίνεστε λίγο πιο ωραία, αλλά **αξίζει τα λεφτά**; Αν δεν αξίζει, ο R^2_{adj} πέφτει – λέγοντάς σας «μην το αγοράσεις».

3.1.5 Ο F-έλεγχος: Αξίζει καν το μοντέλο μας;

Πριν αναλύσουμε κάθε μεταβλητή ξεχωριστά, πρέπει πρώτα να απαντήσουμε ένα πιο βασικό ερώτημα: «Αξίζει **καν** αυτό το μοντέλο; Μήπως **καμία** μεταβλητή δεν βοηθάει;»

Ορισμός: F-έλεγχος – «Είναι χρήσιμο το μοντέλο;»

Ο **F-έλεγχος** (F-test) είναι ένας «ομαδικός» έλεγχος που εξετάζει αν **τουλάχιστον μία** μεταβλητή βοηθάει:

- $H_0 : \beta_1 = \beta_2 = \cdots = \beta_p = 0$

  Μηδενική υπόθεση: «ΚΑΝΕΝΑΣ παράγοντας δεν επηρεάζει την ποιότητα. Τα 11 χημικά χαρακτηριστικά είναι εντελώς άσχετα.»

- H_1 : Τουλάχιστον ένα $\beta_j \neq 0$

  Εναλλακτική υπόθεση: «ΕΣΤΩ ΚΑΙ ΕΝΑΣ παράγοντας επηρεάζει την ποιότητα.»

Η στατιστική F συγκρίνει δύο μοντέλα:

1. Το **«κενό» μοντέλο**: Χωρίς μεταβλητές (quality = μέσος όρος)
2. Το **«πλήρες» μοντέλο**: Με όλες τις μεταβλητές

Αν το πλήρες μοντέλο δεν εξηγεί **σημαντικά περισσότερα** από το κενό, τότε η F θα είναι μικρή και η p-value μεγάλη.
Κανόνας: Αν η p-value του F-test < 0.05, τότε το μοντέλο συνολικά είναι σημαντικό – τουλάχιστον ΜΙΑ μεταβλητή βοηθάει.

Πώς υπολογίζεται η στατιστική F;

Ο τύπος της F βασίζεται σε μια απλή ιδέα: **πόσο καλύτερα εξηγεί το μοντέλο μας τα δεδομένα σε σχέση με ένα μοντέλο χωρίς μεταβλητές;**
Για να το μετρήσουμε, χρειαζόμαστε τρεις ποσότητες:

- $SS_{reg} = \sum_{i=1}^{n}(\hat{Y}_i - \bar{Y})^2$: η **μεταβλητότητα που εξηγεί** το μοντέλο (πόσο οι προβλέψεις μας απομακρύνονται από τον μέσο όρο)
- $SS_{res} = \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$: η **μεταβλητότητα που ΔΕΝ εξηγεί** το μοντέλο (τα «σφάλματα» – πόσο οι πραγματικές τιμές απομακρύνονται από τις προβλέψεις)
- p = αριθμός μεταβλητών, n = αριθμός παρατηρήσεων

Ο τύπος είναι:

$$F = \frac{SS_{reg}/p}{SS_{res}/(n-p-1)} = \frac{\text{«εξηγούμενη μεταβλητότητα ανά μεταβλητή»}}{\text{«ανεξήγητη μεταβλητότητα ανά παρατήρηση»}} \tag{8}$$

Γιατί διαιρούμε; Επειδή δεν είναι δίκαιο να συγκρίνουμε απευθείας τα αθροίσματα. Ένα μοντέλο με 11 μεταβλητές «σπαταλάει» 11 βαθμούς ελευθερίας για να εξηγήσει, ενώ τα σφάλματα κατανέμονται σε $n - p - 1$ βαθμούς. Η διαίρεση «κανονικοποιεί» ώστε η σύγκριση να είναι δίκαιη.

Αναλογία: Η F ως «αξιολόγηση επένδυσης»

Φανταστείτε ότι μια εταιρεία προσλαμβάνει 11 υπαλλήλους (= 11 μεταβλητές) για να αυξήσει τα κέρδη (= να εξηγήσει την ποιότητα):

- Ο **αριθμητής** (SS_{reg}/p) μετράει: «Πόσα κέρδη φέρνει **κατά μέσο όρο** κάθε υπάλληλος;»
- Ο **παρονομαστής** ($SS_{res}/(n-p-1)$) μετράει: «Πόση «αταξία» παραμένει στην εταιρεία;»
- Αν F είναι μεγάλο: Οι υπάλληλοι φέρνουν πολλά κέρδη σε σχέση με την αταξία $\Rightarrow$ η πρόσληψή τους **άξιζε**
- Αν $F \approx 1$: Οι υπάλληλοι δεν κάνουν σχεδόν τίποτα παραπάνω $\Rightarrow$ δεν άξιζε

Στα δεδομένα μας, $F = 183.41$ – τεράστιο νούμερο! Οι 11 «υπάλληλοι» (μεταβλητές) αποδίδουν 183 φορές περισσότερο από ό,τι θα περιμέναμε αν δεν έκαναν τίποτα.

Πώς παίρνουμε την p-value από την F;

Αφού υπολογίσαμε την τιμή F, πρέπει να ρωτήσουμε: «Πόσο πιθανό είναι να δούμε τόσο μεγάλη F **αν δεν υπήρχε καμία σχέση**;»
Η απάντηση δίνεται από την **κατανομή F** (F-distribution) με παραμέτρους $df_1 = p$ και $df_2 = n-p-1$. Η p-value είναι η πιθανότητα η κατανομή F να δώσει τιμή τόσο ακραία ή ακραιότερη:

$$\text{p-value} = P(F_{df_1,df_2} \geq F_{\text{παρατηρούμενη}})$$

Στην πράξη, **ο υπολογιστής κάνει αυτόν τον υπολογισμό αυτόματα**. Εμείς χρειάζεται μόνο να συγκρίνουμε την p-value με το 0.05:

- Στα δεδομένα μας: $F = 183.41$ με $df_1 = 11$ και $df_2 = 5262$
- Η p-value ≈ 0 (τόσο μικρή που ο υπολογιστής δεν μπορεί καν να την εμφανίσει)
- **Συμπέρασμα**: Απορρίπτουμε την H_0 – το μοντέλο μας σίγουρα βοηθάει!

Προσοχή: Ο F-έλεγχος δεν μας λέει ΠΟΙΕΣ μεταβλητές βοηθούν!

Ο F-έλεγχος μας λέει μόνο «ναι, κάτι λειτουργεί εδώ μέσα». ΔΕΝ μας λέει ποια μεταβλητή είναι σημαντική. Είναι σαν να μυρίζετε ένα πιάτο φαγητό και να λέτε «ναι, έχει μπαχαρικά» – αλλά δεν ξέρετε ακόμα ΠΟΙΑ μπαχαρικά. Γι' αυτό χρειαζόμαστε τον **t-έλεγχο** για κάθε μεταβλητή ξεχωριστά (βλ. παρακάτω).

3.1.6 Ο t-έλεγχος κάθε μεταβλητής: «Βοηθάει αυτή η μεταβλητή;»

Ορισμός: Μερικός t-έλεγχος στην πολλαπλή παλινδρόμηση

Αφού ξέρουμε ότι τουλάχιστον μία μεταβλητή βοηθάει (F-test), πρέπει τώρα να ρωτήσουμε για κάθε μεταβλητή **ξεχωριστά**:
«Η μεταβλητή X_j βοηθάει, **δεδομένου** ότι ήδη έχουμε όλες τις υπόλοιπες;»
Αυτό γίνεται με τον **μερικό t-έλεγχο**:

- $H_0 : \beta_j = 0$ («Η μεταβλητή X_j δεν προσφέρει τίποτα επιπλέον»)
- $H_1 : \beta_j \neq 0$ («Η μεταβλητή X_j έχει κάποια μοναδική συνεισφορά»)

Η στατιστική t υπολογίζεται ως:

$$t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \tag{9}$$

όπου:

- $\hat{\beta}_j$ = η εκτίμηση του συντελεστή (πόσο αλλάζει η ποιότητα ανά μονάδα)
- $SE(\hat{\beta}_j)$ = το τυπικό σφάλμα (πόσο «αβέβαιοι» είμαστε για αυτήν την εκτίμηση)

Λογική: Αν ο $\hat{\beta}_j$ είναι μεγάλος σε σχέση με την αβεβαιότητά του (μεγάλο $|t|$), τότε είμαστε αρκετά σίγουροι ότι η μεταβλητή πραγματικά βοηθάει.

Αναλογία: Ο t-έλεγχος ως «σήμα vs θόρυβος»

Φανταστείτε ότι ακούτε ένα ραδιόφωνο:

- Ο $\hat{\beta}_j$ είναι η ένταση του **σήματος** (η πληροφορία)
- Ο $SE(\hat{\beta}_j)$ είναι η ένταση του **θορύβου** (η αβεβαιότητα)
- Η στατιστική $t = \frac{\text{σήμα}}{\text{θόρυβος}}$ μας λέει αν μπορούμε να «ακούσουμε» καθαρά τη μεταβλητή μέσα από τον θόρυβο των δεδομένων

Αν $|t|$ είναι μεγάλο (π.χ. > 2), ο σταθμός ακούγεται καθαρά $\Rightarrow$ η μεταβλητή είναι σημαντική.
Αν $|t|$ είναι μικρό (π.χ. ≈ 1), ο θόρυβος καλύπτει το σήμα $\Rightarrow$ δεν μπορούμε να πούμε αν η μεταβλητή βοηθάει.

3.1.7 Τι σημαίνει «Standard Error» (τυπικό σφάλμα);

Ορισμός: Τυπικό Σφάλμα (SE)

Το **τυπικό σφάλμα** μας λέει πόσο **αβέβαιη** είναι η εκτίμησή μας. Φανταστείτε ότι κάνετε ένα πείραμα 100 φορές – κάθε φορά θα βρίσκατε λίγο διαφορετικό $\hat{\beta}_j$. Το SE μετράει πόσο θα «κουνιούνταν» αυτή η εκτίμηση:

- **Μικρό SE**: Η εκτίμηση είναι σταθερή, αξιόπιστη
- **Μεγάλο SE**: Η εκτίμηση «τρεμοπαίζει», δεν είμαστε σίγουροι

Γι' αυτό ο t-έλεγχος διαιρεί τον $\hat{\beta}_j$ με το SE: αν ο $\hat{\beta}_j$ είναι πολύ μεγαλύτερος από το SE, τότε η αβεβαιότητα δεν αρκεί για να «εξαφανίσει» την επίδραση.

3.2 Εφαρμογή στα δεδομένα μας

3.2.1 Τι ακριβώς κάναμε

Εφαρμόσαμε ένα μοντέλο πολλαπλής παλινδρόμησης με **όλες τις 11 μεταβλητές ταυτόχρονα**:

$$\text{quality} = \beta_0 + \beta_1 \cdot \text{fixed_acidity} + \beta_2 \cdot \text{volatile_acidity} + \cdots + \beta_{11} \cdot \text{alcohol} + \varepsilon$$

Δηλαδή, ζητήσαμε από τον υπολογιστή να βρει τις τιμές $\beta_0, \beta_1, \ldots, \beta_{11}$ που κάνουν τις προβλέψεις του μοντέλου **όσο πιο κοντά γίνεται** στις πραγματικές βαθμολογίες ποιότητας.

3.2.2 Αποτελέσματα: Ο πίνακας συντελεστών

Πίνακας 2: Συντελεστές πολλαπλής γραμμικής παλινδρόμησης

Μεταβλητή	$\hat{\beta}_j$	**SE**	**t-stat**	**p-value**	H_0
Σταθερά (const)	44.231	8.847	5.000	5.92×10^{-7}	Απορρίπτεται
fixed acidity	0.0417	0.014	3.025	2.50×10^{-3}	Απορρίπτεται
volatile acidity	-1.250	0.087	-14.39	4.43×10^{-46}	Απορρίπτεται
citric acid	0.131	0.088	1.485	1.38×10^{-1}	**Δεν απορρ.**
residual sugar	0.0289	0.004	7.089	1.53×10^{-12}	Απορρίπτεται
chlorides	-1.354	0.369	-3.672	2.43×10^{-4}	Απορρίπτεται
free sulfur dioxide	0.0070	0.001	8.261	1.81×10^{-16}	Απορρίπτεται
total sulfur dioxide	-0.0030	0.0003	-9.837	1.22×10^{-22}	Απορρίπτεται
density	-43.09	9.006	-4.785	1.76×10^{-6}	Απορρίπτεται
pH	0.408	0.088	4.616	4.00×10^{-6}	Απορρίπτεται
sulphates	0.773	0.083	9.342	1.36×10^{-20}	Απορρίπτεται
alcohol	0.272	0.015	18.51	4.00×10^{-74}	Απορρίπτεται

Πώς διαβάζω αυτόν τον πίνακα;

Ας πάρουμε ένα παράδειγμα – τη γραμμή του **alcohol**:

- $\hat{\beta} = 0.272$: Κρατώντας σταθερά ΟΛΑ τα άλλα χαρακτηριστικά, κάθε 1% αύξηση αλκοόλ αυξάνει την ποιότητα κατά 0.272 βαθμούς
- $SE = 0.015$: Η αβεβαιότητα αυτής της εκτίμησης (πολύ μικρή – άρα είμαστε σίγουροι)
- $t = 18.51$: Ο λόγος $\frac{0.272}{0.015} = 18.51$ (τεράστιος – πολύ ξεκάθαρο σήμα)
- $p = 4.00 \times 10^{-74}$: Η πιθανότητα αυτό να είναι τυχαίο (ουσιαστικά ΜΗΔΕΝ)
- H_0: Απορρίπτεται – ΝΑΙ, το αλκοόλ πράγματι επηρεάζει την ποιότητα

Τώρα ας δούμε τη γραμμή του **citric acid**:

- $\hat{\beta} = 0.131$: Φαίνεται να υπάρχει μικρή θετική επίδραση
- $SE = 0.088$: Η αβεβαιότητα (σχεδόν τόσο μεγάλη όσο η ίδια η εκτίμηση!)
- $t = 1.485$: Μικρό – το σήμα δεν ξεχωρίζει από τον θόρυβο
- $p = 0.138$: 13.8% πιθανότητα να είναι τυχαίο $> 5\%$ (κατώφλι)
- H_0: **Δεν απορρίπτεται** – ΔΕΝ μπορούμε να πούμε ότι το citric acid βοηθάει

3.2.3 Στατιστικά συνολικού μοντέλου

Συνολική αξιολόγηση μοντέλου

Στατιστικά μοντέλου:

- $R^2 = 0.2771$ – Το μοντέλο εξηγεί **27.7%** της μεταβλητότητας της ποιότητας
- $R^2_{adj} = 0.2756$ – Σχεδόν ίδιο, σημαίνει ότι οι μεταβλητές μας δεν είναι «περιττές»
- $F = 183.41$, $p \approx 0$ – Το μοντέλο είναι **συνολικά σημαντικό** (τουλάχιστον κάτι βοηθάει – πράγματι, σχεδόν τα ΠΑΝΤΑ βοηθούν!)
- $AIC = 11880.85$, $BIC = 11959.70$ – Κριτήρια πληροφορίας (θα τα συγκρίνουμε αργότερα)

title

Η ποιότητα κρασιού βαθμολογείται από 0 έως 10. Αν πάρουμε ΟΛΑ τα 5.274 κρασιά μας, οι βαθμολογίες τους ποικίλλουν (π.χ. κάποιο παίρνει 3, κάποιο 8). Αυτή η ποικιλία ονομάζεται «μεταβλητότητα».
Το $R^2 = 27.7\%$ σημαίνει: «Από όλη αυτή τη μεταβλητότητα, μπορούμε να εξηγήσουμε μόνο το 27.7% χρησιμοποιώντας τα 11 χημικά χαρακτηριστικά. Το υπόλοιπο 72.3% οφείλεται σε παράγοντες που δεν μετράμε.»
Γιατί τόσο χαμηλό; Η ποιότητα κρασιού εξαρτάται από πολλούς παράγοντες που δεν περιλαμβάνονται στα δεδομένα μας:

- Η ποικιλία σταφυλιού, η ηλικία, η μέθοδος ζύμωσης
- Τα γούστα του αξιολογητή (υποκειμενικότητα!)
- Η θερμοκρασία σερβιρίσματος, το φαγητό που συνοδεύει

Αλλά δεν πειράζει – ακόμα κι αυτό το 27.7% μας δίνει **πολύτιμη πληροφορία** για τη σχέση χημείας-ποιότητας.

3.3 Ερμηνεία: Για ποιες μεταβλητές απορρίπτεται η $H_0 : \beta_j = 0$;

Κεντρικό εύρημα

Η μηδενική υπόθεση $H_0 : \beta_j = 0$ **απορρίπτεται** για **10 από τις 11** μεταβλητές σε επίπεδο σημαντικότητας $\alpha = 0.05$. Η **μοναδική εξαίρεση** είναι το **citric acid** (κιτρικό οξύ) με $p = 0.138 > 0.05$.
Τι σημαίνει αυτό σε απλά λόγια: Από τα 11 χημικά χαρακτηριστικά που μετρήσαμε, τα **10 πράγματι επηρεάζουν** την ποιότητα του κρασιού (ακόμα κι αν μερικά πολύ λίγο). Μόνο το κιτρικό οξύ δεν φαίνεται να βοηθάει – τουλάχιστον, όχι αν ήδη ξέρουμε τα υπόλοιπα 10 χαρακτηριστικά.

3.3.1 Η «μυστηριώδης» περίπτωση του citric acid

Αυτό είναι ένα πολύ ενδιαφέρον αποτέλεσμα! Στο Υποερώτημα 1, το citric acid ήταν **στατιστικά σημαντικό** ($p = 7.54 \times 10^{-12}$). Πώς γίνεται τώρα να μην είναι;

Γιατί αλλάζει η σημαντικότητα: Η έννοια της πολυσυγγραμμικότητας

Αυτό το φαινόμενο ονομάζεται **πολυσυγγραμμικότητα** (multicollinearity) και είναι ένα από τα πιο σημαντικά concepts στην πολλαπλή παλινδρόμηση. Ας το εξηγήσουμε βήμα-βήμα:

1. **Στην απλή παλινδρόμηση**: Ρωτήσαμε «Σχετίζεται το citric acid με την ποιότητα;» Η απάντηση ήταν ΝΑΙ ($p < 0.001$). Αυτό είναι η **ολική** επίδραση.

2. **Στην πολλαπλή παλινδρόμηση**: Ρωτάμε κάτι ΔΙΑΦΟΡΕΤΙΚΟ: «Αν ήδη ξέρω τις τιμές ΟΛΩΝ των άλλων μεταβλητών (αλκοόλ, πτητική οξύτητα, κ.λπ.), μου δίνει κάτι ΠΑΡΑΠΑΝΩ η γνώση του citric acid;» Η απάντηση είναι ΟΧΙ ($p = 0.138$).

3. **Γιατί;** Το citric acid συσχετίζεται ισχυρά με άλλες μεταβλητές, ιδιαίτερα τη volatile acidity και τη fixed acidity (και τα τρία είναι «οξέα» του κρασιού). Η πληροφορία που φέρνει «απορροφάται» από αυτές τις μεταβλητές.

Αναλογία: Δύο θερμόμετρα στο ίδιο δωμάτιο

Φανταστείτε ότι θέλετε να προβλέψετε αν κάποιος θα κρυώσει. Έχετε δύο «μεταβλητές»:

- Θερμόμετρο Α: μετράει τη θερμοκρασία σε Κελσίου
- Θερμόμετρο Β: μετράει τη θερμοκρασία σε Φαρενάιτ

Μόνο του, καθένα σχετίζεται **πολύ** με το κρύωμα (απλή παλινδρόμηση: $p \approx 0$ για αμφότερα). Αλλά αν βάλετε **και τα δύο** σε ένα μοντέλο πολλαπλής παλινδρόμησης, ένα από τα δύο θα φανεί «μη σημαντικό» – γιατί αν ήδη ξέρεις τους Κελσίου, ΔΕΝ μαθαίνεις τίποτα νέο βλέποντας τους Φαρενάιτ!
Αυτό ακριβώς συμβαίνει με το citric acid: η πληροφορία του **αλληλοεπικαλύπτεται** τόσο πολύ με τα υπόλοιπα οξέα, που γίνεται «περιττή».

3.4 Αναλυτική ερμηνεία κάθε μεταβλητής

Ας δούμε τώρα τι ακριβώς σημαίνει ο κάθε συντελεστής $\hat{\beta}_j$ – δηλαδή, πώς επηρεάζει **πρακτικά** κάθε χημικό χαρακτηριστικό την ποιότητα του κρασιού.

3.4.1 Μεταβλητές με θετική επίδραση

Αυτές οι μεταβλητές, όταν αυξάνονται, η ποιότητα τείνει να **βελτιώνεται**:

1. **alcohol** ($\hat{\beta} = 0.272$, $p \approx 10^{-74}$): Η **σημαντικότερη** μεταβλητή! Κάθε 1% αύξηση αλκοόλ αυξάνει την ποιότητα κατά 0.272 βαθμούς. Η πολύ μικρή p-value ($\approx 10^{-74}$, δηλαδή 74 μηδενικά μετά την υποδιαστολή!) σημαίνει ότι αυτό δεν οφείλεται σε τύχη.

2. **sulphates** ($\hat{\beta} = 0.773$, $p \approx 10^{-20}$): Τα θειικά βελτιώνουν την ποιότητα. Δρουν ως αντιμικροβιακά και αντιοξειδωτικά, προστατεύοντας το κρασί.

3. **pH** ($\hat{\beta} = 0.408$, $p \approx 10^{-6}$): Υψηλότερο pH (λιγότερη οξύτητα) σχετίζεται με ελαφρώς καλύτερη ποιότητα.

4. **fixed acidity** ($\hat{\beta} = 0.042$, $p = 0.0025$): Η σταθερή οξύτητα βοηθάει ελαφρώς. Αυτό μπορεί να αντανακλά δομή και σώμα στο κρασί.

5. **free sulfur dioxide** ($\hat{\beta} = 0.007$, $p \approx 10^{-16}$): Τα ελεύθερα θειώδη βοηθούν – προστατεύουν από οξείδωση.

6. **residual sugar** ($\hat{\beta} = 0.029$, $p \approx 10^{-12}$): Λίγο παραπάνω υπολειπόμενο σάκχαρο βοηθάει ελαφρώς.

3.4.2 Μεταβλητές με αρνητική επίδραση

Αυτές οι μεταβλητές, όταν αυξάνονται, η ποιότητα τείνει να **χειροτερεύει**:

1. **volatile acidity** ($\hat{\beta} = -1.250$, $p \approx 10^{-46}$): Ο **ισχυρότερος αρνητικός** παράγοντας! Η πτητική οξύτητα σχετίζεται με οσμές και γεύσεις ξυδιού – λογικό να μειώνει την ποιότητα.

2. **total sulfur dioxide** ($\hat{\beta} = -0.003$, $p \approx 10^{-22}$): Αντίθετα από τα **ελεύθερα** θειώδη (θετική επίδραση), τα **ολικά** θειώδη (ελεύθερα + δεσμευμένα) έχουν αρνητική επίδραση. Τα δεσμευμένα θειώδη μπορεί να δημιουργούν δυσάρεστες οσμές.

3. **density** ($\hat{\beta} = -43.09$, $p \approx 10^{-6}$): Υψηλότερη πυκνότητα = χαμηλότερη ποιότητα.

4. **chlorides** ($\hat{\beta} = -1.354$, $p = 0.00024$): Τα χλωριούχα (αλάτια) μειώνουν την ποιότητα. Πολύ αλάτι = κακό κρασί!

Προσοχή: Μη συγκρίνετε τα $\hat{\beta}$ μεταξύ τους χωρίς προσοχή!

Μπορεί να βλέπετε $\hat{\beta}_{\text{density}} = -43.09$ και να σκεφτείτε «Η πυκνότητα είναι ο σημαντικότερος παράγοντας!». Αλλά αυτό είναι **παραπλανητικό**.
Ο λόγος: οι μεταβλητές έχουν **διαφορετικές κλίμακες μέτρησης**:

- Η πυκνότητα κυμαίνεται σε **πολύ στενό εύρος** (≈ 0.990 – 1.004). Μια «μεγάλη» αλλαγή πυκνότητας είναι μόλις 0.005 μονάδες.
- Η πραγματική αλλαγή στην ποιότητα: $0.005 \times (-43.09) = -0.22$ βαθμοί
- Το αλκοόλ κυμαίνεται σε **ευρύ εύρος** (≈ 8 – 15). Μια «μεγάλη» αλλαγή αλκοόλ είναι 3 μονάδες.
- Η πραγματική αλλαγή στην ποιότητα: $3 \times 0.272 = +0.82$ βαθμοί

Συμπέρασμα: Στην πράξη, το **αλκοόλ** επηρεάζει πολύ περισσότερο την ποιότητα από ό,τι η πυκνότητα, παρόλο που ο συντελεστής του φαίνεται μικρότερος!
Για σωστή σύγκριση θα έπρεπε να χρησιμοποιήσουμε **τυποποιημένους συντελεστές** (standardized coefficients), αλλά αυτό ξεφεύγει από τους σκοπούς αυτής της εργασίας.

3.4.3 Σύγκριση: Απλή vs Πολλαπλή Παλινδρόμηση

Τι αλλάζει μεταξύ Υποερωτήματος 1 και 2;

Ας συγκρίνουμε μερικά ενδεικτικά αποτελέσματα:

Μεταβλητή	$\hat{\beta}$ **(Απλή)**	**p (Απλή)**	$\hat{\beta}$ **(Πολλαπλή)**	**p (Πολλαπλή)**
alcohol	$+0.343$	≈ 0	$+0.272$	≈ 0
volatile acidity	-1.386	≈ 0	-1.250	≈ 0
citric acid	$+0.566$	10^{-12}	$+0.131$	0.138
residual sugar	-0.010	10^{-4}	$+0.029$	10^{-12}

Τρία ενδιαφέροντα πράγματα:

1. Ο $\hat{\beta}$ του **alcohol μείωσε** από 0.343 σε 0.272. Γιατί; Στην απλή παλινδρόμηση, μέρος της «επίδρασης» του αλκοόλ ήταν στην πραγματικότητα η επίδραση **άλλων** μεταβλητών (π.χ. πυκνότητα, σάκχαρα) που συσχετίζονται με το αλκοόλ. Τώρα που τις ελέγχουμε, η καθαρή επίδραση είναι μικρότερη.

2. Το **citric acid** έγινε μη σημαντικό. Η πληροφορία του «κρύφτηκε» πίσω από τα άλλα οξέα.

3. Το **residual sugar άλλαξε πρόσημο**! Στην απλή παλινδρόμηση ήταν αρνητικό (-0.010), τώρα είναι θετικό ($+0.029$). Αυτό ονομάζεται **παράδοξο Simpson** (Simpson's paradox) – η κατεύθυνση μιας σχέσης μπορεί να αντιστραφεί αν ελέγξουμε για άλλες μεταβλητές! Πιθανή εξήγηση: τα κρασιά με πολλά σάκχαρα τείνουν να έχουν χαμηλό αλκοόλ (αρνητική φαινομενική σχέση), αλλά **δεδομένου ίδιου αλκοόλ**, λίγο παραπάνω σάκχαρο βοηθάει τη γεύση.

4 Πρόσω Επιλογή Μεταβλητών (Υποερώτημα 3)

4.1 Θεωρητικό υπόβαθρο

4.1.1 Το πρόβλημα: Γιατί χρειαζόμαστε επιλογή μεταβλητών;

Στο Υποερώτημα 2 κατασκευάσαμε ένα μοντέλο πολλαπλής παλινδρόμησης που περιλαμβάνει και τις 11 μεταβλητές. Αυτό μπορεί να φαίνεται λογικό («βάλε τα πάντα, μπας και βγει κάτι»), αλλά στη στατιστική δεν είναι πάντα η σωστή στρατηγική. Ας δούμε γιατί.

title

Φανταστείτε ότι θέλετε να προβλέψετε τον βαθμό σας σε ένα μάθημα. Θα μπορούσατε να μετρήσετε δεκάδες παράγοντες: ώρες μελέτης, ώρες ύπνου, θερμοκρασία δωματίου, χρώμα στυλό, αριθμός σελίδων βιβλίου, κ.λπ. Αλλά μήπως κάποιοι από αυτούς τους παράγοντες είναι **άχρηστοι** ή ακόμα **ζημιογόνοι** για το μοντέλο;
Τέσσερα σοβαρά προβλήματα προκύπτουν όταν βάζουμε πάρα πολλές μεταβλητές:

1. **Υπερπροσαρμογή** (overfitting): Το μοντέλο «μαθαίνει» τον θόρυβο αντί για τα πραγματικά μοτίβα. Σκεφτείτε το έτσι: αν βάλετε αρκετές μεταβλητές, μπορείτε να «εξηγήσετε» ακόμα και τυχαία δεδομένα. Αλλά αυτό δεν σημαίνει ότι το μοντέλο σας καταλαβαίνει πραγματικά τα δεδομένα – απλά τα αποστηθίζει. Αποτέλεσμα: το μοντέλο αποτυγχάνει σε νέα δεδομένα.

2. **Δυσκολία ερμηνείας**: Αν πω «η ποιότητα κρασιού εξαρτάται κυρίως από το αλκοόλ, την οξύτητα και τα θειώδη», αυτό είναι κατανοητό και χρήσιμο. Αν πω «εξαρτάται από 11 μεταβλητές με πολύπλοκες αλληλεπιδράσεις», κανείς δεν μπορεί να αξιοποιήσει αυτήν την πληροφορία στην πράξη.

3. **Πολυσυγγραμμικότητα** (multicollinearity): Κάποιες μεταβλητές μπορεί να μετρούν ουσιαστικά το ίδιο πράγμα. Π.χ. η πυκνότητα (density) σχετίζεται στενά με το αλκοόλ και τα υπολειπόμενα σάκχαρα. Αν βάλουμε και τα τρία, «μπερδεύεται» το μοντέλο ως προς το ποια μεταβλητή πραγματικά επηρεάζει την ποιότητα.

4. **Αρχή της φειδωλότητας** (parsimony / Occam's razor): Η επιστημονική μέθοδος προτιμά τα **απλούστερα** μοντέλα που εξηγούν επαρκώς τα δεδομένα. Αν δύο μοντέλα δίνουν σχεδόν ίδια αποτελέσματα, αυτό με τις λιγότερες μεταβλητές είναι προτιμότερο.

Κίνδυνος: Γιατί δεν δοκιμάζουμε «όλους τους συνδυασμούς»;

Μια αφελής προσέγγιση θα ήταν: «Δοκίμασε όλους τους δυνατούς συνδυασμούς μεταβλητών και κράτα τον καλύτερο». Αυτή η μέθοδος λέγεται **εξαντλητική αναζήτηση** (exhaustive search). Ακούγεται λογικό, αλλά υπάρχει ένα πρόβλημα:
Με 11 μεταβλητές, οι δυνατοί συνδυασμοί είναι $2^{11} - 1 = 2047$. Αυτό είναι ακόμα εφικτό. Αλλά αν είχαμε 50 μεταβλητές; Τότε θα ήταν $2^{50} \approx 10^{15}$ συνδυασμοί – αδύνατο να δοκιμαστούν όλοι! Γι' αυτό χρειαζόμαστε «έξυπνες» μεθόδους που βρίσκουν ένα καλό μοντέλο χωρίς να δοκιμάσουν τα πάντα.

4.1.2 Οι τρεις βασικές μέθοδοι επιλογής μεταβλητών

Πριν εμβαθύνουμε στην πρόσω επιλογή, ας δούμε συνοπτικά τις τρεις κύριες βηματικές μεθόδους:

Οι τρεις βηματικές μέθοδοι

1. **Πρόσω επιλογή** (Forward Selection): Ξεκινάμε χωρίς μεταβλητές και **προσθέτουμε** μία-μία τις πιο σημαντικές. Είναι σαν να χτίζουμε ένα σπίτι τούβλο-τούβλο.
2. **Οπίσθια αφαίρεση** (Backward Elimination): Ξεκινάμε με **όλες** τις μεταβλητές και **αφαιρούμε** μία-μία τις λιγότερο σημαντικές. Είναι σαν να σκαλίζουμε ένα άγαλμα αφαιρώντας μάρμαρο.
3. **Αμφίδρομη επιλογή** (Stepwise / Bidirectional): Συνδυασμός των δύο – σε κάθε βήμα μπορούμε τόσο να προσθέσουμε όσο και να αφαιρέσουμε μεταβλητές.

Στην εργασία μας χρησιμοποιούμε την πρόσω επιλογή, γιατί είναι η πιο διαισθητική μέθοδος και μας δείχνει καθαρά τη σειρά σπουδαιότητας των μεταβλητών.

4.1.3 Η μέθοδος πρόσω επιλογής – Βήμα προς βήμα

Ορισμός: Forward Selection

Η **πρόσω επιλογή** (forward selection) είναι μια **βηματική** (stepwise) μέθοδος επιλογής μεταβλητών. Ο αλγόριθμος λειτουργεί ως εξής:

1. **Αρχικοποίηση**: Ξεκινάμε με ένα «κενό» μοντέλο που περιέχει μόνο τη **σταθερά** β_0 (δηλαδή $\hat{Y} = \bar{Y}$, ο μέσος όρος). Αυτό είναι η βάση αναφοράς μας.
2. **Βήμα 1 – Εύρεση του καλύτερου μοναδικού προβλέπτη**:
   - Φτιάχνουμε 11 ξεχωριστά μοντέλα, ένα για κάθε μεταβλητή

(quality $\sim$ alcohol, quality $\sim$ volatile acidity, κ.λπ.)

- Για κάθε μοντέλο, ελέγχουμε αν η μεταβλητή είναι στατιστικά σημαντική (p-value)
- Η μεταβλητή με τη **μικρότερη p-value** (εφόσον $p < 0.05$) μπαίνει στο μοντέλο

3. **Βήμα 2 – Εύρεση του καλύτερου δεύτερου προβλέπτη**:
   - Κρατώντας τη μεταβλητή του Βήματος 1, φτιάχνουμε 10 νέα μοντέλα (ένα για κάθε εναπομείνασα μεταβλητή)
   - **Προσοχή**: Η p-value που ελέγχουμε τώρα δεν είναι η ίδια με αυτή της απλής παλινδρόμησης! Είναι η p-value **δεδομένου** ότι η πρώτη μεταβλητή ήδη υπάρχει στο μοντέλο. Δηλαδή: «Πόσο βοηθάει αυτή η νέα μεταβλητή **πέρα από** αυτήν που ήδη έχουμε;»
   - Η καλύτερη μπαίνει (αν $p < 0.05$)
4. **Βήματα 3, 4, ...**: Η ίδια διαδικασία επαναλαμβάνεται. Κάθε φορά ρωτάμε: «Ποια μεταβλητή προσφέρει τη μεγαλύτερη **επιπλέον** πληροφορία, δεδομένων αυτών που ήδη έχουμε;»
5. **Τερματισμός**: Ο αλγόριθμος σταματά όταν καμία εναπομείνασα μεταβλητή δεν πληροί το κριτήριο $p < 0.05$. Δηλαδή, κανένας νέος «παίκτης» δεν βελτιώνει σημαντικά την «ομάδα».

Αναλογία: Φτιάξε μια ομάδα ποδοσφαίρου

Η forward selection μοιάζει πάρα πολύ με τη δημιουργία μιας ποδοσφαιρικής ομάδας μέσω draft:

1. **Βήμα 1**: Πρώτα βάζεις τον **καλύτερο παίκτη** (αυτός που βοηθάει πιο πολύ μόνος του). Στην περίπτωσή μας, αυτός είναι το **alcohol** – η μεταβλητή που εξηγεί μόνη της τη μεγαλύτερη μεταβλητότητα.
2. **Βήμα 2**: Μετά δεν επιλέγεις τον δεύτερο καλύτερο παίκτη γενικά, αλλά αυτόν που **συμπληρώνει** καλύτερα τον πρώτο. Αν ο πρώτος είναι επιθετικός, ίσως χρειάζεσαι αμυντικό – όχι δεύτερο επιθετικό.
3. **Βήμα 3**: Τρίτος μπαίνει αυτός που βοηθάει πιο πολύ **δεδομένων** των δύο πρώτων.
4. **Τέλος**: Σταματάς όταν κανένας νέος παίκτης δεν βελτιώνει αρκετά σημαντικά την ομάδα. Ίσως ο 12ος παίκτης είναι καλός, αλλά δεν προσφέρει κάτι παραπάνω σε αυτήν τη συγκεκριμένη ομάδα.

Αυτό εξηγεί ένα σημαντικό φαινόμενο: Μια μεταβλητή που φαίνεται πολύ σημαντική στην απλή παλινδρόμηση (Υποερώτημα 1) μπορεί να μπει αργά στη forward selection, γιατί η πληροφορία της **αλληλοεπικαλύπτεται** με κάποια που ήδη μπήκε. Αντίστροφα, μια «αδύναμη» μεταβλητή μπορεί να μπει νωρίς αν δίνει **μοναδική** πληροφορία.

4.1.4 Η έννοια της «μοναδικής συνεισφοράς»

Βασική έννοια: Μερική vs Ολική συσχέτιση

Για να κατανοήσουμε γιατί η σειρά εισόδου στη forward selection διαφέρει από τη σημαντικότητα στην απλή παλινδρόμηση, πρέπει να κατανοήσουμε τη διαφορά μεταξύ **ολικής** και **μερικής** συσχέτισης:

- **Ολική συσχέτιση**: Πόσο σχετίζεται η μεταβλητή X_j με το Y **μόνη της**; (Αυτό μετρήσαμε στο Υποερώτημα 1)
- **Μερική συσχέτιση**: Πόσο σχετίζεται η μεταβλητή X_j με το Y **αφού αφαιρέσουμε** την επίδραση των άλλων μεταβλητών; (Αυτό χρησιμοποιεί η forward selection)

Παράδειγμα: Η πυκνότητα (density) στην απλή παλινδρόμηση φαίνεται σημαντική ($p < 0.001$). Αλλά η πυκνότητα εξαρτάται σε μεγάλο βαθμό από το αλκοόλ και τα σάκχαρα. Αφού αυτά ήδη μπήκαν στο μοντέλο, η **επιπλέον** πληροφορία που δίνει η πυκνότητα είναι πολύ λιγότερη. Γι' αυτό μπαίνει μόλις στο βήμα 8.

4.1.5 Κριτήρια αξιολόγησης μοντέλων: AIC και BIC

Η p-value μας λέει αν μια μεταβλητή είναι στατιστικά σημαντική, αλλά δεν μας λέει ποιο **μοντέλο στο σύνολό του** είναι καλύτερο. Γι' αυτό χρησιμοποιούμε τα κριτήρια πληροφορίας:

Ορισμός: Κριτήριο Πληροφορίας Akaike (AIC)

Το **AIC** (Akaike Information Criterion) εφευρέθηκε από τον Ιάπωνα στατιστικό Hirotugu Akaike το 1973. Υπολογίζεται ως:

$$AIC = 2p - 2\ln(\hat{L}) \tag{10}$$

όπου:

- p = αριθμός παραμέτρων του μοντέλου (πόσες μεταβλητές + η σταθερά)
- $\hat{L}$ = η μεγιστοποιημένη **συνάρτηση πιθανοφάνειας** (likelihood). Αυτή μετράει πόσο καλά «ταιριάζει» το μοντέλο στα δεδομένα. Όσο μεγαλύτερη, τόσο καλύτερη η προσαρμογή.

Πώς να το σκεφτείτε: Το AIC αποτελείται από δύο «δυνάμεις» που τραβούν προς αντίθετες κατευθύνσεις:

- $-2\ln(\hat{L})$: «Θέλω καλή προσαρμογή» (μειώνεται καθώς το μοντέλο βελτιώνεται)
- $2p$: «Ποινή για πολυπλοκότητα» (αυξάνεται καθώς προσθέτουμε μεταβλητές)

Κανόνας: Μικρότερο AIC = Καλύτερο μοντέλο

Ορισμός: Μπεϋζιανό Κριτήριο Πληροφορίας (BIC)

Το **BIC** (Bayesian Information Criterion), γνωστό και ως κριτήριο Schwarz, υπολογίζεται ως:

$$BIC = p \cdot \ln(n) - 2\ln(\hat{L}) \tag{11}$$

όπου n = μέγεθος δείγματος (στα δεδομένα μας, $n = 5274$).
Διαφορά από το AIC: Η ποινή για κάθε επιπλέον μεταβλητή είναι $\ln(n)$ αντί για 2. Στα δεδομένα μας: $\ln(5274) \approx 8.57$. Δηλαδή το BIC τιμωρεί $8.57/2 \approx 4.3$ φορές πιο αυστηρά κάθε νέα μεταβλητή! Αυτό σημαίνει ότι το BIC τείνει να επιλέγει **απλούστερα μοντέλα** (λιγότερες μεταβλητές).
Κανόνας: Μικρότερο BIC = Καλύτερο μοντέλο

Αναλογία: AIC και BIC ως κριτές διαγωνισμού

Φανταστείτε τα AIC και BIC ως δύο κριτές σε διαγωνισμό μαγειρικής:

- Ο **AIC** είναι ο πιο «χαλαρός» κριτής: επιτρέπει περισσότερα υλικά αρκεί η γεύση να βελτιώνεται
- Ο **BIC** είναι ο «αυστηρός» κριτής: «Γιατί βάζεις 20 μπαχαρικά; Αν μπορείς να φτιάξεις σχεδόν εξίσου νόστιμο πιάτο με 5, προτίμησε τα 5!»

Στη πρακτική, εξετάζουμε **και τα δύο**. Αν συμφωνούν, είμαστε πιο σίγουροι. Αν διαφωνούν, προτιμούμε συνήθως το BIC για ερμηνευτικά μοντέλα.

4.1.6 Ο ρόλος του R^2_{adj} στην επιλογή μεταβλητών

Γιατί R^2_{adj} και όχι R^2;

Υπενθυμίζουμε ότι ο R^2 (συντελεστής προσδιορισμού) μετράει πόσο καλά εξηγεί το μοντέλο τη μεταβλητότητα των δεδομένων. Αλλά ο R^2 έχει ένα πρόβλημα: **πάντα αυξάνεται** (ή μένει ίδιος) όταν προσθέ-

τουμε μεταβλητές, ακόμα κι αν αυτές είναι τελείως τυχαίες!
Ο **διορθωμένος** R^2_{adj} λύνει αυτό το πρόβλημα:

$$R^2_{adj} = 1 - \frac{(1 - R^2)(n - 1)}{n - p - 1} \tag{12}$$

Ο R^2_{adj} **μπορεί να μειωθεί** αν η νέα μεταβλητή δεν βοηθάει αρκετά – τιμωρεί τις περιττές μεταβλητές. Γι' αυτό τον χρησιμοποιούμε για σύγκριση μοντέλων.

4.2 Εφαρμογή: Βήμα-βήμα η πρόσω επιλογή στα δεδομένα μας

Εφαρμόσαμε τη forward selection στα δεδομένα ποιότητας κρασιού (5.274 παρατηρήσεις, 11 μεταβλητές). Το κριτήριο εισόδου ήταν $p < 0.05$. Ακολουθεί η αναλυτική περιγραφή κάθε βήματος.

4.2.1 Βήμα 1: Ποια μεταβλητή εξηγεί μόνη της την ποιότητα καλύτερα;

Στο πρώτο βήμα, δοκιμάζουμε κάθε μεταβλητή **μεμονωμένα** (ακριβώς όπως στο Υποερώτημα 1). Η μεταβλητή **alcohol** κερδίζει με τεράστια διαφορά:

- p-value $= 4.55 \times 10^{-243}$ (πρακτικά μηδέν!)
- $R^2_{adj} = 0.1895$ (εξηγεί μόνο του σχεδόν 19% της μεταβλητότητας)
- AIC $= 12463$

Αυτό ήταν αναμενόμενο: στο Υποερώτημα 1 είδαμε ότι το alcohol είχε μακράν τον υψηλότερο R^2.

Μοντέλο μετά το Βήμα 1: quality $= \beta_0 + \beta_1 \cdot$ alcohol

4.2.2 Βήμα 2: Τι λείπει από το μοντέλο;

Τώρα ρωτάμε: «Δεδομένου ότι ήδη γνωρίζουμε το alcohol, ποια μεταβλητή δίνει τη μεγαλύτερη **επιπλέον** πληροφορία;» Η νικήτρια είναι η **volatile acidity** (πτητική οξύτητα):

- p-value $= 1.09 \times 10^{-79}$ (εξαιρετικά σημαντική)
- R^2_{adj} αυξάνεται από 0.1895 σε **0.2425** (αύξηση $+0.053$)
- AIC πέφτει από 12463 σε **12108** (πτώση -355, τεράστια βελτίωση!)

Αυτό βγάζει νόημα: η πτητική οξύτητα σχετίζεται με οσμές ξυδιού στο κρασί – μια πληροφορία τελείως διαφορετική από το ποσοστό αλκοόλ. Δίνει λοιπόν **μοναδική** πληροφορία.

4.2.3 Βήμα 3: Τα sulphates ως τρίτη δύναμη

Η **sulphates** (θειικά) μπαίνει τρίτη:

- p-value $= 2.10 \times 10^{-18}$
- R^2_{adj}: $0.2425 \to 0.2533$ (αύξηση $+0.011$)
- AIC: $12108 \to 12033$ (πτώση -75)

Παρατήρηση: Φθίνουσα οριακή αξία

Προσέξτε ένα σημαντικό μοτίβο: Κάθε νέα μεταβλητή βελτιώνει το μοντέλο **λιγότερο** από την προηγούμενη:

- Βήμα 1 (alcohol): $+0.190$ στον R^2_{adj}
- Βήμα 2 (volatile acidity): $+0.053$
- Βήμα 3 (sulphates): $+0.011$

Αυτό ονομάζεται **φθίνουσα οριακή απόδοση** – η ίδια αρχή με τα οικονομικά! Η πρώτη μεταβλητή δίνει τη μεγαλύτερη βελτίωση, η δεύτερη λιγότερη, κ.ο.κ. Οι τρεις πρώτες μεταβλητές μαζί εξηγούν $R^2_{adj} = 0.253$, δηλαδή **πάνω από το 91%** αυτού που εξηγεί το πλήρες μοντέλο 10 μεταβλητών ($R^2_{adj} = 0.2755$)!

4.2.4 Βήματα 4–7: Τα sulfur dioxide και τα υπόλοιπα χημικά

- **Βήμα 4**: Εισέρχεται το **free sulfur dioxide** ($p = 2.58 \times 10^{-6}$). Μικρή βελτίωση (R^2_{adj}: $0.2533 \to 0.2563$).
- **Βήμα 5**: Εισέρχεται το **total sulfur dioxide** ($p = 5.64 \times 10^{-16}$). Αξιοσημείωτο ότι μπαίνει **μετά** το free sulfur dioxide – αν και ήταν πιο σημαντικό στην απλή παλινδρόμηση. Αυτό δείχνει ότι μετά τα βήματα 1–4, η **μοναδική** πληροφορία του total sulfur dioxide γίνεται ιδιαίτερα σημαντική. Αύξηση R^2_{adj}: $0.2563 \to 0.2653$ ($+0.009$).
- **Βήμα 6**: Εισέρχεται το **residual sugar** ($p = 8.82 \times 10^{-8}$). R^2_{adj}: $0.2653 \to 0.2692$ ($+0.004$).
- **Βήμα 7**: Εισέρχονται τα **chlorides** ($p = 6.68 \times 10^{-6}$). R^2_{adj}: $0.2692 \to 0.2718$ ($+0.003$).

4.2.5 Βήματα 8–10: Οι τελευταίες προσθήκες

- **Βήμα 8**: Εισέρχεται η **density** ($p = 0.006$). Προσέξτε: η p-value είναι ακόμα κάτω από 0.05, αλλά μόλις! Η πυκνότητα σχετίζεται στενά με alcohol και residual sugar (που ήδη υπάρχουν), γι' αυτό η μοναδική της συνεισφορά είναι μικρή.

- **Βήμα 9**: Εισέρχεται το **pH** ($p = 0.0025$). Μικρή αλλά στατιστικά σημαντική συνεισφορά.
- **Βήμα 10**: Εισέρχεται το **fixed acidity** ($p = 0.00037$). R^2_{adj} φτάνει στο τελικό 0.2755.

4.2.6 Βήμα 11: Η στιγμή που σταματάει ο αλγόριθμος

Γιατί σταματήσαμε: Η περίπτωση του citric acid

Στο βήμα 11, η μόνη εναπομείνασα μεταβλητή είναι το **citric acid** (κιτρικό οξύ). Ο αλγόριθμος ελέγχει αν η p-value του είναι κάτω από 0.05:

$p_{\text{citric acid}} = 0.138 > 0.05 \implies$ **ΔΕΝ εισέρχεται στο μοντέλο**

Αυτό σημαίνει ότι, **δεδομένης της παρουσίας** όλων των άλλων 10 μεταβλητών, το citric acid δεν προσφέρει στατιστικά σημαντική επιπλέον πληροφορία. Δεν σημαίνει ότι το κιτρικό οξύ δεν επηρεάζει καθόλου την ποιότητα – στην απλή παλινδρόμηση ήταν σημαντικό ($p < 0.001$). Σημαίνει ότι η πληροφορία του **αλληλοεπικαλύπτεται** πλήρως με αυτές των 10 μεταβλητών που ήδη επιλέχθηκαν.

Αυτό επιβεβαιώνει εντυπωσιακά το εύρημα του Υποερωτήματος 2, όπου το citric acid ήταν η μόνη μη σημαντική μεταβλητή ($p = 0.138$) στην πολλαπλή παλινδρόμηση!

4.3 Συγκεντρωτικά αποτελέσματα

Πίνακας 3: Βήματα Πρόσω Επιλογής Μεταβλητών

Βήμα	Μεταβλητή	p-value	R^2_{adj}	ΔR^2_{adj}	AIC
1	alcohol	4.55×10^{-243}	0.1895	+0.1895	12463
2	volatile acidity	1.09×10^{-79}	0.2425	+0.0530	12108
3	sulphates	2.10×10^{-18}	0.2533	+0.0108	12033
4	free sulfur dioxide	2.58×10^{-6}	0.2563	+0.0030	12013
5	total sulfur dioxide	5.64×10^{-16}	0.2653	+0.0090	11950
6	residual sugar	8.82×10^{-8}	0.2692	+0.0039	11923
7	chlorides	6.68×10^{-6}	0.2718	+0.0026	11905
8	density	5.96×10^{-3}	0.2727	+0.0009	11899
9	pH	2.46×10^{-3}	0.2739	+0.0011	11892
10	fixed acidity	3.71×10^{-4}	0.2755	+0.0016	11881
11	citric acid (απορρίφθηκε)	0.138	–	–	–

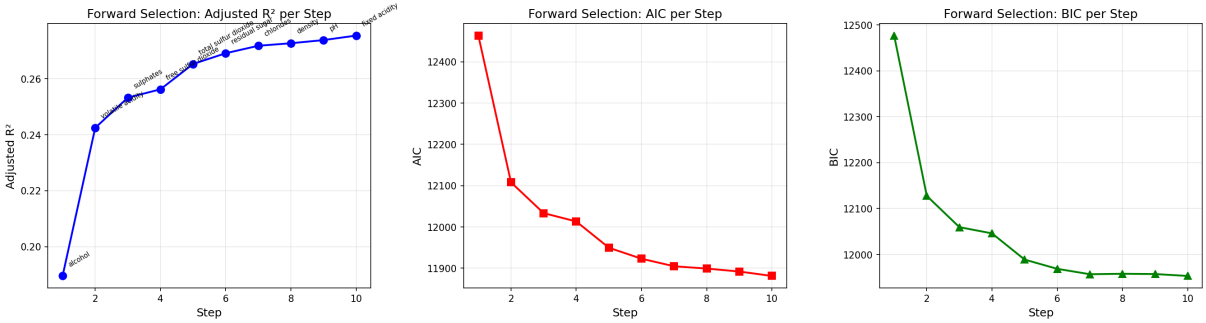

Σχήμα 2: Εξέλιξη των κριτηρίων R^2_{adj}, AIC και BIC κατά τα βήματα της πρόσω επιλογής. Παρατηρήστε ότι ο R^2_{adj} αυξάνεται ολοένα και πιο αργά (φθίνουσα οριακή απόδοση), ενώ το AIC μειώνεται (βελτιώνεται) σε κάθε βήμα.

4.4 Ερμηνεία αποτελεσμάτων

4.4.1 Κεντρικά ευρήματα

Κεντρικά ευρήματα πρόσω επιλογής

1. **Τελικό μοντέλο**: Περιλαμβάνει **10 από τις 11 μεταβλητές**. Αποκλείεται μόνο το **citric acid** ($p = 0.138 > 0.05$).
2. **Ποιότητα προσαρμογής**: $R^2 = 0.2768$, $R^2_{adj} = 0.2755$. Δηλαδή το μοντέλο εξηγεί περίπου το 27.5% της μεταβλητότητας – ακριβώς όσο και το πλήρες μοντέλο του Υποερωτήματος 2, χωρίς τη μία «περιττή» μεταβλητή.
3. **Ιεραρχία σπουδαιότητας**: Οι 3 πρώτες μεταβλητές (alcohol, volatile acidity, sulphates) εξηγούν ήδη $R^2_{adj} = 0.253$, δηλαδή **το 92%** αυτού που εξηγεί το πλήρες μοντέλο.
4. **Τα βήματα 4–10 προσθέτουν ελάχιστα**: Συνολικά $+0.022$ στον R^2_{adj}. Ένας αναλυτής θα μπορούσε εύλογα να κρατήσει μόνο τις 3 πρώτες μεταβλητές για ένα πιο «φειδωλό» μοντέλο.

4.4.2 Γιατί η σειρά εισόδου διαφέρει από την απλή παλινδρόμηση;

Η σειρά εισόδου αντικατοπτρίζει τη μοναδική συνεισφορά!

Ένα ενδιαφέρον παράδειγμα: Στην απλή παλινδρόμηση (Υποερώτημα 1), η πυκνότητα (density) είχε πολύ χαμηλή p-value ($p < 10^{-100}$) και ήταν η δεύτερη πιο σημαντική μεταβλητή. Στη forward selection, μπαίνει μόλις στο **βήμα 8** (οκτώ!).
Εξήγηση: Η πυκνότητα εξαρτάται φυσικά από:

- Το αλκοόλ (μπήκε στο βήμα 1) – το αλκοόλ μειώνει την πυκνότητα

- Τα υπολειπόμενα σάκχαρα (βήμα 6) – τα σάκχαρα αυξάνουν την πυκνότητα

Αφού αυτές οι μεταβλητές ήδη υπάρχουν στο μοντέλο, η πυκνότητα δεν «μαθαίνει» τίποτα νέο – η πληροφορία της είναι ήδη «καλυμμένη». Γι' αυτό η **μοναδική** της συνεισφορά είναι μικροσκοπική ($\Delta R^2_{adj} = +0.0009$).
Αντίθετα, τα sulphates μπαίνουν τρίτα γιατί δίνουν πληροφορία **εντελώς διαφορετική** από το alcohol και τη volatile acidity.

4.4.3 Σύγκριση με το πλήρες μοντέλο (Υποερώτημα 2)

Πρόσω επιλογή vs Πλήρες μοντέλο

Χαρακτηριστικό	Πλήρες μοντέλο	Forward selection
Αριθμός μεταβλητών	11	10
R^2_{adj}	0.2757	0.2755
Μη σημαντική μεταβλητή	citric acid ($p = 0.138$)	citric acid (απορρίφθηκε)

Συμπέρασμα: Τα δύο μοντέλα είναι **ουσιαστικά ισοδύναμα**! Η forward selection απλά επιβεβαιώνει ότι το citric acid δεν χρειάζεται – αφαιρώντας το, χάνουμε μόλις 0.0002 στον R^2_{adj} (αμελητέα διαφορά). Αυτή η συμφωνία μεταξύ δύο διαφορετικών μεθόδων (p-value ελέγχου στην πολλαπλή παλινδρόμηση + forward selection) **ενισχύει την εμπιστοσύνη μας** στο αποτέλεσμα.

4.4.4 Πρακτική σημασία: Αν είχαμε μόνο 3 μεταβλητές;

Πρακτικό σενάριο: Ένα απλό μοντέλο για οινοποιεία

Αν ένα μικρό οινοποιείο ήθελε ένα **απλό** και **πρακτικό** μοντέλο πρόβλεψης ποιότητας, θα μπορούσε να χρησιμοποιήσει μόνο τις 3 πρώτες μεταβλητές:

- **Alcohol** (ποσοστό αλκοόλ)
- **Volatile acidity** (πτητική οξύτητα – δείκτης «ξυδιού»)
- **Sulphates** (θειικά – σχετίζονται με τη συντήρηση)

Αυτό το μοντέλο 3 μεταβλητών εξηγεί $R^2_{adj} = 0.253$, ενώ το πλήρες μοντέλο 10 μεταβλητών εξηγεί $R^2_{adj} = 0.2755$. Η διαφορά είναι μόλις 0.022 (2.2 ποσοστιαίες μονάδες). Για πρακτικούς σκοπούς, αυτό μπορεί να αξίζει τον κόπο – τρεις μετρήσεις αντί για δέκα!

Το τελικό μοντέλο πρόσω επιλογής:

$$\begin{aligned}\text{quality} = {} & 43.86 + 0.274 \cdot \text{alcohol} - 1.300 \cdot \text{volatile_acidity} \\ & + 0.779 \cdot \text{sulphates} + 0.007 \cdot \text{free_SO}_2 \\ & - 0.003 \cdot \text{total_SO}_2 + 0.029 \cdot \text{residual_sugar} \\ & - 1.267 \cdot \text{chlorides} - 42.70 \cdot \text{density} \\ & + 0.394 \cdot \text{pH} + 0.047 \cdot \text{fixed_acidity}\end{aligned}$$

Ανάγνωση του τελικού μοντέλου

Πώς διαβάζουμε αυτήν την εξίσωση; Κάθε συντελεστής μας λέει **πόσο αλλάζει η ποιότητα** για κάθε μοναδιαία αύξηση της αντίστοιχης μεταβλητής, **κρατώντας όλες τις άλλες σταθερές**:

- $+0.274 \cdot$ alcohol: Κάθε 1% αύξηση αλκοόλ $\rightarrow$ ποιότητα +0.274 βαθμούς
- $-1.300 \cdot$ volatile acidity: Κάθε μονάδα αύξηση πτητικής οξύτητας $\rightarrow$ ποιότητα -1.300 βαθμούς (αρνητική επίδραση!)
- $-42.70 \cdot$ density: Ο μεγάλος συντελεστής δεν σημαίνει μεγάλη επίδραση – η πυκνότητα κυμαίνεται σε πολύ μικρό εύρος (≈ 0.99–1.00), άρα η πραγματική επίδραση είναι μικρή

5 Πολυωνυμική Παλινδρόμηση (Υποερώτημα 4)

5.1 Θεωρητικό υπόβαθρο

5.1.1 Πέρα από τη γραμμικότητα

Ορισμός: Πολυωνυμική Παλινδρόμηση

Μέχρι τώρα, υποθέταμε ότι η σχέση μεταξύ X και Y είναι **γραμμική** (ευθεία γραμμή). Αλλά στην πραγματικότητα, οι σχέσεις μπορεί να είναι **καμπυλωτές**. Η πολυωνυμική παλινδρόμηση επιτρέπει τη μοντελοποίηση τέτοιων σχέσεων:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3 + \varepsilon \tag{13}$$

- **Γραμμικό μοντέλο** ($Y = \beta_0 + \beta_1 X$): Ευθεία γραμμή
- **Τετραγωνικό μοντέλο** ($Y = \beta_0 + \beta_1 X + \beta_2 X^2$): Παραβολή – η σχέση μπορεί να αλλάξει κατεύθυνση μία φορά
- **Κυβικό μοντέλο** ($Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3$): Η σχέση μπορεί να αλλάξει κατεύθυνση δύο φορές

Γιατί χρειαζόμαστε πολυωνυμική παλινδρόμηση;

Σκεφτείτε τη σχέση μεταξύ ποσότητας λιπάσματος και παραγωγής φυτών:

- Λίγο λίπασμα $\Rightarrow$ μικρή παραγωγή (λείπει θρεπτική ουσία)
- Μέτριο λίπασμα $\Rightarrow$ μεγάλη παραγωγή (ιδανική ποσότητα)
- Πολύ λίπασμα $\Rightarrow$ μικρή παραγωγή («καίει» τα φυτά!)

Αυτή η σχέση σχηματίζει μια **ανεστραμμένη παραβολή** ($\cap$) – δεν μπορεί να αποτυπωθεί από ευθεία γραμμή!

5.1.2 Πώς ελέγχουμε τη μη γραμμικότητα;

Έλεγχος μη γραμμικότητας

Για να ελέγξουμε αν η σχέση είναι μη γραμμική, εφαρμόζουμε τον κυβικό μοντέλο και ελέγχουμε:

1. Αν $\beta_3 \neq 0$ (σημαντικός κυβικός όρος) $\Rightarrow$ η σχέση είναι κυβική
2. Αν $\beta_3 = 0$ αλλά $\beta_2 \neq 0$ (σημαντικός τετραγωνικός όρος) $\Rightarrow$ τετραγωνική σχέση

3. Αν $\beta_3 = \beta_2 = 0 \Rightarrow$ η γραμμική σχέση αρκεί

Σημαντικό: Παρόλο που τεχνικά προσθέτουμε X^2 και X^3, αυτό **παραμένει** γραμμική παλινδρόμηση ως προς τους **συντελεστές** β. Απλώς οι «μεταβλητές» μας τώρα είναι X, X^2 και X^3.

5.2 Αποτελέσματα

Εξετάσαμε τις μεταβλητές **Residual Sugar**, **Chlorides** και **Alcohol**.

5.2.1 Residual Sugar (Υπολειπόμενη ζάχαρη)

Πίνακας 4: Σύγκριση μοντέλων: quality $\sim$ residual sugar

Μοντέλο	R^2	R^2_{adj}	**AIC**	**BIC**	**p-value ανώτερου όρου**
Γραμμικό	0.0029	0.0027	13557	13571	–
Τετραγωνικό	0.0031	0.0027	13558	13578	0.297 (NS)
Κυβικό	0.0072	0.0066	13539	13565	2.99×10^{-6}

Ανάλυση: Ο τετραγωνικός όρος δεν είναι σημαντικός ($p = 0.297$), αλλά ο κυβικός είναι πολύ σημαντικός ($p = 2.99 \times 10^{-6}$). Αυτό σημαίνει ότι η σχέση μεταξύ ζάχαρης και ποιότητας είναι **μη γραμμική**. Ωστόσο, η βελτίωση σε R^2 είναι πολύ μικρή (από 0.0029 σε 0.0072), υποδεικνύοντας ότι η ζάχαρη παραμένει αδύναμος προβλέπτης.

5.2.2 Chlorides (Χλωριούχα)

Πίνακας 5: Σύγκριση μοντέλων: quality $\sim$ chlorides

Μοντέλο	R^2	R^2_{adj}	**AIC**	**BIC**	**p-value ανώτερου όρου**
Γραμμικό	0.0414	0.0412	13350	13363	–
Τετραγωνικό	0.0583	0.0579	13258	13278	3.93×10^{-22}
Κυβικό	0.0708	0.0702	13190	13216	4.94×10^{-17}

Ανάλυση: Τόσο ο τετραγωνικός ($p = 3.93 \times 10^{-22}$) όσο και ο κυβικός όρος ($p = 4.94 \times 10^{-17}$) είναι εξαιρετικά σημαντικοί. Τα chlorides δείχνουν την **ισχυρότερη μη γραμμικότητα** από τις τρεις μεταβλητές. Η σχέση δεν είναι απλά «όσο αυξάνονται τα χλωριούχα, μειώνεται η ποιότητα» – η μείωση επιταχύνεται σε υψηλές τιμές chlorides.

5.2.3 Alcohol (Αλκοόλ)

Πίνακας 6: Σύγκριση μοντέλων: quality $\sim$ alcohol

Μοντέλο	R^2	R^2_{adj}	**AIC**	**BIC**	**p-value ανώτερου όρου**
Γραμμικό	0.1897	0.1895	12463	12477	–
Τετραγωνικό	0.1903	0.1900	12461	12481	0.046
Κυβικό	0.1947	0.1943	12434	12461	6.56×10^{-8}

Ανάλυση: Ο τετραγωνικός όρος είναι οριακά σημαντικός ($p = 0.046$) και ο κυβικός πολύ σημαντικός ($p = 6.56 \times 10^{-8}$). Η σχέση αλκοόλ-ποιότητας δεν είναι τελείως γραμμική, αλλά η βελτίωση είναι μικρή (R^2: 0.190 $\rightarrow$ 0.195). Αυτό σημαίνει ότι η γραμμική προσέγγιση είναι «αρκετά καλή», αν και τεχνικά η κυβική είναι καλύτερη.

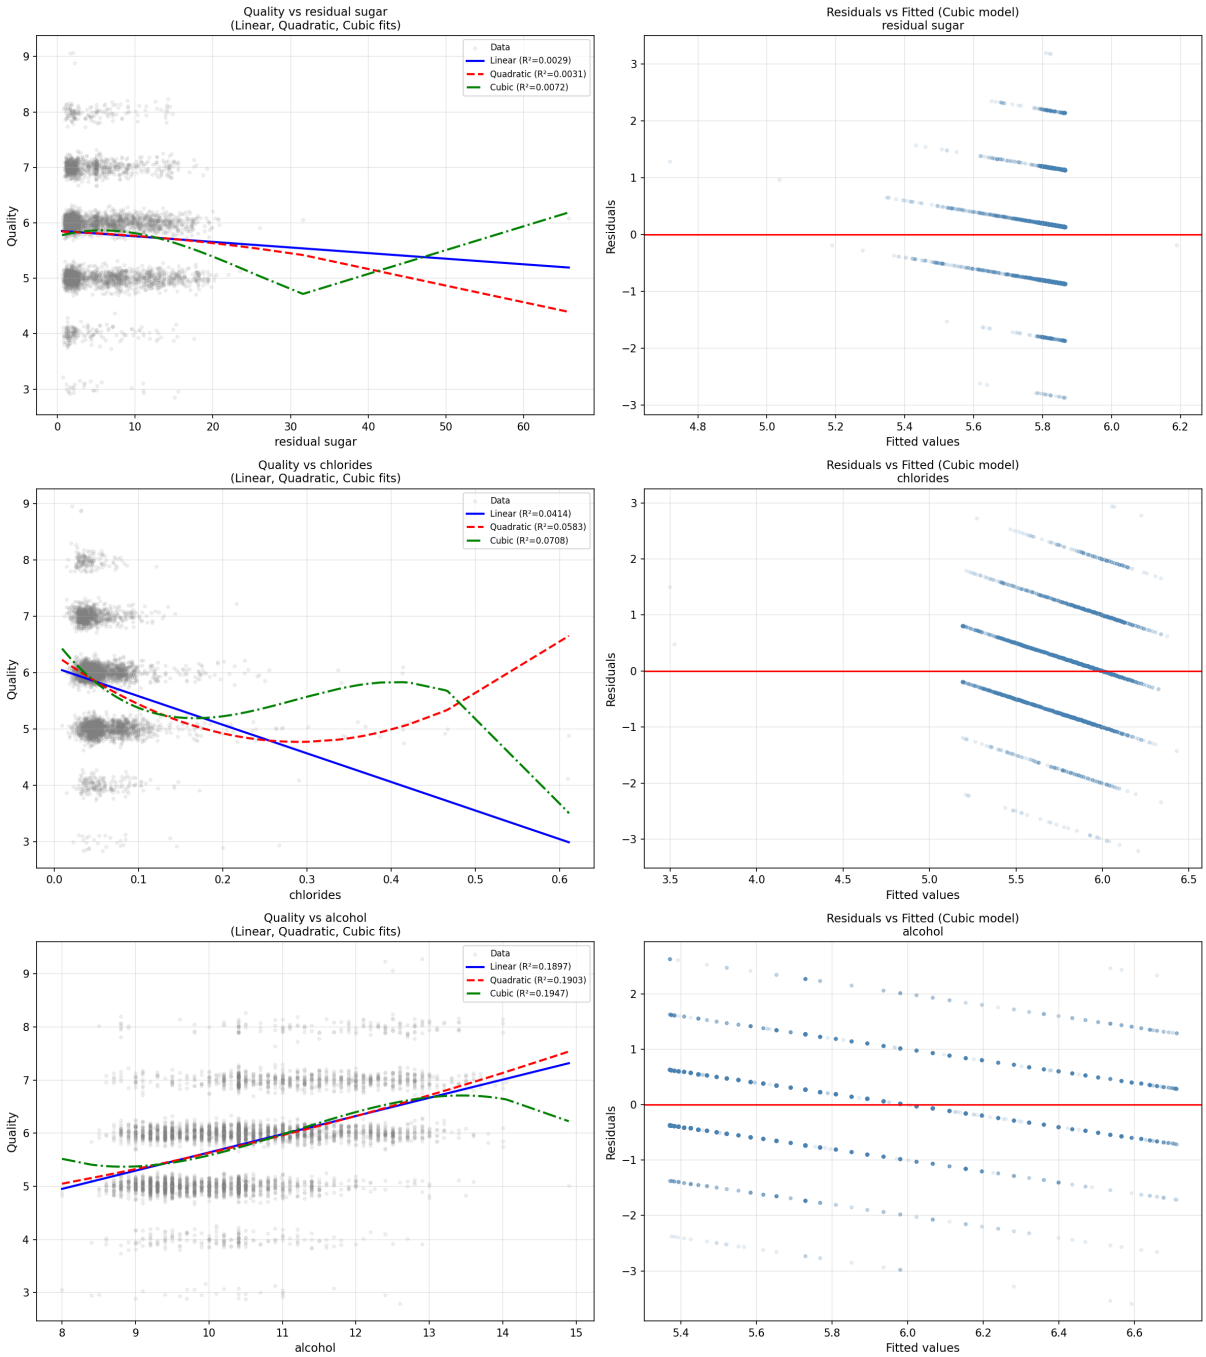

Σχήμα 3: Πολυωνυμική παλινδρόμηση: Αριστερά τα scatter plots με τις τρεις καμπύλες προσαρμογής (γραμμική, τετραγωνική, κυβική). Δεξιά τα διαγράμματα υπολοίπων (residuals) για το βέλτιστο μοντέλο κάθε μεταβλητής.

5.2.4 Συνολική αξιολόγηση

Συμπεράσματα πολυωνυμικής παλινδρόμησης

Και οι τρεις μεταβλητές δείχνουν ενδείξεις μη γραμμικής σχέσης με την ποιότητα:

1. **Chlorides**: Ισχυρή μη γραμμικότητα – τόσο ο τετραγωνικός όσο και ο κυβικός όρος είναι πολύ σημαντικοί. Η σχέση είναι σαφώς κυβική.
2. **Alcohol**: Σημαντικός κυβικός όρος, αλλά η πρακτική βελτίωση είναι μικρή.
3. **Residual Sugar**: Σημαντικός κυβικός (αλλά όχι τετραγωνικός) όρος. Πολύ ασθενής σχέση συνολικά.

Σημαντική παρατήρηση: Παρόλο που η μη γραμμικότητα είναι **στατιστικά σημαντική**, η **πρακτική βελτίωση** σε R^2 είναι μικρή. Αυτό σημαίνει ότι η αλλαγή μορφής (από γραμμικό σε κυβικό) δεν λύνει το πρόβλημα της χαμηλής ερμηνευτικής ικανότητας.

6 Κριτική Αξιολόγηση του Μοντέλου (Υποερώτημα 5)

6.1 Θεωρητικό υπόβαθρο: Υποθέσεις της γραμμικής παλινδρόμησης

Οι 5 βασικές υποθέσεις

Η γραμμική παλινδρόμηση βασίζεται σε 5 βασικές υποθέσεις. Αν κάποια παραβιάζεται, τα αποτελέσματά μας μπορεί να μην είναι αξιόπιστα:

1. **Γραμμικότητα**: Η σχέση μεταξύ X και Y είναι γραμμική
2. **Ανεξαρτησία**: Οι παρατηρήσεις είναι ανεξάρτητες μεταξύ τους
3. **Ομοσκεδαστικότητα**: Η διακύμανση των σφαλμάτων ε είναι σταθερή
4. **Κανονικότητα**: Τα σφάλματα ε ακολουθούν κανονική κατανομή
5. **Μη πολυσυγγραμμικότητα**: Οι μεταβλητές X δεν είναι υπερβολικά συσχετισμένες μεταξύ τους

6.2 Διαγνωστικοί έλεγχοι

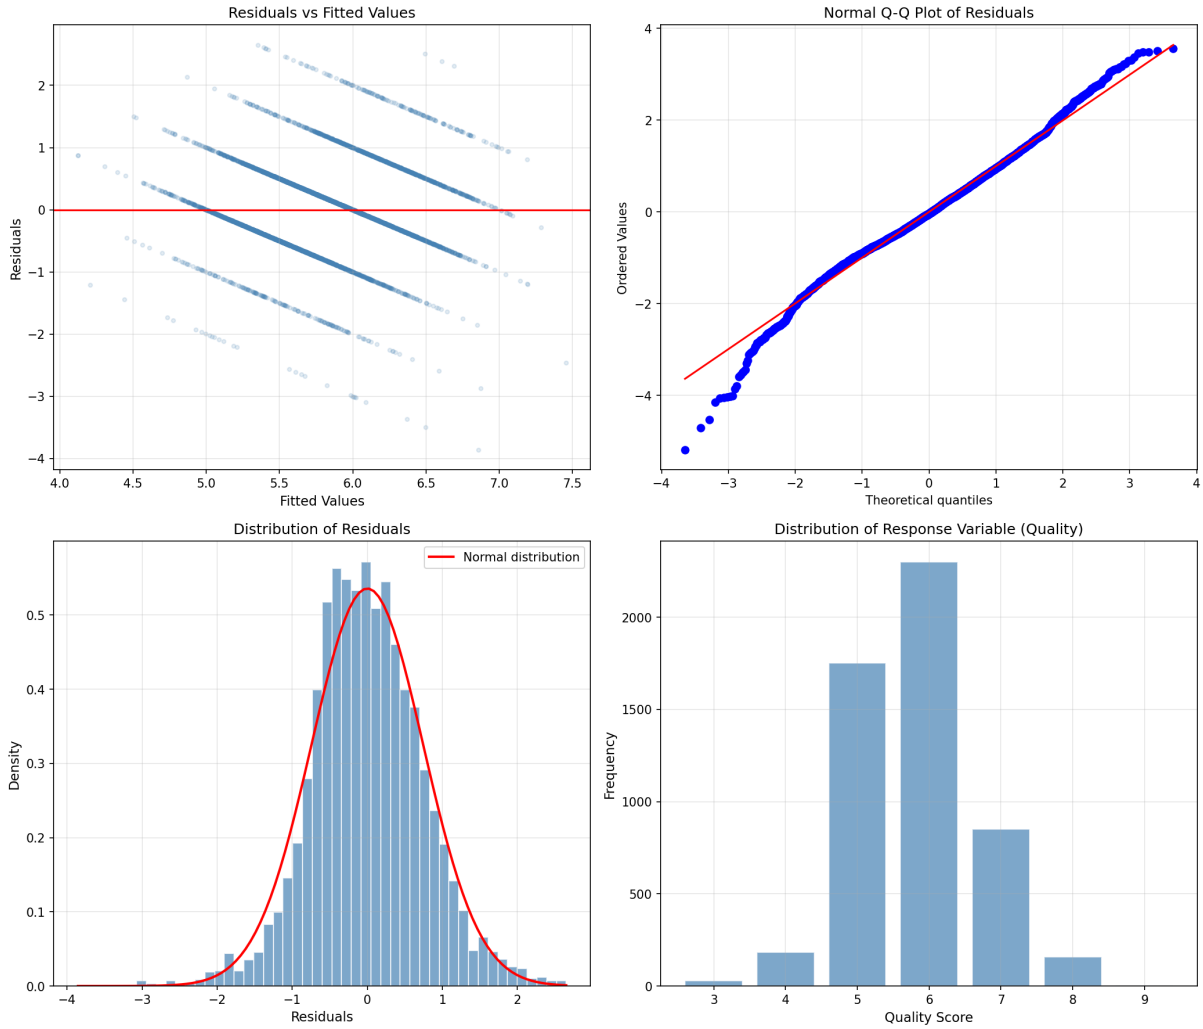

Σχήμα 4: Διαγνωστικά γραφήματα: (a) Υπόλοιπα vs Προβλεπόμενες τιμές, (b) Q-Q plot κανονικότητας, (c) Κατανομή υπολοίπων, (d) Κατανομή μεταβλητής απόκρισης (quality).

6.2.1 Έλεγχος 1: Κανονικότητα υπολοίπων

Τι είναι τα υπόλοιπα (residuals);

Τα **υπόλοιπα** είναι η διαφορά μεταξύ πραγματικής και προβλεπόμενης τιμής:

$$e_i = Y_i - \hat{Y}_i$$

Αν το μοντέλο λειτουργεί σωστά, τα υπόλοιπα πρέπει να μοιάζουν με **τυχαίο θόρυβο** – δηλαδή να ακολουθούν κανονική κατανομή με μέσο 0.

Αποτελέσματα ελέγχων:

- **Shapiro-Wilk**: $W = 0.9912$, $p = 4.37 \times 10^{-17}$

- **Jarque-Bera**: $JB = 222.07$, $p = 5.99 \times 10^{-49}$

Πρόβλημα: Μη κανονικά υπόλοιπα

Και οι δύο έλεγχοι **απορρίπτουν** την υπόθεση κανονικότητας ($p \ll 0.05$). Αυτό σημαίνει ότι τα confidence intervals και τα p-values μπορεί να μην είναι **ακριβή**.
Στο Q-Q plot (Σχήμα 4b) βλέπουμε αποκλίσεις στα **άκρα** (ουρές) – τα ακραία υπόλοιπα είναι μεγαλύτερα από ό,τι θα περιμέναμε σε κανονική κατανομή.

6.2.2 Έλεγχος 2: Ομοσκεδαστικότητα

Τι είναι η ομοσκεδαστικότητα;

Ομοσκεδαστικότητα (homoscedasticity) σημαίνει ότι η «διασπορά» των σφαλμάτων είναι **ίδια** σε όλα τα επίπεδα πρόβλεψης. Αν η διασπορά αλλάζει (π.χ. μεγαλύτερη σε υψηλές τιμές), τότε έχουμε **ετεροσκεδαστικότητα** – πρόβλημα!
Οπτικός έλεγχος: Στο γράφημα residuals vs fitted, τα σημεία πρέπει να σχηματίζουν μια «λωρίδα» σταθερού πλάτους. Αν η λωρίδα «ανοίγει» σαν χοάνη, υπάρχει ετεροσκεδαστικότητα.

Αποτέλεσμα Breusch-Pagan: $BP = 75.01$, $p = 1.35 \times 10^{-11}$

Πρόβλημα: Ετεροσκεδαστικότητα

Ο έλεγχος Breusch-Pagan απορρίπτει την ομοσκεδαστικότητα. Αυτό σημαίνει ότι τα **τυπικά σφάλματα** (standard errors) των συντελεστών μπορεί να μην είναι αξιόπιστα, και κατ' επέκταση τα t-tests και τα confidence intervals.

6.2.3 Έλεγχος 3: Αυτοσυσχέτιση

Τι είναι η αυτοσυσχέτιση;

Η **αυτοσυσχέτιση** (autocorrelation) σημαίνει ότι τα σφάλματα **διαδοχικών** παρατηρήσεων σχετίζονται μεταξύ τους. Ο έλεγχος **Durbin-Watson** ελέγχει αυτό, δίνοντας τιμή 0–4:

- $DW \approx 2$: Δεν υπάρχει αυτοσυσχέτιση (ιδανικό)
- $DW \ll 2$: Θετική αυτοσυσχέτιση
- $DW \gg 2$: Αρνητική αυτοσυσχέτιση

Αποτέλεσμα: $DW = 2.041 \approx 2$ – **Δεν υπάρχει πρόβλημα αυτοσυσχέτισης.**

6.2.4 Έλεγχος 4: Πολυσυγγραμμικότητα (VIF)

Τι είναι η πολυσυγγραμμικότητα και ο VIF;

Η **πολυσυγγραμμικότητα** (multicollinearity) υπάρχει όταν δύο ή περισσότερες προβλεπτικές μεταβλητές είναι ισχυρά συσχετισμένες μεταξύ τους. Αυτό δημιουργεί αστάθεια στις εκτιμήσεις των β.
Ο **VIF** (Variance Inflation Factor) μετράει πόσο «φουσκωμένη» είναι η διακύμανση ενός $\hat{\beta}_j$ λόγω συσχέτισης:

$$VIF_j = \frac{1}{1 - R_j^2} \tag{14}$$

όπου R_j^2 είναι ο R^2 από την παλινδρόμηση του X_j πάνω στα υπόλοιπα X.
Εμπειρικοί κανόνες:

- $VIF < 5$: Αποδεκτό
- $5 < VIF < 10$: Μέτρια πολυσυγγραμμικότητα (πιθανό πρόβλημα)
- $VIF > 10$: Σοβαρή πολυσυγγραμμικότητα (σίγουρο πρόβλημα)

Πίνακας 7: Παράγοντας Πληθωρισμού Διακύμανσης (VIF) για κάθε μεταβλητή

Μεταβλητή	**VIF**	**Αξιολόγηση**
fixed acidity	2.70	Αποδεκτό
volatile acidity	1.85	Αποδεκτό
citric acid	1.56	Αποδεκτό
residual sugar	3.38	Αποδεκτό
chlorides	1.59	Αποδεκτό
free sulfur dioxide	2.09	Αποδεκτό
total sulfur dioxide	2.79	Αποδεκτό
density	6.26	Μέτρια πολυσυγγρ.
pH	1.70	Αποδεκτό
sulphates	1.41	Αποδεκτό
alcohol	2.53	Αποδεκτό

Ανάλυση: Η πυκνότητα (density) εμφανίζει **μέτρια πολυσυγγραμμικότητα** ($VIF = 6.26$). Αυτό είναι φυσικό, καθώς η πυκνότητα εξαρτάται φυσικά από τη ζάχαρη και το αλκοόλ. Οι υπόλοιπες μεταβλητές δεν εμφανίζουν σημαντικό πρόβλημα.

6.3 Κριτική αξιολόγηση: Είναι η παλινδρόμηση κατάλληλη;

Βασικό πρόβλημα: Η μεταβλητή απόκρισης είναι διακριτή!

Το **θεμελιώδες πρόβλημα** του μοντέλου μας είναι ότι η μεταβλητή quality δεν είναι συνεχής – παίρνει ακέραιες τιμές (3, 4, 5, 6, 7, 8, 9). Η γραμμική παλινδρόμηση υποθέτει ότι η εξαρτημένη μεταβλητή είναι **συνεχής**.
Αυτό σημαίνει ότι:

- Οι προβλέψεις μπορεί να πέφτουν **εκτός** του έγκυρου εύρους (π.χ. 4.7 ή 7.3 – δεν υπάρχουν τέτοιοι βαθμοί)
- Τα υπόλοιπα εμφανίζουν χαρακτηριστικές **λωρίδες** (bands) αντί για ομοιογενή κατανομή
- Οι βασικές υποθέσεις κανονικότητας παραβιάζονται εξ αρχής

Σύνοψη όλων των προβλημάτων:

1. **Διακριτή μεταβλητή απόκρισης**: Η quality είναι τακτική (ordinal) με ακέραιες τιμές 3–9, ενώ η παλινδρόμηση υποθέτει συνεχή απόκριση.
2. **Χαμηλή ερμηνευτική ικανότητα** ($R^2 \approx 27.7\%$): Το μοντέλο εξηγεί **λιγότερο από το ένα τρίτο** της μεταβλητότητας. Αυτό υποδεικνύει ότι:
   - Υπάρχουν σημαντικοί παράγοντες που δεν περιλαμβάνονται στα δεδομένα
   - Η ποιότητα κρασιού επηρεάζεται από υποκειμενικούς παράγοντες (π.χ. αξιολογητής, γεύση, αισθητική)
   - Οι σχέσεις μπορεί να είναι πιο πολύπλοκες
3. **Μη κανονικά υπόλοιπα**: Οι έλεγχοι Shapiro-Wilk και Jarque-Bera απορρίπτουν σαφώς την κανονικότητα. Αυτό επηρεάζει τα confidence intervals και τα hypothesis tests.
4. **Ετεροσκεδαστικότητα**: Ο έλεγχος Breusch-Pagan ($p = 1.35 \times 10^{-11}$) δείχνει ότι η διακύμανση των σφαλμάτων **δεν** είναι σταθερή, παραβιάζοντας μία ακόμη υπόθεση.
5. **Πολυσυγγραμμικότητα**: Η πυκνότητα (density) εμφανίζει μέτρια πολυσυγγραμμικότητα ($VIF = 6.26$), καθώς εξαρτάται φυσικά από αλκοόλ και ζάχαρη.
6. **Μη γραμμικές σχέσεις**: Όπως αποδείχθηκε στο Υποερώτημα 4, ορισμένες σχέσεις δεν είναι γραμμικές.

6.4 Εναλλακτικές προσεγγίσεις

Τι θα μπορούσαμε να κάνουμε διαφορετικά;

1. **Τακτική λογιστική παλινδρόμηση** (Ordinal Logistic Regression): Σχεδιασμένη ειδικά για τακτικές εξαρτημένες μεταβλητές. Αντί να προβλέπει αριθμό, μοντελοποιεί τις **πιθανότητες** κάθε κατηγορίας.
2. **Random Forest / Gradient Boosting**: Αλγόριθμοι μηχανικής μάθησης που:
   - Δεν υποθέτουν γραμμικότητα
   - Χειρίζονται αυτόματα αλληλεπιδράσεις μεταξύ μεταβλητών
   - Συνήθως επιτυγχάνουν πολύ υψηλότερο R^2
3. **Ridge / LASSO παλινδρόμηση**: Παραλλαγές παλινδρόμησης που αντιμετωπίζουν την πολυσυγγραμμικότητα προσθέτοντας «ποινή» στους μεγάλους συντελεστές.
4. **Παλινδρόμηση Poisson**: Κατάλληλη για μεταβλητές τύπου «μέτρησης» (count data), που μοιάζουν με τη quality.

7 Συμπεράσματα

Η ανάλυση παλινδρόμησης στα δεδομένα ποιότητας κρασιού αποκάλυψε τα ακόλουθα:

1. **Υποερώτημα 1 – Απλή παλινδρόμηση**: Και οι 11 μεταβλητές εμφανίζουν στατιστικά σημαντικές σχέσεις με την ποιότητα. Ο ισχυρότερος μεμονωμένος προβλέπτης είναι το **αλκοόλ** ($R^2 = 0.19$), ακολουθούμενο από την πυκνότητα ($R^2 = 0.09$) και την πτητική οξύτητα ($R^2 = 0.06$).

2. **Υποερώτημα 2 – Πολλαπλή παλινδρόμηση**: Το πλήρες μοντέλο ($R^2 = 0.277$) εμφανίζει σημαντικούς συντελεστές για 10 από τις 11 μεταβλητές. Μοναδική εξαίρεση: το **citric acid** ($p = 0.138$), του οποίου η πληροφορία απορροφάται από τις υπόλοιπες μεταβλητές.

3. **Υποερώτημα 3 – Πρόσω επιλογή**: Η μέθοδος forward selection επέλεξε 10 μεταβλητές (εξαιρώντας πάλι το citric acid) με $R^2_{adj} = 0.2755$. Οι 3 πρώτες μεταβλητές (alcohol, volatile acidity, sulphates) παρέχουν ήδη τη μεγαλύτερη ερμηνευτική αξία.

4. **Υποερώτημα 4 – Πολυωνυμική παλινδρόμηση**: Υπάρχουν στατιστικά σημαντικές ενδείξεις μη γραμμικότητας και για τις τρεις μεταβλητές (residual sugar, chlorides, alcohol), με τα chlorides να εμφανίζουν την ισχυρότερη μη γραμμική σχέση.

5. **Υποερώτημα 5 – Κριτική**: Η γραμμική παλινδρόμηση δεν είναι η ιδανική επιλογή λόγω (α) διακριτής μεταβλητής απόκρισης, (β) χαμηλού R^2, (γ) παραβίασης υποθέσεων κανονικότητας και ομοσκεδαστικότητας. Εναλλακτικές όπως η τακτική λογιστική παλινδρόμηση ή αλγόριθμοι μηχανικής μάθησης θα ήταν πιο κατάλληλες.

Τι μάθαμε;

Η παλινδρόμηση είναι ένα **ισχυρό εργαλείο** αλλά όχι πανάκεια. Η σωστή χρήση της απαιτεί:

- Κατανόηση των **υποθέσεών** της
- Κριτική σκέψη – τα αποτελέσματα δεν αρκεί να είναι «στατιστικά σημαντικά», πρέπει να είναι και **ουσιαστικά σημαντικά**
- Γνώση εναλλακτικών μεθόδων
- Διαγνωστικούς ελέγχους (residual analysis, VIF, κ.λπ.)

Σε αυτήν την εργασία, αν και η γραμμική παλινδρόμηση αποκάλυψε χρήσιμα μοτίβα (η σημασία του αλκοόλ, η αρνητική επίδραση της πτητικής οξύτητας), η χαμηλή ερμηνευτική ικανότητα ($R^2 \approx 28\%$) υπενθυμίζει ότι η ποιότητα κρασιού είναι ένα **πολύπλοκο** φαινόμενο που δεν μπορεί να αποδοθεί μόνο σε φυσικοχημικές ιδιότητες.