3η Εργασία στο μάθημα “Ανάλυση Δεδομένων” 2025–2026

Πρόβλεψη του τύπου κρασιού (λευκό / κόκκινο)

Ονοματεπώνυμο: Ρακοβαλής Παύλος
ΑΕΜ: 6931

21 Απριλίου 2026

Σύνοψη δεδομένων και πειραματικού πλαισίου

Τα δεδομένα της εργασίας περιέχουν 5 295 παρατηρήσεις κρασιών με 12 αριθμητικά χημικά χαρακτηριστικά και την κατηγορική μεταβλητή στόχο `wine_type` (*red* / *white*). Η κατανομή των κλάσεων είναι έντονα ασύμμετρη:

- **white**: 3 991 δείγματα ($\approx 75{,}4\%$),
- **red**: 1 304 δείγματα ($\approx 24{,}6\%$).

Ο διαχωρισμός σε training/test έγινε με αναλογία **70%/30%**, **stratified** ως προς τη μεταβλητή στόχο, ώστε να διατηρηθεί η αναλογία των δύο κλάσεων και στα δύο υποσύνολα. Η παράμετρος `random_state` ορίζεται ίση με τον ΑΕΜ του φοιτητή, δηλαδή `random_state = 6931`. Έτσι το test set περιέχει 391 ερυθρά και 1198 λευκά κρασιά ($n_{\text{test}} = 1589$).

Όλη η ανάλυση υλοποιήθηκε σε `Python 3.12` με χρήση των βιβλιοθηκών `pandas`, `numpy`, `scikit-learn` και `matplotlib`. Σε όλη τη συνέχεια χρησιμοποιείται η σύμβαση **red = 0** (αρνητική κλάση) και **white = 1** (θετική κλάση).

1 Ερώτημα Α — Πρόβλεψη με μία προβλεπτική μεταβλητή

Για κάθε μία από τις τρεις προβλεπτικές μεταβλητές **Alcohol**, **pH** και **Chlorides** εφαρμόστηκαν τρεις ταξινομητές:

- Logistic Regression (LogReg)
- Linear Discriminant Analysis (LDA)
- Gaussian Naive Bayes (GNB), με την υπόθεση κανονικής κατανομής για το χαρακτηριστικό σε κάθε κλάση.

Συνολικά εκπαιδεύτηκαν $3 \times 3 = 9$ μοντέλα.

1.1 Μέτρα αξιολόγησης που χρησιμοποιήθηκαν

Λόγω της σημαντικής ανισορροπίας των κλάσεων, η απλή *accuracy δεν* είναι κατάλληλο μέτρο: ένας ταξινομητής που προβλέπει συστηματικά “white” πετυχαίνει ήδη accuracy $\approx 0{,}754$. Για τον λόγο αυτό αναφέρονται επιπλέον:

- **Balanced Accuracy** = $\frac{\text{Sensitivity}+\text{Specificity}}{2}$, ανθεκτικό σε ασύμμετρες κλάσεις.

- **Sensitivity (Recall white)** = $\dfrac{TP}{TP+FN}$.
- **Specificity (Recall red)** = $\dfrac{TN}{TN+FP}$.
- **Precision** ανά κλάση και **F1** ανά κλάση.
- **AUC (ROC)**: ολοκλήρωμα της καμπύλης ROC, ανεξάρτητο από το κατώφλι απόφασης.

1.2 A(i) Confusion matrices και μέτρα ακρίβειας

(α) Προβλεπτική μεταβλητή: *Alcohol*

Πίνακας 1: Confusion matrices στο test set — μεταβλητή *alcohol*.

	LogReg		**LDA**		**GNB**	
	pred red	pred white	pred red	pred white	pred red	pred white
true red	0	391	0	391	0	391
true white	0	1198	0	1198	0	1198

Πίνακας 2: Μέτρα ακρίβειας — μεταβλητή *alcohol*.

Method	Acc	BalAcc	AUC	Sens(w)	Spec(r)	F1(w)	F1(r)
LogReg	0,7539	0,5000	0,5219	1,0000	0,0000	0,8597	0,0000
LDA	0,7539	0,5000	0,5219	1,0000	0,0000	0,8597	0,0000
GNB	0,7539	0,5000	0,5678	1,0000	0,0000	0,8597	0,0000

Σχόλιο: Και οι τρεις μέθοδοι υπολογίζουν *όριο απόφασης* έξω από την περιοχή των δεδομένων και προβλέπουν συστηματικά την πλειοψηφική κλάση (*white*). Η accuracy ($0{,}754$) ταυτίζεται ακριβώς με τη συχνότητα της πλειοψηφικής κλάσης. Η balanced accuracy ισούται με $0{,}5$, δηλώνοντας ότι το μοντέλο δεν έχει *καμία* διακριτική ικανότητα. Το AUC είναι σχεδόν στο τυχαίο όριο ($\approx 0{,}52$ για LogReg/LDA, $0{,}57$ για GNB), που εξηγείται από το γεγονός ότι οι μέσες τιμές της *alcohol* στις δύο κλάσεις είναι σχεδόν ίδιες (10,44 για red έναντι 10,53 για white) σε σχέση με την τυπική απόκλιση ($\approx 1{,}1$).

(β) Προβλεπτική μεταβλητή: *pH*

Πίνακας 3: Confusion matrices στο test set — μεταβλητή *pH*.

	LogReg		**LDA**		**GNB**	
	pred red	pred white	pred red	pred white	pred red	pred white
true red	36	355	40	351	44	347
true white	30	1168	42	1156	47	1151

Σχόλιο: Η *pH* φέρνει μέτρια διακριτική ικανότητα (AUC $\approx 0{,}680$). Το πρόσημο του συντελεστή είναι *αρνητικό* ($\hat{\beta}_1 \approx -4{,}20$ στη LogReg), δηλαδή υψηλότερο pH συσχετίζεται με κόκκινο κρασί (μέσο pH 3,30 έναντι 3,20). Παρότι η accuracy αυξάνεται οριακά, η balanced accuracy μένει κοντά στο $0{,}53$, επειδή ο ταξινομητής εξακολουθεί να μην "πιάνει" σχεδόν καθόλου την κλάση red (specificity $\leq 0{,}11$).

Πίνακας 4: Μέτρα ακρίβειας — μεταβλητή *pH*.

Method	Acc	BalAcc	AUC	Sens(w)	Spec(r)	F1(w)	F1(r)
LogReg	0,7577	0,5335	0,6798	0,9750	0,0921	0,8585	0,1575
LDA	0,7527	0,5336	0,6798	0,9649	0,1023	0,8547	0,1691
GNB	0,7520	0,5366	0,6798	0,9608	0,1125	0,8539	0,1826

(γ) Προβλεπτική μεταβλητή: *Chlorides*

Πίνακας 5: Confusion matrices στο test set — μεταβλητή *chlorides*.

	LogReg		**LDA**		**GNB**	
	pred red	pred white	pred red	pred white	pred red	pred white
true red	26	365	80	311	99	292
true white	23	1175	38	1160	38	1160

Πίνακας 6: Μέτρα ακρίβειας — μεταβλητή *chlorides*.

Method	Acc	BalAcc	AUC	Sens(w)	Spec(r)	F1(w)	F1(r)
LogReg	0,7558	0,5236	**0,9220**	**0,9808**	0,0665	0,8583	0,1182
LDA	0,7804	0,5864	**0,9220**	0,9683	0,2046	0,8692	0,3143
GNB	**0,7923**	**0,6107**	0,9214	0,9683	**0,2532**	**0,8755**	**0,3750**

Σχόλιο: Η *chlorides* είναι αναμφισβήτητα η ισχυρότερη μονή μεταβλητή. Η AUC ξεπερνά το $0{,}92$ και για τις τρεις μεθόδους, ενώ *μόνο εδώ* η balanced accuracy ξεπερνά αξιόλογα το $0{,}5$ — δείκτης ότι ο ταξινομητής αρχίζει να αναγνωρίζει και την κλάση red. Τα κόκκινα κρασιά έχουν σχεδόν διπλάσιο μέσο επίπεδο χλωριούχων (0,086 έναντι 0,047), διαφορά που είναι μεγαλύτερη από τις τυπικές αποκλίσεις.

Παρατήρηση για παραμέτρους Gaussian Naive Bayes. Για κάθε μία προβλεπτική μεταβλητή, ο GNB εκτιμά μέσο και διασπορά ξεχωριστά για κάθε κλάση. Στο training set προέκυψαν:

Πίνακας 7: Παράμετροι Gaussian Naive Bayes ανά κλάση.

Predictor	μ_{red}	σ_{red}	μ_{white}	σ_{white}
alcohol	10,429	1,013	10,553	1,141
pH	3,295	0,149	3,197	0,143
chlorides	0,086	0,050	0,046	0,023

Ιδιαίτερα στη μεταβλητή *chlorides*, η διασπορά της κλάσης red είναι σχεδόν διπλάσια εκείνης της κλάσης white. Αυτή η διαφορά εκμεταλλεύεται από τον GNB (που επιτρέπει διαφορετική σ ανά κλάση) αλλά *όχι* από την LDA (που υποθέτει κοινή διασπορά).

1.3 A(ii) Καταλληλότερη προβλεπτική μεταβλητή

Από τα παραπάνω αποτελέσματα προκύπτει σαφέστατα ότι η **Chlorides** είναι η καταλληλότερη μονή προβλεπτική μεταβλητή για την πρόβλεψη του τύπου κρασιού. Η εκτίμηση τεκμηριώνεται στους εξής άξονες:

1. **AUC.** Η *chlorides* έχει AUC $\approx 0{,}92$, έναντι $0{,}68$ της *pH* και $0{,}52 \sim 0{,}57$ της *alcohol*. Το AUC είναι το πιο "δίκαιο" μέτρο, καθώς αξιολογεί τη διακριτική ικανότητα του ταξινομητή ανεξάρτητα από το επιλεγμένο κατώφλι.

2. **Λόγος σήματος προς θόρυβο.** Η απόσταση των μέσων τιμών των δύο κλάσεων ως προς τη μέση τυπική απόκλιση είναι:

$$d_{\text{chlorides}} \approx \frac{0{,}086 - 0{,}046}{0{,}037} \approx 1{,}1, \quad d_{\text{pH}} \approx \frac{0{,}10}{0{,}146} \approx 0{,}68, \quad d_{\text{alcohol}} \approx \frac{0{,}12}{1{,}08} \approx 0{,}11.$$

   Δηλαδή η chlorides προσφέρει *σήμα* τάξης μεγέθους ίσο με τη διασπορά, ενώ η alcohol πρακτικά κανένα.

3. **Balanced Accuracy.** Με την *chlorides* η balanced accuracy φτάνει το $0{,}61$ (GNB), ενώ με τις άλλες δύο μεταβλητές παραμένει κοντά στο τυχαίο όριο $0{,}5$.

4. **F1 για την κλάση red.** Μόνο η *chlorides* επιτρέπει αξιοπρεπή ταξινόμηση της μειοψηφικής κλάσης (F1_{red} έως $0{,}38$). Με τις άλλες μεταβλητές, η F1_{red} κυμαίνεται μεταξύ 0 και $0{,}18$.

5. **Φυσική / οινολογική ερμηνεία.** Τα ερυθρά κρασιά παράγονται με μάκρωση επί της φλούδας, διαδικασία που τυπικά αυξάνει τη συγκέντρωση χλωριούχων αλάτων. Είναι λοιπόν αναμενόμενο και ερμηνεύσιμο φυσικά να αποτελεί η *chlorides* τον ισχυρότερο διακριτή των δύο τύπων.

1.4 A(iii) Σύγκριση μεθόδων με προβλεπτική την Chlorides

Στην ενότητα αυτή εξετάζουμε αν οι τρεις μέθοδοι ταξινόμησης παρουσιάζουν σημαντική διαφορά στην επίδοση όταν χρησιμοποιείται *αποκλειστικά* η μεταβλητή *chlorides*.

Διαφορές στις προβλέψεις του test set

Πίνακας 8: Επίδοση των τριών μεθόδων στο test set με μοναδική προβλεπτική την *chlorides*.

Method	Accuracy	BalAcc	AUC	Sens(w)	Spec(r)
LogReg	0,7558	0,5236	**0,9220**	**0,9808**	0,0665
LDA	0,7804	0,5864	**0,9220**	0,9683	0,2046
GNB	**0,7923**	**0,6107**	0,9214	0,9683	**0,2532**

Έλεγχος στατιστικής σημαντικότητας: McNemar test

Ο έλεγχος του *McNemar* είναι ζευγαρωτός: συγκρίνει τις σωστές / λανθασμένες προβλέψεις δύο ταξινομητών στα *ίδια* test δείγματα. Η μηδενική υπόθεση είναι ότι τα δύο μοντέλα έχουν την ίδια πιθανότητα λάθους.

Και οι τρεις p-τιμές είναι μικρότερες του $\alpha = 0{,}05$, άρα οι διαφορές στην επίδοση είναι **στατιστικά σημαντικές**. Η σχέση που προκύπτει είναι:

$$\text{GNB} \succ \text{LDA} \succ \text{LogReg}$$

με την έννοια ότι ο επόμενος πετυχαίνει *περισσότερες* σωστές προβλέψεις από τον προηγούμενο.

Πίνακας 9: McNemar test (paired) — *chlorides* ως μοναδική προβλεπτική.

Σύγκριση (A vs B)	A σωστό & B λάθος	A λάθος & B σωστό	p-value
LogReg vs LDA	15	54	$2{,}6 \times 10^{-6}$
LogReg vs GNB	15	73	$2{,}6 \times 10^{-10}$
LDA vs GNB	0	19	$3{,}8 \times 10^{-6}$

Επιβεβαίωση με 10-fold Stratified Cross-Validation

Για να αποκλειστεί η εξάρτηση από συγκεκριμένο διαχωρισμό, τα μοντέλα αξιολογήθηκαν επιπλέον με 10-fold stratified cross-validation σε όλο το dataset:

Πίνακας 10: 10-fold Stratified CV (μέσος $\pm$ τυπική απόκλιση).

Method	Accuracy	Balanced Accuracy	AUC
LogReg	$0{,}7535 \pm 0{,}0053$	$0{,}5195 \pm 0{,}0105$	$0{,}9184 \pm 0{,}0124$
LDA	$0{,}7817 \pm 0{,}0098$	$0{,}5859 \pm 0{,}0180$	$0{,}9184 \pm 0{,}0124$
GNB	$\mathbf{0{,}7915 \pm 0{,}0098}$	$\mathbf{0{,}6082 \pm 0{,}0181}$	$0{,}9176 \pm 0{,}0106$

Τα CV αποτελέσματα επιβεβαιώνουν την κατάταξη: ο GNB έχει τη μεγαλύτερη μέση accuracy και balanced accuracy, η LDA ακολουθεί πολύ κοντά, ενώ η LogReg υπολείπεται κατά ≈ 4 ποσοστιαίες μονάδες.

Συζήτηση: γιατί διαφέρουν παρόλο που το AUC είναι σχεδόν ίδιο;

Όλες οι μέθοδοι παράγουν *ίδιας ποιότητας διάταξη* πιθανοτήτων (AUC $\approx 0{,}92$ και για τις τρεις). Άρα η ικανότητά τους να διαχωρίσουν τις δύο κλάσεις σε επίπεδο πιθανοτήτων είναι ισοδύναμη. Οι διαφορές στην accuracy εντοπίζονται στο *σημείο* όπου τοποθετείται το όριο απόφασης (κατώφλι $0{,}5$ στην προβλεπόμενη πιθανότητα):

- **LogReg.** Μοντελοποιεί άμεσα το $\log\frac{p}{1-p}$ ως γραμμική συνάρτηση της chlorides. Λόγω της ασυμμετρίας των κλάσεων και του γεγονότος ότι η μεγάλη πυκνότητα των white τιμών συγκεντρώνεται σε μικρά chlorides, το όριο $p = 0{,}5$ μετατοπίζεται σε υψηλή τιμή chlorides — με αποτέλεσμα σχεδόν όλα τα δείγματα να ταξινομούνται ως white.
- **LDA.** Υποθέτει κανονική κατανομή ανά κλάση με *κοινή* διασπορά. Ενσωματώνει ρητά τα priors (3:1 υπέρ της white) στον υπολογισμό των posterior, αλλά συγχρόνως ισορροπεί το όριο σε σημείο που λαμβάνει υπόψη τις μέσες τιμές των δύο κλάσεων.
- **GNB.** Επιτρέπει *διαφορετική* διασπορά ανά κλάση. Αξιοποιεί το γεγονός ότι $\sigma_{\text{red}} \approx 2 \cdot \sigma_{\text{white}}$, ώστε η posterior $P(\text{red} \mid x)$ να αυξάνει πιο γρήγορα όταν η τιμή χλωριούχων ξεπερνά τη μέση τιμή των white. Έτσι τοποθετεί το όριο σε χαμηλότερο σημείο και "πιάνει" περισσότερα κόκκινα δείγματα.

Συμπέρασμα του A(iii)

- Υπάρχει **σημαντική (στατιστικά) διαφορά** στην επίδοση των μεθόδων όταν χρησιμοποιείται μόνο η *chlorides*.
- Καλύτερη απόδοση παρουσιάζει ο **Gaussian Naive Bayes** (accuracy $\approx 0{,}79$, balanced accuracy $\approx 0{,}61$, $\text{F1}_{\text{red}} \approx 0{,}38$).

- Η διαφορά οφείλεται στην ικανότητά του GNB να μοντελοποιεί διαφορετικές διασπορές ανά κλάση, σε αντίθεση με τη LDA που υποθέτει κοινή διασπορά.
- Η LogReg, παρότι έχει *ίδιο* AUC με τις άλλες, λειτουργεί πρακτικά ως majority-class predictor στο κατώφλι $0{,}5$ και είναι η χειρότερη επιλογή στη συγκεκριμένη ρύθμιση.

2 Ερώτημα Β — Πρόβλεψη με όλες τις προβλεπτικές μεταβλητές

Στο Ερώτημα Β χρησιμοποιούμε ως προβλεπτικές μεταβλητές *όλες* τις χημικές μετρήσεις του dataset, εξαιρώντας μόνο τις δύο μη-προβλεπτικές στήλες: τη μεταβλητή στόχο `wine_type` και τη μεταβλητή `quality` (όπως ορίζει η εκφώνηση). Καταλήγουμε έτσι σε $p = 11$ προβλεπτικές: *fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulphates, alcohol*.

Διατηρούμε τον ίδιο διαχωρισμό 70%/30% stratified με `random_state=6931`, συνεπώς το test set περιέχει 391 red και 1198 white δείγματα ($n_{\text{test}} = 1589$).

2.1 Μέθοδοι και προεπεξεργασία

Εκπαιδεύτηκαν πέντε ταξινομητές:

1. **KNN**, με την παράμετρο K να επιλέγεται μέσω *5-fold Stratified CV* στο training set.
2. **Logistic Regression** (`lbfgs`, `max_iter=5000`).
3. **Linear Discriminant Analysis (LDA)**.
4. **Quadratic Discriminant Analysis (QDA)**, με ελαφρά κανονικοποίηση `reg_param` = 10^{-3} για την αντιμετώπιση οριακά μη-αντιστρέψιμου πίνακα συνδιακύμανσης.
5. **Gaussian Naive Bayes (GNB)**.

Σχετικά με την κανονικοποίηση δεδομένων. Οι προβλεπτικές μεταβλητές διαφέρουν δραστικά σε κλίμακα (π.χ. *total sulfur dioxide* εύρους έως ~ 440 έναντι *chlorides* εύρους $\sim 0{,}6$). Συνεπώς:

- **KNN**: *απαραίτητη* τυποποίηση (`StandardScaler`), διότι ο αλγόριθμος βασίζεται σε ευκλείδειες αποστάσεις και θα κυριαρχούσαν οι μεταβλητές με μεγάλη κλίμακα.
- **Logistic Regression**: *συνιστάται* τυποποίηση για αριθμητική σταθερότητα και ταχύτερη σύγκλιση του `lbfgs`.
- **LDA, QDA, GNB**: είναι αμετάβλητοι σε γραμμική αλλαγή κλίμακας ανά μεταβλητή, οπότε η τυποποίηση δεν είναι απαραίτητη (αλλά και δεν επηρεάζει αρνητικά).

Στην υλοποίηση, η τυποποίηση ενσωματώθηκε σε `Pipeline` ώστε ο `StandardScaler` να εκτιμάται μόνο στο training fold του CV, αποφεύγοντας *data leakage*.

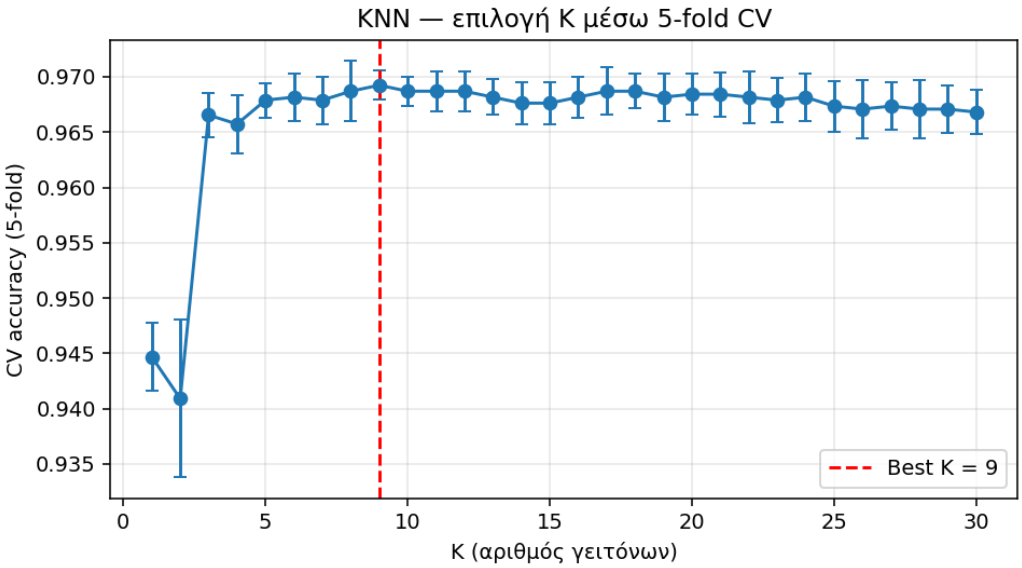

Σχήμα 1: Επιλογή της βέλτιστης τιμής K για τον KNN μέσω 5-fold stratified CV. Το κόκκινο διακεκομμένο δείχνει τη βέλτιστη τιμή $K = 9$. Οι μπάρες σφάλματος αντιστοιχούν στην τυπική απόκλιση μεταξύ των 5 folds.

2.2 Επιλογή της παραμέτρου K για τον KNN

Με 5-fold stratified cross-validation στο training set (3 706 δείγματα) και $K \in \{1, 2, \ldots, 30\}$, η μέση CV accuracy μεγιστοποιείται στο $\boxed{K = 9}$ με τιμή $0{,}9692$ (Σχήμα 1).
Σχόλιο: Η καμπύλη CV accuracy εμφανίζει χαρακτηριστική συμπεριφορά: οι πολύ μικρές τιμές $K \in \{1, 2\}$ υποαποδίδουν ($\sim 0{,}94$) λόγω υψηλής διασποράς (overfitting), σταθεροποιείται από $K \approx 5$ και άνω σε ένα "plateau" γύρω στο $0{,}967$, με τη μέγιστη τιμή στο $K = 9$. Επειδή οι διαφορές μετά το $K \approx 5$ είναι μικρότερες από την τυπική απόκλιση, η επιλογή $K = 9$ είναι ουσιαστικά ισοδύναμη με κάθε τιμή στο διάστημα $[5, 20]$.

2.3 B(i) Confusion matrices στο test set

Για κάθε μέθοδο παρουσιάζεται ο πίνακας σύγχυσης στα 1 589 δείγματα του test set (red = αρνητική, white = θετική κλάση).

Πίνακας 11: Confusion matrices στο test set — όλες οι μέθοδοι του Ερωτήματος B.

	KNN ($K = 9$)		**LogReg**		**LDA**		**QDA**		**GNB**	
	pred r	pred w	pred r	pred w	pred r	pred w	pred r	pred w	pred r	pred w
true red	369	22	363	28	363	28	357	34	358	33
true white	25	1173	27	1171	23	1175	36	1162	56	1142

2.4 B(ii) Μέτρα ακρίβειας

Παρουσιάζονται για κάθε μέθοδο τα ίδια μέτρα με το Ερώτημα A (accuracy, balanced accuracy, sensitivity, specificity, F1 ανά κλάση, AUC), διατηρώντας τη διάκριση red/white λόγω της σημαντικής ανισορροπίας των κλάσεων.
Με όλες τις προβλεπτικές μεταβλητές διαθέσιμες, και οι πέντε μέθοδοι επιτυγχάνουν *εξαιρετική* επίδοση: η accuracy κυμαίνεται από $0{,}9440$ (GNB) έως $0{,}9704$ (KNN), η balanced accuracy ξεπερνά παντού το $0{,}93$ — δραματική βελτίωση σε σχέση με το Ερώτημα A

Πίνακας 12: Μέτρα ακρίβειας στο test set — όλες οι 11 προβλεπτικές μεταβλητές.

Method	Acc	BalAcc	AUC	Sens(w)	Spec(r)	F1(w)	F1(r)
KNN (K=9)	**0,9704**	**0,9614**	0,9664	0,9791	**0,9437**	**0,9804**	**0,9401**
LogReg	0,9654	0,9529	**0,9692**	0,9775	0,9284	0,9771	0,9296
LDA	0,9679	0,9546	0,9678	**0,9808**	0,9284	0,9788	0,9344
QDA	0,9559	0,9415	0,9605	0,9699	0,9130	0,9708	0,9107
GNB	0,9440	0,9344	0,9575	0,9533	0,9156	0,9625	0,8894

($\leq$ 0,61). Η ισχυρή ικανότητα ταξινόμησης οφείλεται στο γεγονός ότι οι 11 χημικές μεταβλητές προσφέρουν *συμπληρωματική* πληροφορία (π.χ. *volatile acidity*, *total sulfur dioxide*, *residual sugar*), που μαζί διαχωρίζουν σχεδόν τέλεια τα ερυθρά από τα λευκά κρασιά.

2.5 B(iii) Καμπύλες ROC και AUC

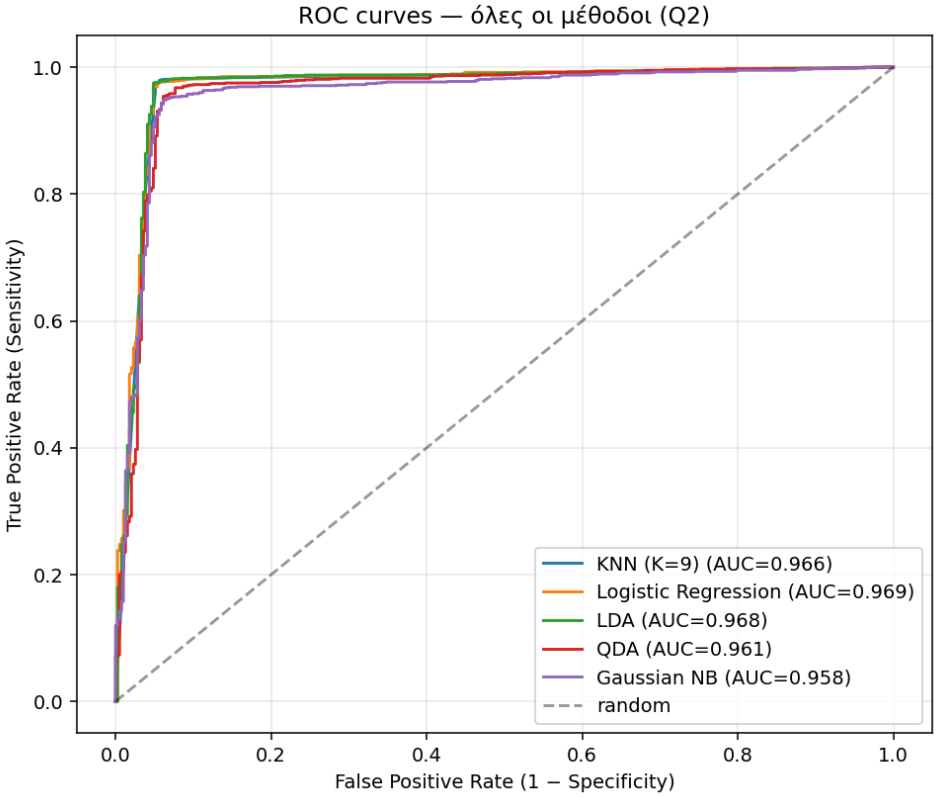

Σχήμα 2: Καμπύλες ROC των πέντε μεθόδων στο test set (Ερώτημα B). Η διακεκομμένη μαύρη γραμμή αντιστοιχεί σε τυχαίο ταξινομητή ($AUC = 0{,}5$).

Οι τιμές AUC συνοψίζονται παρακάτω:
Όλες οι μέθοδοι έχουν AUC $> 0{,}95$, δηλαδή σχεδόν τέλεια διακριτική ικανότητα. Παρατηρείται ότι:

- Οι **γραμμικές** μέθοδοι (LogReg, LDA) και ο **KNN** αποτελούν την "επάνω" ομάδα με AUC $\in [0{,}966, 0{,}970]$.
- Οι QDA και GNB πέφτουν χαμηλότερα (0,96 και 0,958).

Πίνακας 13: AUC ανά μέθοδο (Ερώτημα B).

Method	AUC
Logistic Regression	**0,9692**
LDA	0,9678
KNN ($K = 9$)	0,9664
QDA	0,9605
Gaussian NB	0,9575

- Στο επίπεδο των πιθανοτήτων, η Logistic Regression έχει οριακά την υψηλότερη AUC ($0{,}9692$), αλλά *σε επίπεδο απόφασης* (κατώφλι $0{,}5$) ο KNN πετυχαίνει την υψηλότερη accuracy και balanced accuracy χάρη σε καλύτερη *specificity* στην κλάση red.

2.6 B(iv) Στατιστική σύγκριση των μεθόδων: McNemar test

Για τον έλεγχο σημαντικής διαφοράς ανάμεσα στις πέντε μεθόδους εφαρμόστηκε ο ζευγαρωτός έλεγχος του *McNemar* σε όλα τα $\binom{5}{2} = 10$ ζεύγη. Σε κάθε ζεύγος καταγράφονται: b_{AB} = δείγματα όπου σωστή *μόνο* η A και b_{BA} = δείγματα όπου σωστή *μόνο* η B. Λόγω σχετικά μικρών συνολικών ασυμφωνιών χρησιμοποιήθηκε η ακριβής (*exact*) εκδοχή του test.

Πίνακας 14: McNemar test (paired) — Ερώτημα B. Έντονο = $p < 0{,}05$.

Σύγκριση (A vs B)	b_{AB}	b_{BA}	p-value
KNN vs LogReg	13	5	0,096
KNN vs LDA	9	5	0,424
KNN vs QDA	27	4	$7{,}8 \times 10^{-5}$
KNN vs GNB	44	2	$1{,}5 \times 10^{-9}$
LogReg vs LDA	2	6	0,289
LogReg vs QDA	21	6	$7{,}1 \times 10^{-3}$
LogReg vs GNB	38	4	$3{,}5 \times 10^{-7}$
LDA vs QDA	24	5	$8{,}3 \times 10^{-4}$
LDA vs GNB	42	4	$4{,}9 \times 10^{-8}$
QDA vs GNB	25	6	$1{,}2 \times 10^{-3}$

Με βάση τα παραπάνω αποτελέσματα προκύπτει η ακόλουθη ιεράρχηση:

$$\underbrace{\{\text{KNN},\ \text{LogReg},\ \text{LDA}\}}_{\text{ομάδα A — κορυφαία, χωρίς εσωτερικές διαφορές}} \succ \underbrace{\text{QDA}}_{\text{ενδιάμεση}} \succ \underbrace{\text{GNB}}_{\text{χαμηλότερη}}$$

Συγκεκριμένα: (α) τα τρία μέλη της ομάδας A δεν διαφέρουν *εσωτερικά* ($p \in [0{,}10,\ 0{,}42]$, μη-σημαντικές διαφορές), (β) ο QDA διαφέρει *στατιστικά σημαντικά* τόσο από κάθε μέλος της ομάδας A ($p \leq 7 \times 10^{-3}$) όσο και από τον GNB ($p = 1{,}2 \times 10^{-3}$), και (γ) ο GNB είναι ο μοναδικός ταξινομητής που διαφέρει σημαντικά από *όλους* τους υπόλοιπους.

2.7 B(v) Συμπεράσματα — Βέλτιστη μέθοδος και σχόλια

- **Υπάρχει** σημαντική διαφορά στην επίδοση των μεθόδων: ο QDA υπολείπεται στατιστικά σημαντικά της κορυφαίας τριάδας, ενώ ο GNB είναι σαφώς ο χειρότερος και διαφέρει σημαντικά από *όλους* τους άλλους.

- **Καλύτερη ακρίβεια στο test set:** ο **KNN με** $K = 9$ (accuracy = $0{,}9704$, balanced accuracy = $0{,}9614$, F1_{red} = $0{,}9401$). Παρόλο που η διαφορά του από LogReg και LDA *δεν* είναι στατιστικά σημαντική (McNemar $p = 0{,}10 \sim 0{,}42$), έχει συστηματικά ελαφρώς υψηλότερη *specificity* στην κλάση red.

- **Γιατί οι γραμμικές μέθοδοι (LogReg, LDA) είναι τόσο ισχυρές εδώ:** Ο διαχωρισμός λευκών/ερυθρών είναι σε μεγάλο βαθμό *γραμμικά διαχωρίσιμος* στον χώρο των 11 χημικών μεταβλητών (μεταβλητές όπως *volatile acidity*, *chlorides*, *total sulfur dioxide* έχουν πολύ διαφορετικά μέσα ανά κλάση). Έτσι μια γραμμική επιφάνεια απόφασης είναι αρκετή για να πετύχει κανείς $> 96{,}7\%$ accuracy.

- **Γιατί υπολείπονται οι QDA και GNB:** Και οι δύο είναι *γενναιόδωρες* μέθοδοι ως προς τις παραμέτρους που εκτιμούν. Ο QDA εκτιμά *ξεχωριστούς* πίνακες συνδιακύμανσης ανά κλάση ($p(p+1)/2 = 66$ παράμετροι ανά κλάση), που με την παρούσα αναλογία θετικών/αρνητικών δειγμάτων (αλλά κυρίως λόγω σχεδόν συνγραμμικών μεταβλητών όπως *density* με *residual sugar*) οδηγούν σε ασταθή-/σχεδόν singular εκτιμήσεις (απαιτείται `reg_param` > 0). Ο GNB έχει το αντίθετο πρόβλημα: υποθέτει *ανεξαρτησία* όλων των προβλεπτικών δοθείσας της κλάσης, που είναι έντονα ψευδής υπόθεση όταν π.χ. *free* SO_2 και *total* SO_2 είναι ισχυρά συσχετισμένες.

- **Σύγκριση με το Ερώτημα Α:** Η balanced accuracy αυξάνεται από $\approx 0{,}61$ (chlorides μόνο) σε $\approx 0{,}96$ (όλες οι μεταβλητές) — βελτίωση κατά 35 ποσοστιαίες μονάδες, η οποία τονίζει τη *συμπληρωματικότητα* των χημικών χαρακτηριστικών στην ταξινόμηση τύπου κρασιού.

Τελικό συμπέρασμα Ερωτήματος Β

Οι μέθοδοι KNN, Logistic Regression και LDA σχηματίζουν την κορυφαία ομάδα με στατιστικά ισοδύναμη επίδοση. Στο συγκεκριμένο test set ο **KNN με** $K = 9$ είναι ο ταξινομητής με την υψηλότερη *accuracy* ($97{,}04\%$), τη μεγαλύτερη *balanced accuracy* ($96{,}14\%$) και την καλύτερη ισορροπία μεταξύ ευαισθησίας στην κλάση white και ειδικότητας στην κλάση red. Ο QDA έπεται στατιστικά σημαντικά (accuracy $95{,}59\%$), ενώ ο GNB είναι ο χειρότερος ταξινομητής, διαφέροντας σημαντικά και από τον QDA, λόγω της απλοϊκής υπόθεσης ανεξαρτησίας των χαρακτηριστικών (που καταρρίπτεται από τις ισχυρές συσχετίσεις π.χ. ανάμεσα σε *free* και *total* SO_2 ή *density* και *residual sugar*).